

Trabajo 1 - Tres series: descripción, operador de rezago, dependencia, pronóstico y argumentación

Por: Daniel Bustamante Cortés, Andrés Felipe López Díaz y Viviana Astrid León Oróstogue

Departamento de Estadística, Facultad de Ciencias
Universidad Nacional de Colombia – Sede Medellín

Series de Tiempo (3009297)

Docente: Juan Pablo Valencia Arango

Octubre 15, 2026

Tabla de contenidos

Las tres series y la pregunta de pronóstico 3
Descripción del patrón 5
Operador de rezago 12
Dependencia y estacionariedad 21
Pronóstico y evaluación 34
Conclusión técnica 82
Argumentos para los interesados 83

Las tres series y la pregunta de pronóstico

(a) Para cada serie, una ficha verificada con código: nombre, unidad, frecuencia, fecha inicial y final, T, mínimo, máximo y media.

- Ficha técnica para la serie 1:

Atributo	Valor
Nombre	Casos mensuales de enfermedad diarreica aguda notificados
Unidad	Casos de enfermedad diarreica aguda notificados
Frecuencia	Mensual
Fecha inicial	2013-01-01
Fecha final	2025-12-01
Número de observaciones (T)	156
Mínimo	74
Máximo	311
Media	169.0448718

- Ficha técnica para la serie 2:

Atributo	Valor
Nombre	Afiliados activos a un programa de control de hipertensión
Unidad	Personas inscritas y activas en el programa de control de hipertensión arterial
Frecuencia	Semanal
Fecha inicial	2022-12-05
Fecha final	2025-12-22
Número de observaciones (T)	160
Mínimo	48
Máximo	478
Media	218.1625

- Ficha técnica para la serie 3:

Atributo	Valor
Nombre	Consultas semanales por enfermedad respiratoria en un hospital

Atributo	Valor
Unidad	Consultas de medicina general cuyo motivo principal es una enfermedad respiratoria
Frecuencia	Semanal
Fecha inicial	2021-01-04
Fecha final	2025-08-04
Número de observaciones (T)	240
Mínimo	99
Máximo	146
Media	121.1416667

(b) Para cada serie, a partir del contexto, la pregunta de pronóstico escrita por el equipo, la decisión que depende de la respuesta y el horizonte H que esa decisión exige, en dos o tres líneas y coherente con la unidad y la frecuencia de la serie.

- Para la serie 1: *¿Cuántos casos mensuales de EDA se esperarán el siguiente año?* La idea es pronosticar mensualmente los casos para los próximos 12 meses ($H = 12$). La decisión es programar con tres meses de anticipación las brigadas y las compras de sales, con el fin de asignar el presupuesto anual aprobado en noviembre y evitar el doble de costo que implicarían las contrataciones de urgencia ante un brote. El horizonte cubre un año completo, lo cual permite planificar el presupuesto y las brigadas para cada mes del año que sigue.
- Para la serie 2: *¿Cuántas dosis de medicamento semanales para la hipertensión se deben considerar para la siguiente compra?* La decisión es hallar la cantidad de medicamento que logre un equilibrio entre escasez y vencimiento de las dosis. Se desea pronosticar semanalmente los afiliados para las próximas 6 semanas ($H = 6$), pues la compra se hace cada cuatro semanas y hay un plazo de entrega de dos.
- Para la serie 3: *¿Cuántas consultas por enfermedades respiratorias se esperan en la semana del próximo bloque, y por tanto, cuántos médicos adicionales se deben contratar para tratar estas consultas?* La decisión es encontrar el número óptimo de médicos que minimize el número de pacientes en urgencias, sin representar una carga económica elevada por el número de personal. El objetivo es pronosticar semanalmente la cantidad de médicos a contratar para las siguientes 6 semanas ($H = 6$), debido a que los médicos adicionales se contratan por cuatro semanas con dos de anticipación.

(c) Una tabla de las tres series con la partición de la sección de reglas: n_0, H, número de orígenes para $h = 1$ y para H, y fechas que delimitan cada tramo.

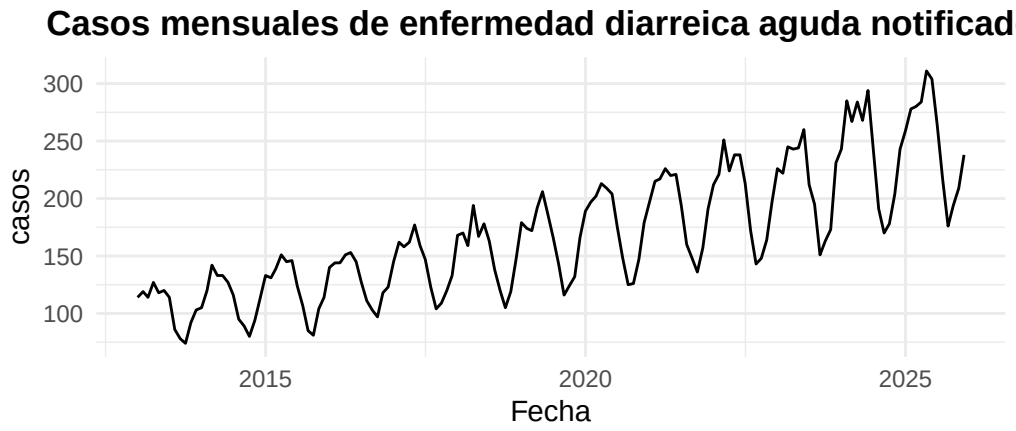
Serie	n_0	H	Número de orígenes $h = 1$	Número de orígenes $h = H$	Fechas de entrena-miento	Fechas de evaluación
1	124	12	32	21	2013-01-01 hasta 2023-04-01	2023-05-01 hasta 2025-12-01
2	128	6	32	27	2022-12-05 hasta 2025-05-12	2025-05-19 hasta 2025-12-22
3	192	6	48	43	2021-01-04 hasta 2024-09-02	2024-09-09 hasta 2025-08-04

Descripción del patrón

(a) Para cada serie, el gráfico en el tiempo, con título, ejes con nombre y unidad, eje de fechas legible y un caption con el número de observaciones, y el gráfico de rezagos de y_t contra y_{t-k} para los rezagos que el equipo juzgue informativos, justificando la elección.

Para definir el número de rezagos en cada gráfico de rezagos para las 3 series se tuvo en cuenta la información previamente definida del horizonte H, en cada caso. En la serie 1, 12 rezagos permiten ver el comportamiento dentro de un año, en la serie 2 y 3, al ser semanales y ambas tener un horizonte de 6 un rezago igual a este valor permite observar que pasa en este lapso de tiempo, que es el de interés.

```
g1 <- graficar_serie(datos1, titulo = "Casos mensuales de enfermedad diarreica aguda notifica
g2 <- grafico_rezagos(datos = datos1, k = 12)
g1 / g2
```



Número de observaciones: 156



La serie de casos mensuales de EDA presenta una tendencia creciente a lo largo del tiempo, junto a un patrón estacional. El gráfico de rezagos muestra una relación lineal positiva entre las observaciones presentes (y_t) y pasadas (y_{t-12}), lo que confirma una alta autocorrelación y una fuerte dependencia estructural en los datos.

```
g1 <- graficar_serie(datos2, titulo = "Afiliados activos al programa de control de hipertensi
g2 <- grafico_rezagos(datos = datos2, k = 6)
g1 / g2
```

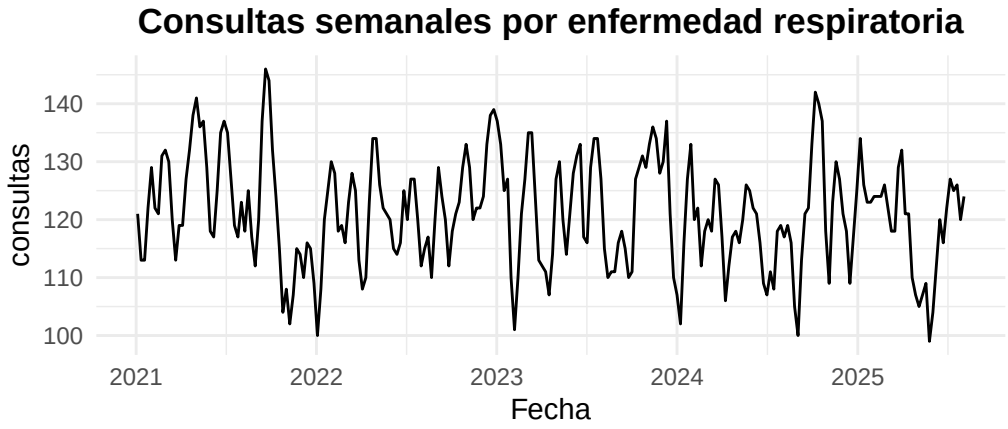


Número de observaciones: 160

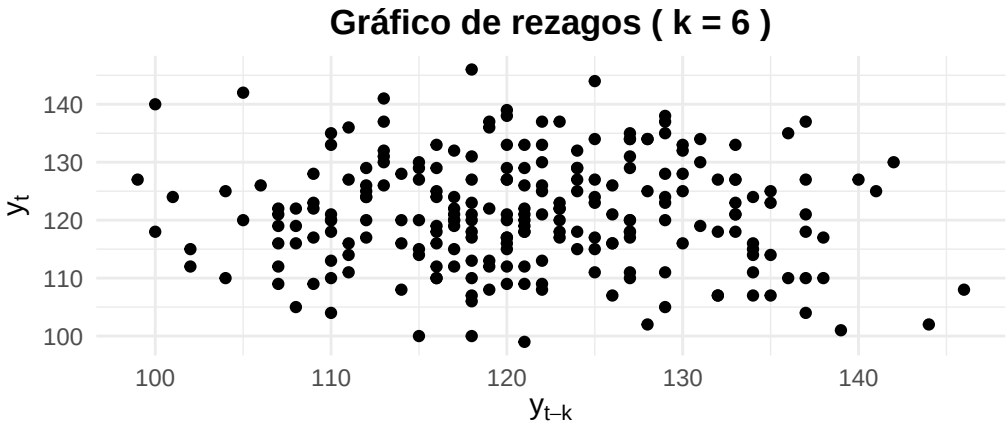


La serie de afiliados activos del programa de control de hipertensión presenta una tendencia creciente a lo largo del tiempo. El gráfico de rezagos muestra una relación lineal positiva entre las observaciones presentes (y_t) y pasadas (y_{t-6}), lo que confirma una alta autocorrelación y una fuerte dependencia estructural en los datos.

```
g1 <- graficar_serie(datos3, titulo = "Consultas semanales por enfermedad respiratoria")
g2 <- grafico_rezagos(datos = datos3, k = 6)
g1 / g2
```



Número de observaciones: 240



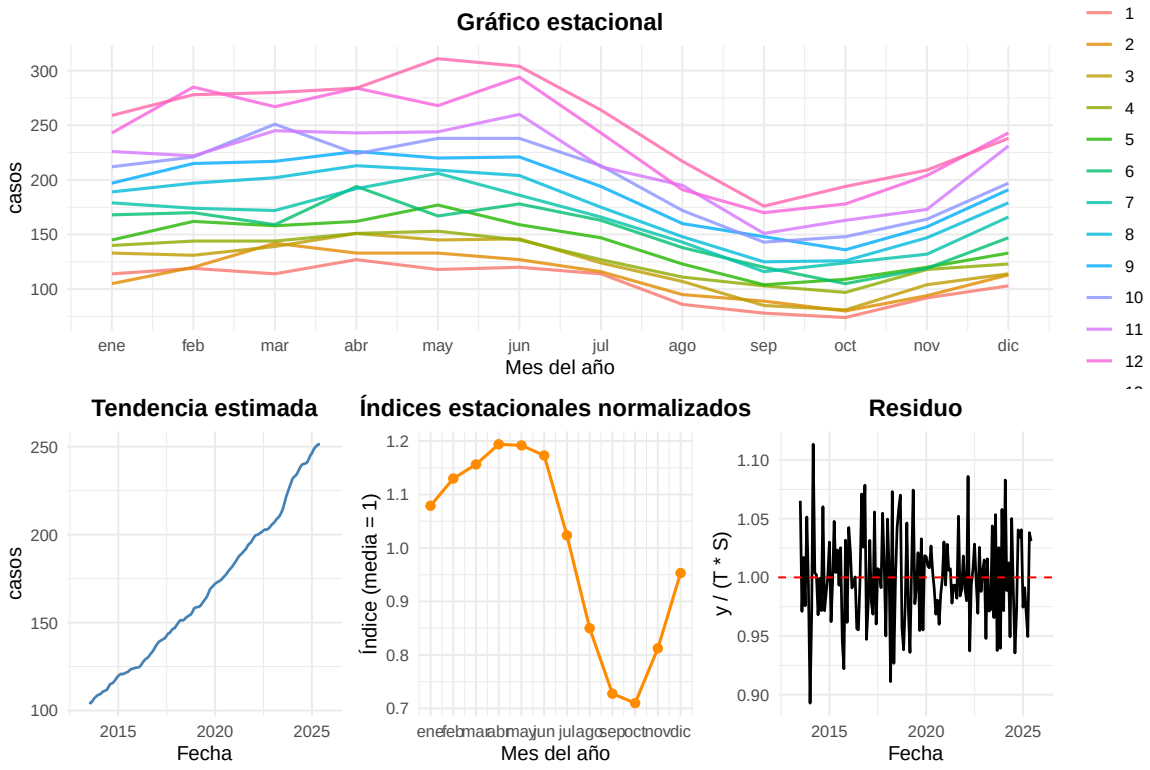
La serie de consultas semanales por enfermedad respiratoria no parece presentar ni tendencia ni estacionalidad. El gráfico de rezagos no muestra una relación lineal entre las observaciones presentes (y_t) y pasadas (y_{t-6}), por lo que no parece haber una fuerte dependencia estructural en los datos.

(b) Para cada serie, la decisión argumentada sobre si tiene estacionalidad y, si la tiene, cuál es su período. Toda serie a la cual el equipo le atribuya estacionalidad lleva el gráfico estacional, con un trazo por ciclo sobre el índice de estación, y una descomposición clásica programada a mano con una media móvil centrada, en la versión aditiva o multiplicativa, cuya elección se justifica con evidencia gráfica y numérica; se muestran la tendencia estimada, los índices estacionales normalizados y el residuo. Toda serie a la cual no se le atribuya estacionalidad lleva la evidencia que lo sostiene.

Como se vió en el punto anterior, la única serie que parece tener estacionalidad es la 1, con período $s = 12$, pues hay un solo ciclo por año, se nota un solo pico y un solo valle por año. Además, la amplitud estacional crece con el nivel general, por lo que se elige una descomposición

multiplicativa: $y_t = T_t \times S_t \times R_t$. La media móvil centrada suaviza la tendencia y, al sacar la tendencia, los índices estacionales normalizados muestran que los meses de marzo a junio son sistemáticamente superiores a la media anual, mientras que septiembre y octubre son los más bajos. El residuo se mantiene alrededor de cero sin un patrón anual claro, lo que refuerza la decisión de atribuir estacionalidad a la serie 1.

```
grafico_estacional(datos = datos1, s = 12, tipo = "multiplicativo")
```

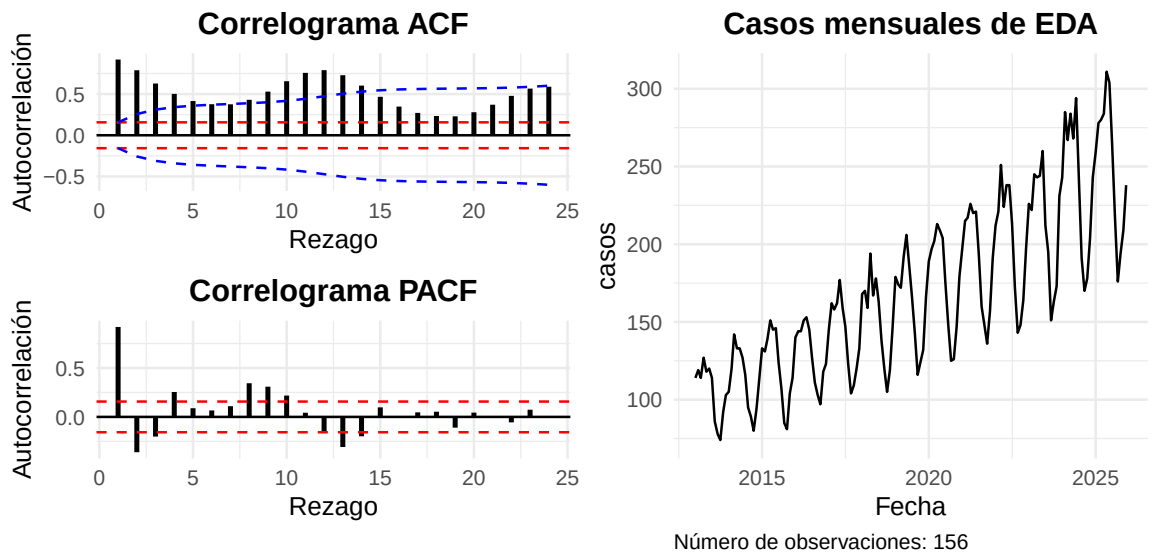


En la descomposición, la tendencia estimada es creciente a lo largo del periodo, los índices estacionales normalizados tienen valores alrededor de 1 y capturan la estructura anual del brote diarreico, y el residuo no presenta un patrón sistemático restante. Por tanto, la serie 1 se clasifica como una serie con tendencia creciente y estacionalidad anual de tipo multiplicativo.

(c) Para cada serie, la clasificación de su patrón, apoyada en el gráfico y en el correlograma de la serie sin transformar con $m = mn\lfloor T/4 \rfloor, 24$ rezagos, con la lectura de la forma de ese correlograma.

- Para la serie 1:

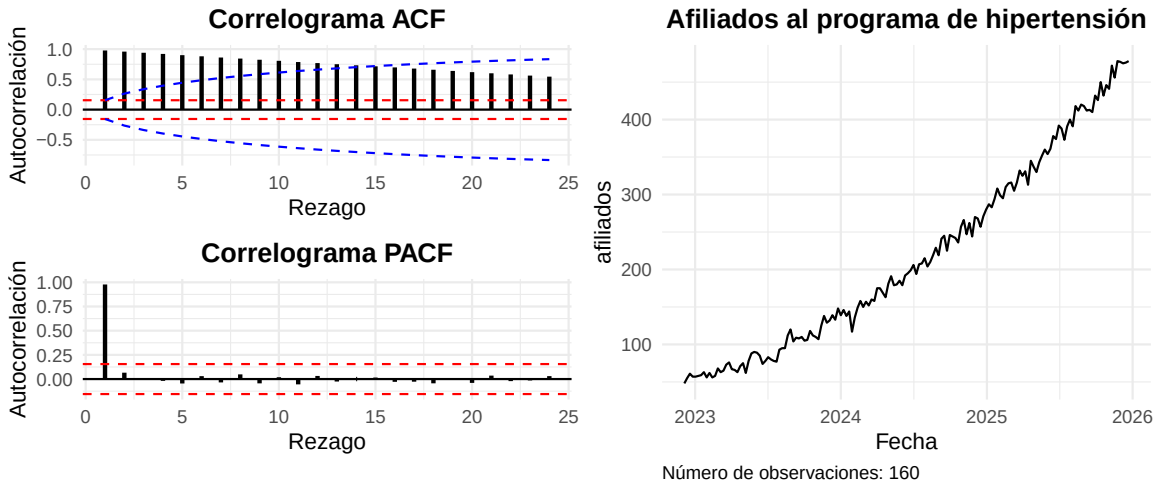
```
m <- min(length(datos1$y), 24)
a <- correlograma(datos1, m)
b <- graficar_serie(datos1, titulo = "Casos mensuales de EDA")
a | b
```



En los primeros rezagos, el correlograma tiene autocorrelaciones altamente significativas, las cuales van disminuyendo lentamente a medida que el rezago crece, esto indica tendencia. Por otro lado, sobre el comportamiento descrito se notan picos cuando el rezago es multiplo de 12 (serie mensual), por lo que la serie parece tener estacionalidad. Estas características son aún más claras en la serie.

- Para la serie 2:

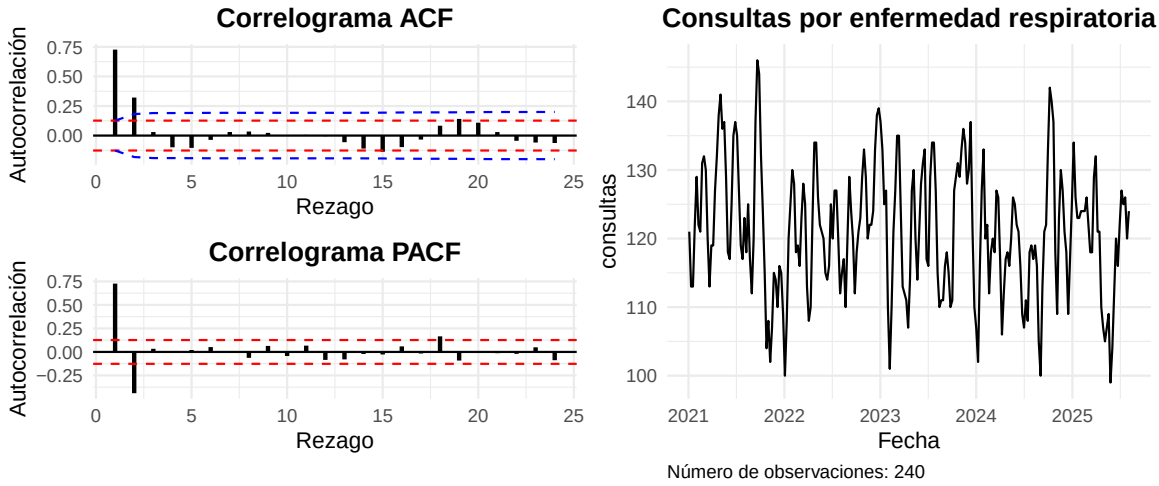
```
m <- min(length(datos2$y), 24)
a <- correlograma(datos2, m)
b <- graficar_serie(datos2, titulo = "Afiliados al programa de hipertensión")
a | b
```



El comportamiento de decaimiento lento en el correlograma es evidencia clara de que la serie sin transformaciones tiene tendencia. Con base en el gráfico de la serie se recalca lo ya dicho y se observa que la tendencia es de crecimiento.

- Para la serie 3:

```
m <- min(length(datos3$y), 24)
a <- correlograma(datos3, m)
b <- graficar_serie(datos3, titulo = "Consultas por enfermedad respiratoria")
a | b
```



Para este caso no se logran identificar patrones de estacionalidad o tendencia de la serie relacionada a las consultas por enfermedades respiratorias. No parece haber una estructura

visible clara ni muchos rezagos que superen la banda. Aunque si se nota un nivel constante, pues en el gráfico de la serie se nota que se oscila siempre sobre 120 aproximadamente.

Operador de rezago

(a) Escriba `diferenciar(y, d, D, s)`, que aplica $(1-B)^d(1-B^s)^D$ sin usar `diff()`, y `polinomio_rezago(coef)`, que recibe los coeficientes de $c(B) = 1 + c_1B + \cdots + c_pB^p$ y devuelve sus raíces con su módulo. Verifique `diferenciar()` contra `diff()` en un bloque de verificación.

```
# Código de verificación de diferenciar() vs. diff()
set.seed(67)
y_prueba <- rnorm(15)

d_prueba <- 1
D_prueba <- 1
s_prueba <- 12

res_manual <- diferenciar(y_prueba, d = d_prueba, D = D_prueba, s = s_prueba)

res_diff <- diff(y_prueba, lag = s_prueba, differences = D_prueba)
res_diff <- diff(res_diff, lag = 1, differences = d_prueba)
print("diferenciar vs. diff")
```

```
[1] "diferenciar vs. diff"
```

```
print(res_manual);print(res_diff)
```

```
[1] 0.02991735 1.71525811
```

```
[1] 0.02991735 1.71525811
```

```
print("c(B) = 1 - 2B + 3B^2")
```

```
[1] "c(B) = 1 - 2B + 3B^2"
```

```
print("Raíces y módulos del polinomio de prueba:")
```

```
[1] "Raíces y módulos del polinomio de prueba:"
```

```
print(polinomio_rezago(c(-2, 3)))
```

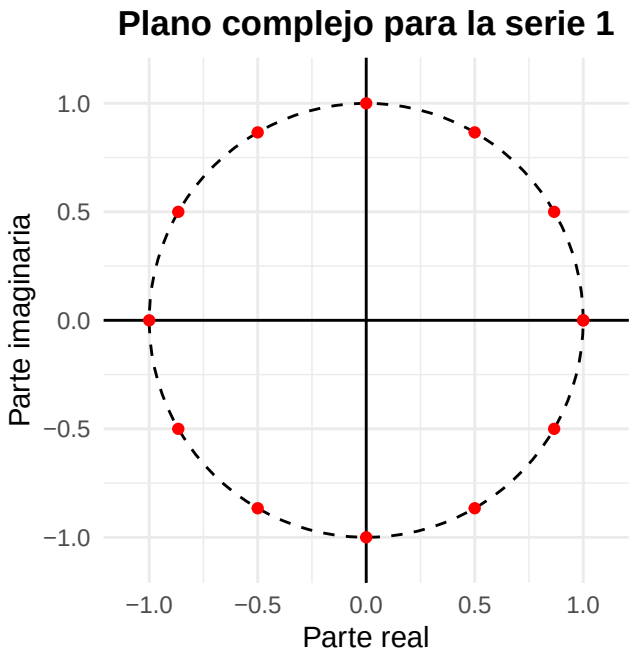
```
                  Raiz    Modulo
1 0.3333333+0.4714045i 0.5773503
2 0.3333333-0.4714045i 0.5773503
```

(b) Para cada serie, proponga las transformaciones candidatas que su diagnóstico sugiere, incluidas las transformaciones previas de escala si las hay, y escriba cada una como polinomio en B. Calcule las raíces de cada polinomio con `polinomio_rezago()`, ubíquelas en el plano complejo y explique qué componente determinista elimina cada factor.

- Serie 1: Ya vimos que esta serie tiene tendencia y estacionalidad con período 12, por lo que se aplica una diferencia para quitar la tendencia y una estacional para la estacionalidad. Además, esta serie tiene comportamiento multiplicativo, pues a medida que pasa el tiempo la amplitud de las variaciones estacionales crece, debido a esto lo ideal es aplicar una transformación a los datos, un logaritmo natural. Se tendría entonces,

$$\nabla_1 \nabla_{12} \ln(y_t) = (1-B)(1-B^{12}) = 1 - B^{12} - B + B^{13} = 1 - B - B^{12} + B^{13}$$

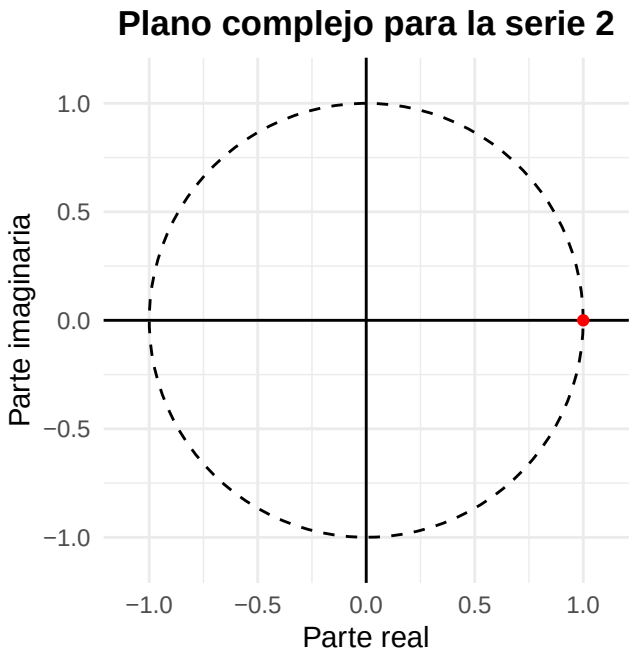
```
datos1$log <- log(datos1$y)
coefs_1 <- c(-1, rep(0, 10), -1, 1)
raices_1 <- polinomio_rezago(coefs_1)
df1 <- data.frame(Parte_Real = Re(raices_1$Raiz),
                  Parte_imaginaria = Im(raices_1$Raiz))
ggplot(df1, aes(x = Parte_Real, y = Parte_imaginaria)) +
  annotate("path", x = cos(seq(0, 2*pi, length.out = 100)),
           y = sin(seq(0, 2*pi, length.out = 100)), linetype = "dashed") +
  geom_hline(yintercept = 0) +
  geom_vline(xintercept = 0) +
  geom_point(color = "red") +
  labs(title = "Plano complejo para la serie 1", x = "Parte real",
       y = "Parte imaginaria") +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5)) +
  coord_fixed(ratio = 1, xlim = c(-1.1, 1.1), ylim = c(-1.1, 1.1))
```



- Serie 2: Esta serie cuanta con tendencia, por lo que es suficiente aplicar una diferencia para eliminarla:

$$\nabla_1 = (1 - B)$$

```
coefs_2 <- c(-1)
raices_2 <- polinomio_rezago(coefs_2)
df2 <- data.frame(Parte_Real = Re(raices_2$Raiz),
                  Parte_imaginaria = Im(raices_2$Raiz))
ggplot(df2, aes(x = Parte_Real, y = Parte_imaginaria)) +
  annotate("path", x = cos(seq(0, 2*pi, length.out = 100)),
           y = sin(seq(0, 2*pi, length.out = 100)), linetype = "dashed") +
  geom_hline(yintercept = 0) +
  geom_vline(xintercept = 0) +
  geom_point(color = "red") +
  labs(title = "Plano complejo para la serie 2", x = "Parte real",
       y = "Parte imaginaria") +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5)) +
  coord_fixed(ratio = 1, xlim = c(-1.1, 1.1), ylim = c(-1.1, 1.1))
```



- Serie 3: No es necesario aplicar transformaciones, pues no se presentó ni estacionalidad ni tendencia. El polinomio sería igual a 1, por tanto no tiene sentido hacer la gráfica ya que no habría puntos.

(c) Para cada serie, una tabla con la varianza muestral y r_1 de la serie y de cada transformación candidata. Elija la transformación con la cual la serie resultante es plausiblemente estacionaria, que puede ser ninguna, y defienda que no aplica diferencias de más, con la identidad $Var(\nabla Y_t) = 2\gamma(0) - 2\gamma(1)$ y con lo que le ocurre a r_1 cuando se diferencia una serie que ya era estacionaria. Verifique sobre los datos que la media de la serie transformada coincide con lo que la transformación debe dejar.

- Serie 1:

```
resumen_serie <- function(x){
  x <- na.omit(x)
  n <- length(x)
  if (n < 2) return(c(media=NA, varianza=NA, r1=NA))
  media <- mean(x)
  varianza <- var(x) * (n-1)/n
  r1 <- cor(x[-1], x[-n])
  return(c(media = media, varianza = varianza, r1 = r1))
}
```

```r
datos1$logy <- log(datos1$y)
datos1$dif1_logy <- c(NA, diferenciar(datos1$logy, d = 1, D = 0, s = 12))
datos1$dif12_logy <- c(rep(NA, 12), diferenciar(datos1$logy, d = 0, D = 1, s = 12))
datos1$dif_est_logy <- c(rep(NA, 13), diferenciar(datos1$logy, d = 1, D = 1, s = 12))

datos2$dif_y <- c(NA, diferenciar(datos2$y, d = 1, D = 0, s = 1))
datos3$dif_y <- c(NA, diferenciar(datos3$y, d = 1, D = 0, s = 1))
```

Por el inciso anterior se sabe que para la serie 1 la transformacion que se aplica es una diferencia para quitar la tendencia y una estacional para la estacionalidad, sin embargo vamos a ilustrar una tabla con cuatro escenarios, es decir, serie original comparada ante las transformaciones para esta serie, con el fin de ver el paso a paso:

```r
s1_ori   <- resumen_serie(datos1$y)
s1_log   <- resumen_serie(datos1$logy)
s1_d1    <- resumen_serie(datos1$dif1_logy)
s1_d12 <- resumen_serie(datos1$dif12_logy)
s1_d1d12 <- resumen_serie(datos1$dif_est_logy)
t1 <- data.frame(
  row.names = c("Original", "Logaritmo", "Log + Dif(1)", "Log + Dif(12)", "Log + Dif(1) + Di
  media = c(s1_ori["media"], s1_log["media"], s1_d1["media"], s1_d12["media"],  s1_d1d12["me
  varianza  = c(s1_ori["varianza"],s1_log["varianza"],s1_d1["varianza"],s1_d12["varianza"],s
  r1 = c(s1_ori["r1"], s1_log["r1"], s1_d1["r1"], s1_d12["r1"], s1_d1d12["r1"]))

round(t1, 4)
```

```
                          media  varianza      r1
Original                169.0449 2970.1711  0.9271
Logaritmo                 5.0779    0.1062  0.9269
Log + Dif(1)              0.0047    0.0155  0.4181
Log + Dif(12)             0.0727    0.0037 -0.0678
Log + Dif(1) + Dif(12)    0.0004    0.0077 -0.5580
```

La diferencia estacional del logaritmo tiene r_1 cercano a cero y varianza muestral aproximada de 0.00370. Al agregar la diferencia ordinaria, la varianza sube a aproximadamente 0.00771 y r_1 cae a aproximadamente -0.558. Esta combinación de aumento de varianza y autocorrelación negativa marcada es una señal de que la diferencia ordinaria adicional puede estar sobrando. Por tanto, con la evidencia disponible, la elección preferible es $\nabla_{12} \log(Y_t)$

$$\hat{\gamma}(1) = r_1 \times \hat{\gamma}(0) = (-0.0678 \times 0.0037) = -0.0002509$$
$$2\hat{\gamma}(0) - 2\hat{\gamma}(1) \approx 2(0.0037) - 2(-0.0002509) \approx 0.007902$$

La varianza muestral observada de la diferencia ordinaria adicional es aproximadamente 0.0077, cercana a ese valor teórico aproximado. Esto indica que una diferencia más duplica la varianza muestral de la serie 1, no aportando evidencia a favor de usarla.

La media resultante es aproximadamente (0.0727), se interpreta como el incremento logarítmico anual promedio, no como una media que la transformación deba forzar a cero. En la escala original equivale a un crecimiento anual promedio aproximado de 7.5 %.

```
n <- length(datos1$logy)
(sum(tail(datos1$logy, 12)) - sum(head(datos1$logy, 12))) / (n - 12)
```

```
[1] 0.07272296
```

- Serie 2:

```
s2_ori  <- resumen_serie(datos2$y)
s2_d1   <- resumen_serie(datos2$dif_y)

t2 <- data.frame(
  row.names = c("Original", "Dif(1)"),
  media     = c(s2_ori["media"],  s2_d1["media"]),
  varianza  = c(s2_ori["varianza"],s2_d1["varianza"]),
  r1        = c(s2_ori["r1"],      s2_d1["r1"]))
round(t2, 4)
```

```
            media   varianza      r1
Original 218.1625 16332.6861  0.9964
Dif(1)     2.7044   117.3151 -0.4455
```

La serie original presenta $r_1 = 0.9964$, lo que evidencia una tendencia determinista fuerte y confirma que no es estacionaria. La varianza elevada (tendencia hace que los valores se alejen de la media) y la media no estable refuerzan la necesidad de transformación. La gran reducción de varianza (de 16332 a 118) prueba que la primera diferencia era necesaria para extraer la señal de la tendencia. Una segunda diferencia no tendría tendencia que eliminar y solo introduciría ruido. En cuanto a la media, este valor no es cero, sino que representa el crecimiento promedio semanal de los afiliados, lo cual es exactamente lo que debe dejar una primera diferencia cuando la serie original crece de forma constante.

PASO 1: calcular para la serie original

$$\begin{aligned}\gamma(1) &= 0.9964 \times 16332.6861 = 16273.89 \\ \text{Var}(\nabla Y_t)_{\text{teórica}} &= 2(16332.6861) - 2(16273.89) \\ &= 32665.37 - 32547.78 = \mathbf{117.59}\end{aligned}$$

Se observa que la varianza cae drásticamente, por lo que se confirma que la primera diferencia remueve la tendencia.

PASO 2: calcular sobre la serie ya diferenciada(dif1)

$$\begin{aligned}\gamma(0) &= 117.3151, \quad r_1 = -0.4455 \\ \gamma(1) &= -0.4455 \times 117.3151 = -52.26 \\ \text{Var}(\nabla^2 Y_t)_{\text{teórica}} &= 2(117.3151) - 2(-52.26) \\ &= 234.63 + 104.52 = \mathbf{339.15}\end{aligned}$$

Se observa que la varianza subiría de 117.32 a 339.15 claramente aumenta, lo cual es una señal de sobrediferenciación. Así que se para en este punto.

La media no se espera que sea cero, porque la serie crece de forma casi constante. Lo que deja una primera diferencia es la pendiente promedio y la verificación confirma que ese número sale solo de los extremos de la serie.

```
y <- datos2$y
n <- length(y)

media_dif <- mean(datos2$dif_y, na.rm = TRUE)
media_teor<- (y[n] - y[1]) / (n - 1)

c(observada = media_dif, teorica = media_teor)
```

```
observada   teorica
 2.704403  2.704403
```

- Serie 3:

Ahora para la serie 3 vamos a calcular la tabla suponiendo que SI se aplicara una sola diferencia solo para hacer una comparacion y defender que no se usan diferencias en este caso.

```r
s3_ori <- resumen_serie(datos3$y)
s3_d1 <- resumen_serie(datos3$dif_y)

t3 <- data.frame(
  row.names = c("Original", "Dif(1)"),
  media     = c(s3_ori["media"],  s3_d1["media"]),
  varianza  = c(s3_ori["varianza"],s3_d1["varianza"]),
  r1        = c(s3_ori["r1"],      s3_d1["r1"]))

round(t3, 4)
```

```
            media varianza     r1
Original 121.1417  86.6299 0.7271
Dif(1)     0.0126  47.4768 0.2445
```

La varianza baja al diferenciar, pero eso no es evidencia a favor de diferenciar. Por la identidad, la varianza disminuye siempre que r > 0.5, y aquí r $= 0.7271$. La identidad se cumple: $2\gamma(0) - 2\gamma(1) = 2 * 86.63 - 2 * (0.7271 * 86.63) = 47.28 \approx (\nabla Y_t)$,pero es un chequeo algebraico, no una prueba de estacionariedad. En esta serie el criterio de varianza no sirve para detectar sobrediferenciación, así que la decisión se apoya en el diagnóstico: no hay tendencia ni estacionalidad en el gráfico, el nivel oscila alrededor de 121 y la ACF cae rápido tras el rezago 2. No hay ninguna componente determinista que una diferencia deba eliminar. Diferenciar solo destruiría el nivel, pues la media pasa de 121.14 a 0.0126, y el r de 0.7271 a 0.2445.

Su media ($\bar{x} = 121.1417$) representa el nivel promedio estable de consultas respiratorias. Si se aplicara diferencia, la media pasaría a ser 0, perdiendo toda interpretación del nivel.

```r
y <- datos3$y
n <- length(y)
c(media_dif = mean(diferenciar(y, 1, 0, 1)),
  teorica_dif = (y[n] - y[1]) / (n - 1))
```

```
  media_dif teorica_dif
  0.0125523   0.0125523
```

(d) A mano, en el informe. Pruebe que la función de pronóstico de Holt, $\hat{Y}_{T+h} = L_T + \hat{T}_T h$, satisface $(1-B)^2 \hat{Y}_{T+h} = 0$ para $h \geq 3$, y que la de Holt–Winters aditivo con período s, $\hat{Y}_{T+h} = L_T + \hat{T}_T h + S_{T+h-s\lceil h/s \rceil}$, satisface $(1 - B)(1 - B^s)\hat{Y}_{T+h} = 0$ para $h \geq s + 2$, con el operador actuando sobre h. Escriba la solución general de cada ecuación en diferencias y diga qué raíces del polinomio característico corresponden a la tendencia y cuáles a la estacionalidad.

- Demostración de que $\hat{Y}_{T+h} = L_T + \hat{T}_T h$ satisface $(1-B)^2\hat{Y}_{T+h} = 0$ para $h \geq 3$:

$$\begin{aligned}(1-B)^2\hat{Y}_{T+h} &= (1-2B+B^2)\hat{Y}_{T+h}\\ &= \hat{Y}_{T+h} - 2B\hat{Y}_{T+h} + B^2\hat{Y}_{T+h}\\ &= \hat{Y}_{T+h} - 2\hat{Y}_{T+h-1} + \hat{Y}_{T+h-2}\\ &= L_T + \hat{T}_T h - 2[L_T + \hat{T}_T(h-1)] + L_T + \hat{T}_T(h-2)\\ &= L_T + \hat{T}_T h - 2L_T - 2\hat{T}_T h + 2\hat{T}_T + L_T + \hat{T}_T h - 2\hat{T}_T\\ &= (2L_T - 2L_T) + (2\hat{T}_T h - 2\hat{T}_T h) + (2\hat{T} - 2\hat{T})\\ &= 0\end{aligned}$$

- Demostración de que $\hat{Y}_{T+h} = L_T + \hat{T}_T h + S_{T+h-s\lceil h/s\rceil}$, satisface $(1-B)(1-B^s)\hat{Y}_{T+h} = 0$ para $h \geq s+2$:

$$\begin{aligned}(1-B^s)\hat{Y}_{T+h} &= \hat{Y}_{T+h} - \hat{Y}_{T+h-s}\\ &= L_T + \hat{T}_T h + S_{T+h-s\lceil h/s\rceil} - L_T - \hat{T}_T(h-s) - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T h - \hat{T}_T h + \hat{T}_T s + S_{T+h-s\lceil h/s\rceil}\\ &\quad - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T s + S_{T+h-s\lceil h/s\rceil} - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T s + S_{T+h-s\lceil h/s\rceil} - S_{T+h-s\lceil h/s\rceil}\\ &= \hat{T}_T s\end{aligned}$$

$$\begin{aligned}(1-B)(1-B^s)\hat{Y}_{T+h} &= (1-B)(\hat{T}_T s)\\ &= \hat{T}_T s - \hat{T}_T s \ (No\ depende\ de\ h)\\ &= 0\end{aligned}$$

Se tiene que $h \geq s+2$, pues asegura que el menor valor posible para $h-s-1$ sea 1, un horizonte menor a 1 no tiene sentido.

Para Holt $(1-B)^2 = 0$ la raíz es $B = 1$ con multiplicidad 2. La solución general para una raíz como esta está dada por:

$\hat{Y}_{T+h} = c_1 + c_2 h$

Para Holt-Winters $(1-B)(1-B^s) = 0$ el factor $(1-B)$ aporta una raíz $B = 1$ y el factor $(1-B^s)$ aporta s raíces de la forma $B = e^{i2\pi k/s},\ k = 0, 1, 2, ..., s-1$. Hay $s+1$ raíces, con solución general:

$\hat{Y}_{T+h} = c_1 + c_2 h + \sum_{k=1}^{\lfloor s/2\rfloor} \alpha_k cos(\frac{2\pi kh}{s}) + \beta_k sin(\frac{2\pi kh}{s})$ La raíz $B = 1$ corresponde a la tendencia de la serie, mientras que las raíces $B = e^{i2\pi k/s}$ se refieren a la estacionalidad de período s.

Dependencia y estacionariedad

(a) Escriba `pacf_dl(r)`, la autocorrelación parcial muestral por la recursión de Durbin y Levinson a partir de $r_1, ..., r_m$, y verifíquela contra `pacf()` con máxima diferencia absoluta menor que 10^{-10}. Para cada serie presente ACF y PACF muestrales hasta el rezago m, con la banda de ruido blanco $\pm 1,96/\sqrt{n}$ y la banda de Bartlett $\pm 1,96\sqrt{(1+2\sum_{i<h} r_i^2)/n}$, y diga cuál de las dos corresponde a cada pregunta que se le hace al correlograma.

Para comparar `pacf()` contra `pacf_dl(r)` se usa los datos de la serie 1 transformada (logaritmo y diferencia estacional) con 24 rezagos :

```
a <- na.omit(datos1$dif12_logy)
acfs <- acf_muestral(a, m = 24)
pacf_dl_ <- pacf_dl(r = acfs)
pacf_R <- pacf(a, lag.max = 24, plot = FALSE)$acf[, 1, 1]

max_dif <- max(abs(pacf_dl_ - pacf_R))
print(paste("Máxima diferencia absoluta: ", max_dif))
```

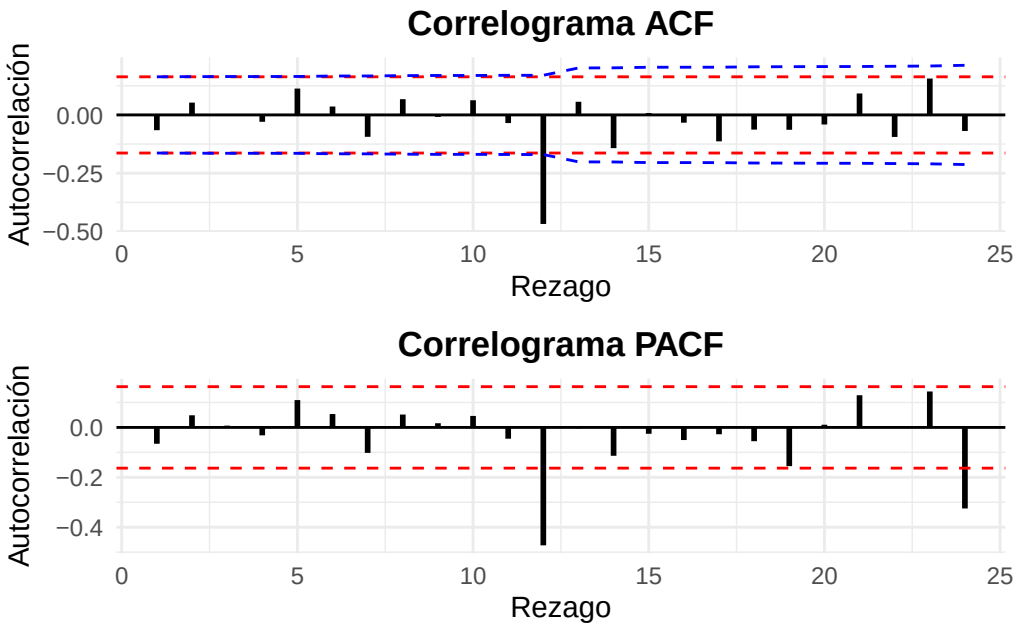
```
[1] "Máxima diferencia absoluta:  8.32667268468867e-16"
```

A continuación se presentan ACF y PACF muestrales para cada una de las series. Para esto se crea una nueva función, `correlograma_muestral(y, m)`, que usa las autocorrelaciones parciales determinadas con `pacf_dl(r)` en lugar de la función base de R `pacf()` como lo hace `correlograma()`. Esta función se creó en el archivo `informe.qmd`, sin embargo, se decidió no mostrarlo en el archivo pdf debido al tamaño extendido del código.

La banda de ruido blanco (roja) responde a ¿La serie es ruido blanco puro? Mientras que la banda de Bartlett responde a ¿El rezago h aporta algo significativo dado que los anteriores son reales?

- Para la serie 1:

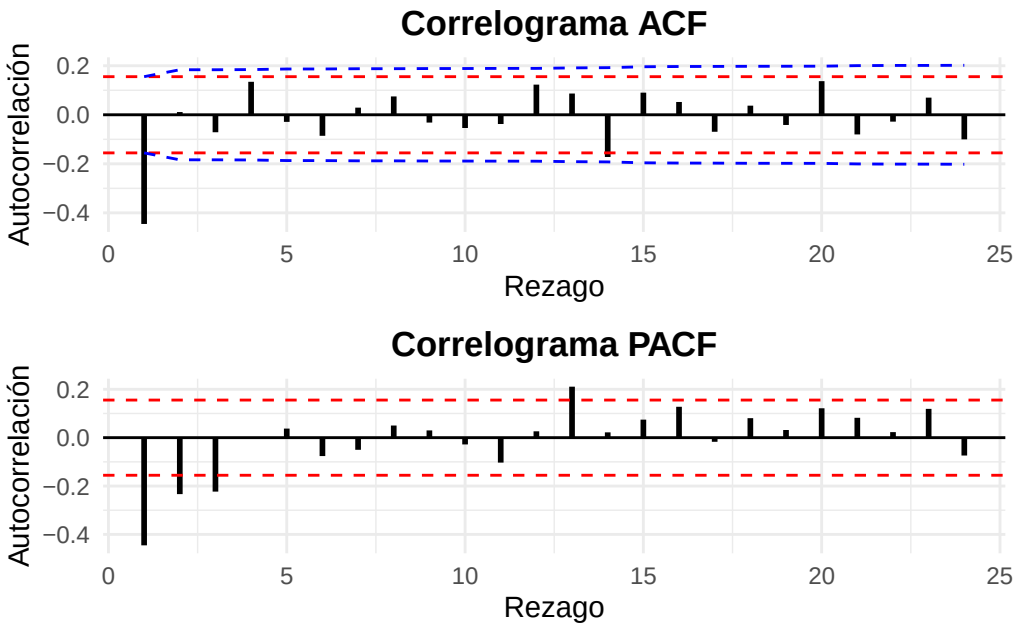
```
correlograma_muestral(y = datos1$dif12_logy, m = 24)
```



A partir del correlograma se nota que la ACF muestral es compatible con ruido blanco en todos los rezagos salvo el 12, donde supera tanto la banda de ruido blanco como la de Bartlett. La PACF presenta picos negativos en los rezagos 12 y 24 que decaen. Esa forma (ACF que se corta tras el rezago estacional y PACF que decae en múltiplos de 12) es la de una media móvil estacional de orden 1. No quedan tendencia ni dependencia de corto plazo relevante: los rezagos 1 a 11 están dentro de las bandas.

- Para la serie 2:

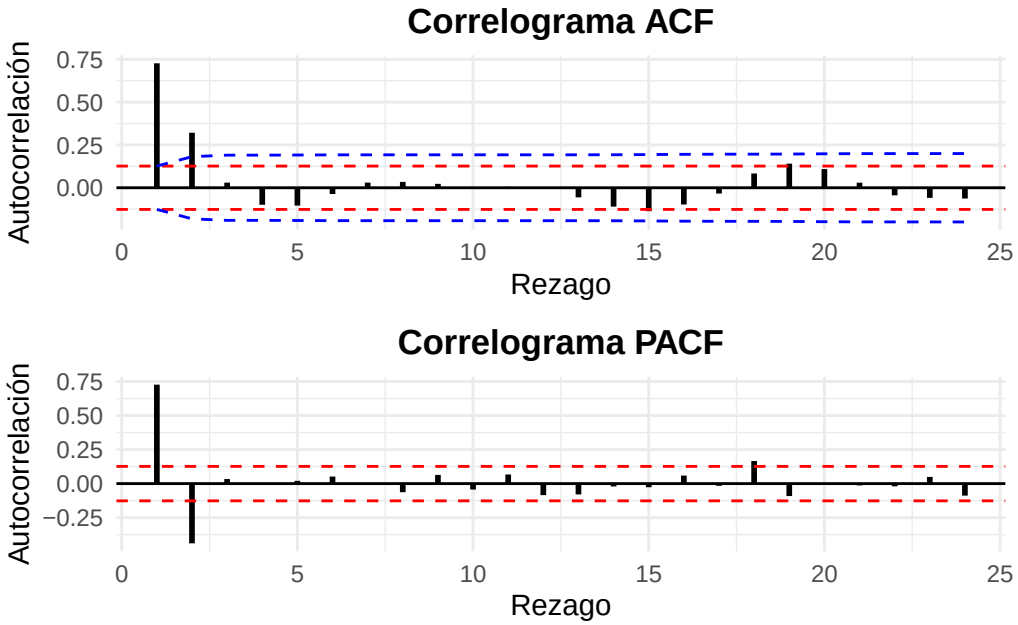
```
correlograma_muestral(y = datos2$dif_y, m = 24)
```



La ACF muestral se corta después del rezago 1 y los demás rezagos están dentro de las bandas, excepto el rezago 14. La PACF decae con signo negativo (en los rezagos 1 a 3). Esa forma es la de una media móvil de orden 1, MA(1), con coeficiente negativo. No hay picos en múltiplos de ningún período, así que no se observa estacionalidad.

- Para la serie 3:

```
correlograma_muestral(y = datos3$y, m = 24)
```



En cuanto a la banda de ruido blanco, se puede observar que los rezagos 1 y 2 tienen autocorrelaciones significativas, por lo que sí parece haber estructura temporal. Los rezagos 1 y 2 se salen de la banda de Bartlett, pero a partir del rezago 3, las autocorrelaciones caen y se mantienen dentro de esta banda, esto es evidencia de que la memoria de la serie se apaga rápidamente y se corta después del segundo periodo.

(b) Para cada serie, la prueba de Ljung–Box con sus seis elementos, con m elegido y justificado, y la lectura de la forma de la ACF y de la PACF. Diga con qué proceso de los estudiados en clase es compatible esa forma y con cuáles no, y por qué.

Los seis elementos de la prueba de Ljung-Box para las tres series son:

1. Hipotesis nula y alternativa:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_{24} = 0 \quad : \text{la serie es ruido blanco.}$$
$$H_a : \exists k \in \{1, 2, \ldots, 24\} \quad \text{tal que } \rho_k \neq 0 \quad : \text{existe dependencia serial.}$$

2. Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$Q = n(n+2) \sum_{k=1}^{m} \frac{r_k^2}{n-k}$$

Donde: - n es el número de observaciones, - r_k es la autocorrelación muestral al rezago k, - m es el número de rezagos evaluados.

Bajo H_0, el estadístico Q sigue una distribución:

$$Q \xrightarrow{d} \chi^2_{(m)}$$

3. Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

4. Valor observado del estadístico y valor p

- Q_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

5. Decision

Se compara Q_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $Q_{\text{obs}} > \chi^2_{m,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, no se rechaza H_0.

6. Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de dependencia del fenómeno:

- Si se rechaza H_0, existe dependencia serial, la serie no es ruido blanco, presenta estructura temporal compatible con procesos autorregresivos, de media móvil o mixtos ARMA.
- Si no se rechaza H_0, no hay evidencia de dependencia serial, la serie se comporta como ruido blanco, no hay patrón temporal predecible.

Serie 1: Casos mensuales de EDA (transformada):

$$w_t = (1 - B^{12}) \ln(y_t)$$

- PASO 1: elección de m

Se toma $m = 24$ rezagos, justificado por:

- Regla del trabajo: $m = \text{mín}\left(\left\lfloor \frac{T}{4} \right\rfloor, 24\right) = \text{mín}(36,\, 24) = 24$.
- La serie tiene período estacional $s = 12$; revisar dos ciclos completos permite detectar estructura de dependencia estacional remanente.

- PASO 2: aplicar la prueba

```
z <- as.numeric(na.omit(datos1$dif12_logy))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 56.73398

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 0.0001819201
```

Se rechaza H_0 por tanto hay evidencia estadistica para sugerir que aunque se eliminó la tendencia y la estacionalidad anual, persiste estructura de dependencia remanente: las autocorrelaciones conjuntas no son nulas. El patrón sugiere que la serie transformada aún guarda memoria, por lo que un modelo autorregresivo estacional podría capturar esa dependencia y mejorar el pronóstico respecto a métodos más simples. Los valores de casos en meses anteriores siguen informando sobre los casos futuros, más allá del comportamiento anual y el crecimiento general.

Como se vió en el punto anterior el comportamiento presentado en los correlogramas es la de un proceso de Media Móvil Estacional de orden 1 ($SMA(1)$). No es compatible ruido una media móvil $MA(q)$ (la ACF sería distinta de cero en los rezagos 1 a q, no solo en el 12) y un $AR(p)$ (la PACF tiene picos en 12 y 24, no se corta).

Serie 2: Afiliados activos al programa de hipertensión (transformada):

$$w_t = (1 - B)y_t$$

- PASO 1: elección de m

$m = \text{mín}\left(\frac{159}{4}, 24\right) = 24$. Suficiente para capturar dependencia semanal sin exceder un cuarto de la muestra.

- PASO 2: aplicar la prueba

```r
z <- as.numeric(na.omit(datos2$dif_y))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 59.52425

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 7.453714e-05
```

Como podemos observar se rechaza H_0 por tanto hay evidencia estadistica para sugerir que la diferencia eliminó el crecimiento, pero no convirtió la serie en ruido blanco: subsiste dependencia serial significativa (relacionado con los valores anteriores), concentrada principalmente en los primeros rezagos. Esto significa que el número de afiliados de semanas anteriores sigue siendo un buen predictor del número de afiliados de la semana siguiente. Un modelo autorregresivo de orden bajo puede aprovechar esa inercia para afinar la estimación de la demanda de medicamento.

Con el gráfico expuesto en el punto anterior de la serie 2 se mencionó que un proceso compatible es una media móvil de orden 1. Un proceso incompatible es uno con proceso autorregresivo ($AR(p)$). En un autorregresivo, la PACF se cortaría y la ACF mostraría un decaimiento gradual.

Serie 3: Consultas por enfermedad respiratoria (sin transformación):

$$w_t = y_t$$

PASO 1: elección de m

Se toma $m = 24$ rezagos, justificado por:

- $T = 240$, $m = \text{mín}\left(\frac{240}{4}, 24\right) = \text{mín}(60, 24) = 24$. Cubre casi que medio año de observaciones semanales.
- Suficiente para capturar dependencia semanal sin exceder un cuarto de la muestra.

PASO 2: aplicar la prueba

```r
z <- as.numeric(na.omit(datos3$y))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 184.3596

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 1.074328e-26
```

Se rechaza H_0, esto confirma que existe dependencia serial conjunta, concentrada en los primeros dos rezagos: las consultas de una semana influyen en las de la siguiente. La estructura es de memoria corta: la influencia se apaga rápidamente, por lo que el pronóstico a corto plazo puede mejorarse aprovechando la semana inmediatamente anterior, pero la previsión a más largo plazo se aproxima a la media. No se requieren transformaciones, pero sí un modelo que recoja la dependencia de corto plazo.

La serie presenta memoria corta; la ACF muestra autocorrelaciones significativas en los rezagos 1 y 2 que salen de la banda de Bartlett, y a partir del rezago 3 se corta y se mantiene dentro de las bandas, por lo que al cortarse la ACF después del segundo periodo, el patrón es compatible con un proceso de media móvil de orden 2. No es compatible con procesos de memoria larga o de tendencia (como curvas de crecimiento deterministas o caminatas aleatorias), debido a que carece de un decaimiento lento en la ACF.

(c) Estacionariedad y ergodicidad. Para cada serie, divida la serie transformada en cuatro bloques consecutivos y compare media y varianza por bloque. Estime su media con dos errores estándar: el ingenuo $\sigma/\sqrt{n}$ y el que usa la varianza de largo plazo con núcleo de Bartlett, escrito en `varianza_largo_plazo(y, L)` con $L = \lfloor 4(n/100)^{2/9} \rfloor$. Construya los dos intervalos al 95 %, explique por qué difieren, diga cuál es el adecuado y diga qué representa esa media en términos de la serie original.

```r
calcular_L <- function(n) {
  floor(4 * (n / 100)^(2/9))
}
w1 <- na.omit(datos1$dif12_logy)
w2 <- na.omit(datos2$dif_y)
w3 <- na.omit(datos3$y)

n1 <- length(w1)   # Serie 1: EDA transformada
n2 <- length(w2)   # Serie 2: Hipertensión transformada
n3 <- length(w3)   # Serie 3: Respiratoria (sin transformación)

L1 <- calcular_L(n1)
L2 <- calcular_L(n2)
L3 <- calcular_L(n3)


dividir_bloques <- function(y, num_bloques = 4) {

  n <- length(y)
  tam_bloque <- floor(n / num_bloques)
  bloques <- list()
  for (i in 1:num_bloques) {
    desde <- (i - 1) * tam_bloque + 1
    hasta <- min(i * tam_bloque, n)
    bloques[[i]] <- y[desde:hasta]
  }

  return(bloques)
}
```

```r
bloques1 <- dividir_bloques(w1)
bloques2 <- dividir_bloques(w2)
bloques3 <- dividir_bloques(w3)

resumen_bloques <- function(bloques) {
  medias <- sapply(bloques, mean)
  varianzas <- sapply(bloques, var)
  data.frame(
    Bloque = paste0("Bloque ", 1:4),
    Media = round(medias, 5),
    Varianza = round(varianzas, 5))
}
```

```r
rb1 <- resumen_bloques(bloques1)
rb2 <- resumen_bloques(bloques2)
rb3 <- resumen_bloques(bloques3)

vlp1 <- varianza_largo_plazo(w1, L1)
vlp2 <- varianza_largo_plazo(w2, L2)
vlp3 <- varianza_largo_plazo(w3, L3)
```

```r
# Fórmula: media ± 1.96 * sqrt(varianza / n)
intervalo_ingenuo <- function(y) {
  n <- length(y)
  media <- mean(y)
  error_estandar <- sqrt(var(y) / n)

  limite_inferior <- media - 1.96 * error_estandar
  limite_superior <- media + 1.96 * error_estandar

  list(
    media = media,
    error_ingenuo = error_estandar,
    inf = limite_inferior,
    sup = limite_superior)
}


intervalo_largo_plazo <- function(y, L) {
  n <- length(y)
  media <- mean(y)
  vlp <- varianza_largo_plazo(y, L)
  error_ajustado <- sqrt(vlp / n)
  limite_inferior <- media - 1.96 * error_ajustado
  limite_superior <- media + 1.96 * error_ajustado
  list(
    media = media,
    vlp = vlp,
    error_lp = error_ajustado,
    inf = limite_inferior,
    sup = limite_superior)
}

ing1 <- intervalo_ingenuo(w1)   # Ingenuo - Serie 1
```

```
lp1  <- intervalo_largo_plazo(w1, L1)   # Largo plazo - Serie 1

ing2 <- intervalo_ingenuo(w2)   # Ingenuo - Serie 2
lp2  <- intervalo_largo_plazo(w2, L2)   # Largo plazo - Serie 2

ing3 <- intervalo_ingenuo(w3)   # Ingenuo - Serie 3
lp3  <- intervalo_largo_plazo(w3, L3)   # Largo plazo - Serie 3
```

Serie 1 — EDA transformada: $w_t = (1 - B^{12}) \ln(y_t)$

Bloques consecutivos

```
rb1
```

```
    Bloque   Media Varianza
1 Bloque 1 0.07195  0.00509
2 Bloque 2 0.07491  0.00428
3 Bloque 3 0.07055  0.00179
4 Bloque 4 0.07349  0.00396
```

Observamos que las medias por bloque son cercanas a cero y las varianzas no presentan cambios bruscos ni muy diferentes entre sí, por lo cual hay evidencia compatible con estacionariedad tras la transformación o en otras palabras todos los bloques se parecen. La serie se comporta igual desde el inicio hasta el final, es ergódica

Serie 2: Afiliados activos al programa de hipertensión (transformada): $w_t = (1 - B)y_t$

Bloques consecutivos

```
rb2
```

```
    Bloque   Media  Varianza
1 Bloque 1 1.43590  55.98920
2 Bloque 2 1.92308  99.07287
3 Bloque 3 3.51282 136.51957
4 Bloque 4 4.12821 193.58839
```

Las medias son similares en cada bloque, aunque parecen haber diferencias a considerar, sin embargo estas se san debido a que las varianzas crecen de forma marcada y progresiva. Esto nos indica que, aunque la media se estabilizó, la variabilidad aumenta con el tiempo: los cambios en el número de afiliados son más irregulares y de mayor magnitud en los periodos recientes.

La serie es estacionaria en media, pero no en cuanto a la varianza. Pensando en un futuro al modelar, la dependencia de media se puede capturar con un modelo autorregresivo, pero la volatilidad creciente debe tenerse presente al interpretar los intervalos de pronóstico. La media sí es ergódica, aunque la varianza podría no serlo del todo por la inestabilidad. La estimación de la media es confiable, pero la dispersión debe interpretarse con cautela.

Serie 3 — Respiratoria (sin transformación): $w_t = y_t$

Bloques consecutivos

```
rb3
```

```
    Bloque    Media  Varianza
1 Bloque 1 122.2667 110.30056
2 Bloque 2 121.7500  74.90254
3 Bloque 3 121.4167  72.45056
4 Bloque 4 119.1333  88.89718
```

Las medias de los cuatro bloques son bien parecidas entre sí, sin diferencias importantes ni con una clara tendencia a subir o bajar a lo largo de la muestra. Lo mismo podemos ver en cuanto a las varianzas, pues se mantienen en un rango diriamos que estrecho, sin saltos ni tendencia creciente o decreciente pronunciada. Entonces con esto podemos hablar de que la serie es ergodica, la media de consultas que se calculó representa fielmente el nivel estable del fenómeno. Esto da de cuenta que la serie original ya es estacionaria por naturaleza: no presenta tendencia, estacionalidad ni cambios de dispersión, por lo que no requiere de ninguna transformación previa.La estructura de dependencia detectada (memoria corta, solo los primeros rezagos) es la única dinámica que queda por modelar, sin necesidad de diferencias ni ajustes de escala.

Tablas de intervalos de confianza al 95 % - Ingenuo vs Varianza de Largo Plazo

1. Intervalo ingenuo — Fórmula

$$\bar{y} \pm 1.96 \cdot \sqrt{\frac{\hat{\sigma}^2}{n}}$$

2. Intervalo de largo plazo — Fórmula

$$\bar{y} \pm 1.96 \cdot \sqrt{\frac{\text{VLP}}{n}}$$

Donde la Varianza de Largo Plazo (VLP) con núcleo de Bartlett se calcula como:

$$\text{VLP} = \hat{\sigma}^2 \cdot \left[1 + 2 \sum_{k=1}^{L} \left(1 - \frac{k}{L} \right) r_k \right]$$

Ya con esa especificacion vamos con los intervalos de una vez

```
tabla_ic <- function(ing, lp, titulo) {
  tabla <- data.frame(
    `Método` = c(
      "Ingenuo",
      "Varianza Largo plazo"),
    `Error estándar` = c(
      round(ing$error_ingenuo, 5),
      round(lp$error_lp, 5)),
    `Límite inferior` = c(
      round(ing$inf, 5),
      round(lp$inf, 5)),
    `Límite superior` = c(
      round(ing$sup, 5),
      round(lp$sup, 5)),
    check.names = FALSE)

  return(tabla)
}

tabla_ic(ing1, lp1, "Intervalos al 95% - Serie 1 (EDA)")
```

```
                Método Error estándar Límite inferior Límite superior
1              Ingenuo        0.00507         0.06279         0.08266
2 Varianza Largo plazo        0.00492         0.06309         0.08236
```

```
tabla_ic(ing2, lp2, "Intervalos al 95% - Serie 2 (Hipertensión)")
```

```
                Método Error estándar Límite inferior Límite superior
1              Ingenuo        0.86168         1.01550         4.39330
2 Varianza Largo plazo        0.46870         1.78576         3.62305
```

```
tabla_ic(ing3, lp3, "Intervalos al 95% - Serie 3 (Respiratoria)")
```

```
                Método Error estándar Límite inferior Límite superior
1              Ingenuo        0.60205        119.9616        122.3217
2 Varianza Largo plazo        0.95618        119.2675        123.0158
```

Para la serie 1 se tiene que la cercanía entre ambos errores estándar muestra que la transformación ($\nabla_{12} \ln(y_t)$) logró limpiar casi toda la dependencia que afectaba la estimación del nivel. Ambos intervalos contienen valores muy cercanos a cero confirmando que no queda un desplazamiento permanente en el nivel.

En cuanto a la serie 2, el método ingenuo sobreestima la incertidumbre. Esto ocurre porque la serie ya diferenciada tiene autocorrelación fuertemente negativa . Cuando hay dependencia negativa, los cambios se compensan entre sí (a un valor alto le sigue uno bajo), haciendo que la media de la muestra converja más rápido a la media real. El método ingenuo ignora esta compensación natural, asume independencia y, por tanto, entrega un intervalo más amplio.

Por último, para la serie 3, hay autocorrelación **positiva** ($r_1 = 0.7271$), la dependencia temporal positiva significa que los datos consecutivos se parecen mucho, por lo que cada nueva observación aporta menos información que si fuera un dato 100 % independiente. El método ingenuo asume que cada dato aporta información nueva completa y, al hacerlo, subestima la verdadera incertidumbre. El intervalo de largo plazo es el único adecuado porque detecta esta redundancia de información y ensancha el intervalo para reflejar correctamente la variabilidad real.

Pronóstico y evaluación

(a) Métodos y asignación. Cada método del catálogo funciona en su propia función, con las convenciones de inicialización de las notas, se verifica en un ejemplo pequeño a mano o contra una cifra de las notas, y se aplica al menos a una de las tres series. En cada serie se aplican todos los métodos cuyo supuesto sostiene el diagnóstico de las secciones 3 a 5, y además al menos uno cuyo supuesto ese diagnóstico contradice, que sirve de contraste. Una tabla dice, para cada método y cada serie, si se aplicó y con qué evidencia se decidió

Ejemplos a mano

```
# Verificacion a mano de los 11 metodos del catalogo (seccion 6a).
# Convenciones de inicializacion:

# ============================================================

prueba <- function(x, y, tol = 1e-10) {
  x <- as.numeric(x); y <- as.numeric(y)
  if (length(x) != length(y))
    stop(sprintf("Longitudes distintas: %d vs %d", length(x), length(y)))
  stopifnot(isTRUE(all.equal(x, y, tolerance = tol)))
}

# ============================================================
```

```r
# 1. Media simple
#    yhat[t] = mean(y[1:t-1]) para t >= 2
#    pronosticar(h) = rep(mean(y), h)
# ------------------------------------------------------------
# Ejemplo a mano: y = (4, 6, 8)
#   yhat[1] = NA
#   yhat[2] = y[1] = 4
#   yhat[3] = (4+6)/2 = 5
#   media_final = (4+6+8)/3 = 6
# ============================================================
y <- c(4, 6, 8)
m <- ajustar_media(y)
prueba(m$yhat[2], 4)
prueba(m$yhat[3], 5)
prueba(m$pronosticar(1), 6)
prueba(m$pronosticar(4), rep(6, 4))

# ============================================================
# 2. Ingenuo
#    yhat[t] = y[t-1] ; pronosticar(h) = rep(y[n], h)
# ------------------------------------------------------------
# Ejemplo: y = (4, 6, 8)
#   yhat = (NA, 4, 6)
#   pronosticar(1) = 8
# ============================================================
y <- c(4, 6, 8)
m <- ajustar_ingenuo(y)
prueba(m$yhat[2], 4)
prueba(m$yhat[3], 6)
prueba(m$pronosticar(1), 8)
prueba(m$pronosticar(3), rep(8, 3))

# ============================================================
# 3. Ingenuo estacional (s = 4)
#    yhat[t] = y[t-s] ; pronosticar cicla el ultimo ciclo
# ------------------------------------------------------------
# Ejemplo: y = (10,20,30,40, 12,22,32,42), s = 4
#   yhat[5] = y[1] = 10, ..., yhat[8] = y[4] = 40
#   ciclo_final = (12, 22, 32, 42)
#   pronosticar(1) = 12, pronosticar(2) = 22,
#   pronosticar(3) = 32, pronosticar(4) = 42, pronosticar(5) = 12
# ============================================================
```

```r
y <- c(10, 20, 30, 40, 12, 22, 32, 42)
m <- ajustar_ingenuo_estacional(y, s = 4)
prueba(m$yhat[5], 10)
prueba(m$yhat[8], 40)
prueba(m$pronosticar(1), 12)
prueba(m$pronosticar(2), c(12, 22))
prueba(m$pronosticar(3), c(12, 22, 32))
prueba(m$pronosticar(4), c(12, 22, 32, 42))
prueba(m$pronosticar(5), c(12, 22, 32, 42, 12))   # vuelve a empezar el ciclo

# ============================================================
# 4. Media movil (k = 3)
#    yhat[t] = mean(y[(t-k):(t-1)]) para t >= k+1
#    pronosticar(h) = rep(mean(tail(y, k)), h)
# ------------------------------------------------------------
# Ejemplo: y = (1, 2, 3, 4, 5), k = 3
#   yhat[4] = mean(1,2,3) = 2
#   yhat[5] = mean(2,3,4) = 3
#   mm_final = mean(3,4,5) = 4
# ============================================================
y <- c(1, 2, 3, 4, 5)
m <- ajustar_mm(y, k = 3)
prueba(m$yhat[4], 2)
prueba(m$yhat[5], 3)
prueba(m$pronosticar(1), 4)
prueba(m$pronosticar(2), rep(4, 2))

# ============================================================
# 5. Suavizamiento exponencial simple (alpha = 0.5)
#    nivel_1 = y[1]
#    yhat[t] = nivel_{t-1}
#    nivel_t = alpha*y[t] + (1-alpha)*nivel_{t-1}
# ------------------------------------------------------------
# Ejemplo: y = (10, 12, 11), alpha = 0.5
#   t=1: nivel = 10
#   t=2: yhat[2] = 10 ; nivel = 0.5*12 + 0.5*10 = 11
#   t=3: yhat[3] = 11 ; nivel = 0.5*11 + 0.5*11 = 11
#   pronosticar(1) = 11
# Verificacion de la forma de correccion de error:
#   nivel_t = nivel_{t-1} + alpha * e_t
# ============================================================
y <- c(10, 12, 11)
```

```r
m <- ajustar_ses(y, alpha = 0.5)
prueba(m$yhat[2], 10)
prueba(m$yhat[3], 11)
prueba(m$pronosticar(1), 11)

nivel_manual <- y[1]
for (t in 2:3) {
  e_t <- y[t] - nivel_manual
  nivel_manual <- nivel_manual + 0.5 * e_t
}
prueba(m$pronosticar(1), nivel_manual)

# ============================================================
# 6. Doble media movil (k = 3)
#    MM_t = mean(y[(t-k+1):t])
#    DMM_t = mean(MM[(t-k+1):t]) para t >= 2k-1
#    nivel[t] = 2*MM[t] - DMM[t]
#    pendiente[t] = 2/(k-1) * (MM[t] - DMM[t])
#    yhat[t+1] = nivel[t] + pendiente[t]
# ------------------------------------------------------------
# Ejemplo: y = (1, 2, 3, 4, 5, 6), k = 3
#   MM:   MM[3]=2, MM[4]=3, MM[5]=4, MM[6]=5
#   DMM:  DMM[5]=mean(2,3,4)=3, DMM[6]=mean(3,4,5)=4
#   nivel[5] = 2*4 - 3 = 5 ; pendiente[5] = 1
#   nivel[6] = 2*5 - 4 = 6 ; pendiente[6] = 1
#   yhat[6] = nivel[5] + pendiente[5] = 6
#   pronosticar(1) = 6 + 1*1 = 7
#   pronosticar(2) = 6 + 1*2 = 8
# ============================================================
y <- c(1, 2, 3, 4, 5, 6)
m <- ajustar_dmm(y, k = 3)
prueba(m$yhat[6], 6)
prueba(m$pronosticar(1), 7)
prueba(m$pronosticar(2), c(7, 8))

# ============================================================
# 7a. Tendencia lineal
#    OLS de y ~ [1, t] sobre y[1:n]; pronostico continuo la recta
# ------------------------------------------------------------
# Ejemplo: y = (3, 5, 7, 9), t = 1..4
#   OLS: y = 1 + 2*t
#   yhat[3] = 1 + 2*3 = 7
```

```
#   yhat[4] = 1 + 2*4 = 9
#   pronosticar(1) = 1 + 2*5 = 11
#   pronosticar(2) = 1 + 2*6 = 13
# ============================================================
y <- c(3, 5, 7, 9)
m <- ajustar_tendencia(y, "lineal")
prueba(m$yhat[3], 7)
prueba(m$yhat[4], 9)
prueba(m$pronosticar(1), 11)
prueba(m$pronosticar(2), c(11, 13))

# ============================================================
# 7b. Tendencia cuadratica
#    OLS de y ~ [1, t, t^2]
# ------------------------------------------------------------
# Ejemplo: y = (1, 4, 9, 16) = t^2
#   OLS: y = 0 + 0*t + 1*t^2
#   pronosticar(1) = 5^2 = 25
#   pronosticar(2) = 6^2 = 36
# ============================================================
y <- c(1, 4, 9, 16)
m <- ajustar_tendencia(y, "cuadratica")
prueba(m$pronosticar(1), 25)
prueba(m$pronosticar(2), c(25, 36))

# ============================================================
# 7c. Tendencia exponencial
#    log(y) = a + theta*t ; pronosticar = exp(a + theta*(n+h))
#    Sin correccion de sesgo por defecto.
# ------------------------------------------------------------
# Ejemplo: y = (2, 4, 8, 16) = 2^t
#   log(y) = t * log(2) ; a = 0, theta = log(2)
#   pronosticar(1) = exp(0 + log(2)*5) = 32
#   pronosticar(2) = exp(0 + log(2)*6) = 64
# ============================================================
y <- c(2, 4, 8, 16)
m <- ajustar_tendencia(y, "exponencial")
prueba(m$pronosticar(1), 32)
prueba(m$pronosticar(2), c(32, 64))

# ============================================================
# 8. Tendencia con ficticias de suma cero (s = 2)
```

```r
#    Diseno: [1, t, D_1] con D_1 = 1 si periodo 1, -1 si periodo s.
#    Modelo: y = b0 + b1*t + b2*D_1
# ------------------------------------------------------------
# Ejemplo: y = (5, 10, 7, 12, 9, 14) -> impares=5,7,9; pares=10,12,14
#   Impares: y = b0 + b1*t + b2   -> pendiente 1, b0+b2 = 4
#   Pares:   y = b0 + b1*t - b2   -> pendiente 1, b0-b2 = 8
#   => b0 = 6, b1 = 1, b2 = -2
#   pronosticar(1) en t=7, periodo 1: 6 + 7 - 2 = 11
#   pronosticar(2) en t=8, periodo 2: 6 + 8 + 2 = 16
# ============================================================
y <- c(5, 10, 7, 12, 9, 14)
m <- ajustar_tendencia_estacional(y, s = 2)
prueba(m$parametros$coeficientes["intercepto"],  6)
prueba(m$parametros$coeficientes["tendencia"],   1)
prueba(m$parametros$coeficientes["estacion_1"], -2)
prueba(m$pronosticar(1), 11)
prueba(m$pronosticar(2), c(11, 16))

# ============================================================
# 9. Holt (alpha = 0.5, beta = 0.5)
#    nivel_1 = y[1] ; tendencia_1 = 0
#    yhat[t]       = nivel_{t-1} + tendencia_{t-1}
#    nivel_t       = alpha*y[t] + (1-alpha)*yhat[t]
#    tendencia_t   = beta*(nivel_t - nivel_{t-1}) + (1-beta)*tendencia_{t-1}
# ------------------------------------------------------------
# Ejemplo: y = (10, 12, 14, 16)
#   t=1: nivel=10, tend=0
#   t=2: yhat=10 ; nivel=11     ; tend=0.5
#   t=3: yhat=11.5 ; nivel=12.75 ; tend=1.125
#   t=4: yhat=13.875 ; nivel=14.9375 ; tend=1.65625
#   pronosticar(1) = 14.9375 + 1.65625*1 = 16.59375
#   pronosticar(2) = 14.9375 + 1.65625*2 = 18.25
# ============================================================
y <- c(10, 12, 14, 16)
m <- ajustar_holt(y, alpha = 0.5, beta = 0.5)
prueba(m$parametros$nivel[4],     14.9375)
prueba(m$parametros$tendencia[4],  1.65625)
prueba(m$pronosticar(1), 14.9375 + 1.65625)
prueba(m$pronosticar(2), c(
  14.9375 + 1 * 1.65625,
  14.9375 + 2 * 1.65625
))
```

```r
# ============================================================
# 10. Holt-Winters aditivo (s = 2, alpha = beta = gamma = 0.5)
#     Inicializacion con dos ciclos (convencion de este codigo):
#       media_1 = mean(y[1:s]) ; media_2 = mean(y[s+1:2s])
#       tendencia_2s = (media_2 - media_1) / s
#       est_1 = y[1:s] - media_1 ; est_2 = y[s+1:2s] - media_2
#       est = (est_1 + est_2)/2 ; renormalizar a suma 0
#       nivel[2s] = media_2 ; tendencia[2s] = tendencia_2s
# ------------------------------------------------------------
# Ejemplo: y = (2, 4, 2, 4, 2, 4), s = 2
#   media_1 = 3, media_2 = 3, tendencia_2s = 0
#   est_1 = (-1, 1), est_2 = (-1, 1), est = (-1, 1) (ya suma 0)
#   nivel[4] = 3 ; tendencia[4] = 0 ; estacional[1:4] = (-1,1,-1,1)
#   t=5: yhat = 3 + 0 + (-1) = 2 ; nivel=3 ; tend=0 ; est[5]=-1
#   t=6: yhat = 3 + 0 + 1 = 4 ; nivel=3 ; tend=0 ; est[6]=1
#   pronosticar(1) = 3 + 0*1 + est[5] = 2
#   pronosticar(2) = 3 + 0*2 + est[6] = 4
#   pronosticar(3) = 3 + 0*3 + est[5] = 2
#   pronosticar(4) = 3 + 0*4 + est[6] = 4
# ============================================================
y <- c(2, 4, 2, 4, 2, 4)
m <- ajustar_hw(y, s = 2, alpha = 0.5, beta = 0.5, gamma = 0.5)
prueba(m$yhat[5], 2)
prueba(m$yhat[6], 4)
prueba(m$pronosticar(1), 2)
prueba(m$pronosticar(2), c(2, 4))
prueba(m$pronosticar(3), c(2, 4, 2))
prueba(m$pronosticar(4), c(2, 4, 2, 4))

# ============================================================
# 11. Holt-Winters multiplicativo (s = 2, alpha = beta = gamma = 0.5)
#     Misma inicializacion, pero:
#       est_1 = y[1:s] / media_1 ; est_2 = y[s+1:2s] / media_2
#       renormalizar a media 1
# ------------------------------------------------------------
# Ejemplo: y = (2, 4, 2, 4, 2, 4), s = 2
#   est_1 = (2/3, 4/3), est_2 = (2/3, 4/3), est = (2/3, 4/3)
#   nivel[4] = 3 ; tendencia[4] = 0 ; estacional[1:4] = (2/3,4/3,2/3,4/3)
#   pronosticar(1) = (3 + 0*1) * 2/3 = 2
#   pronosticar(2) = (3 + 0*2) * 4/3 = 4
# ============================================================
y <- c(2, 4, 2, 4, 2, 4)
```

```r
m <- ajustar_hw_mult(y, s = 2, alpha = 0.5, beta = 0.5, gamma = 0.5)
prueba(m$yhat[5], 2)
prueba(m$yhat[6], 4)
prueba(m$pronosticar(1), 2)
prueba(m$pronosticar(2), c(2, 4))
prueba(m$pronosticar(3), c(2, 4, 2))
prueba(m$pronosticar(4), c(2, 4, 2, 4))

# ============================================================
# Bloque de contraste contra lm()
# Permitido: lm() puede usarse en bloques de verificacion.
# Solo se contrasta la parte determinista del ajuste.
# ============================================================
y <- c(3, 5, 7, 9)
m_lm <- lm(y ~ seq_along(y))
prueba(unname(coef(m_lm)), c(1, 2))

y <- c(1, 4, 9, 16)
m_lm <- lm(y ~ seq_along(y) + I(seq_along(y)^2))
prueba(unname(coef(m_lm)), c(0, 0, 1), tol = 1e-8)

# Caso constante: con y = rep(5, 8), HW aditivo devuelve 5 en todo h.
y <- rep(5, 8)
m <- ajustar_hw(y, s = 4, alpha = 0.5, beta = 0.5, gamma = 0.5)
prueba(m$pronosticar(1), 5)
prueba(m$pronosticar(4), rep(5, 4))

# ============================================================
# Verificacion estructural con las series reales STUW9J
# (dimension y calentamiento; los valores ya se verificaron a mano)
# ============================================================
s1 <- read.csv("../datos/STUW9J-serie-1.csv")$valor
s2 <- read.csv("../datos/STUW9J-serie-2.csv")$valor
s3 <- read.csv("../datos/STUW9J-serie-3.csv")$valor

stopifnot(length(s1) == 156L)
stopifnot(length(s2) == 160L)
stopifnot(length(s3) == 240L)

m1 <- ajustar_hw(s1[1:124], s = 12, alpha = 0.3, beta = 0.1, gamma = 0.3)
stopifnot(length(m1$pronosticar(12)) == 12L)
stopifnot(all(is.finite(m1$pronosticar(12))))
```

```r
m2 <- ajustar_hw_mult(s2[1:128], s = 52, alpha = 0.3, beta = 0.1, gamma = 0.3)
stopifnot(length(m2$pronosticar(4)) == 4L)

m3 <- ajustar_hw(s3[1:192], s = 52, alpha = 0.3, beta = 0.1, gamma = 0.3)
stopifnot(length(m3$pronosticar(4)) == 4L)

cat("Verificacion 6(a): los 11 metodos pasaron.\n")
```

```
Verificacion 6(a): los 11 metodos pasaron.
```

Aplicación de los métodos por serie:

"*" indica el método de contraejemplo, es decir, uno no indicado para la serie correspondiente.

Método	Serie 1	Serie 2	Serie 3
Media simple	No	Sí*	Sí
Ingenuo	No	Sí	Sí
Ingenuo estacional	Sí	No	No
Media móvil	No	No	Sí
Suavizamiento exponencial simple	No	No	Sí
Doble media móvil	No	Sí	No
Tendencia lineal, cuadrática y exponencial	Sí*	Sí	No
Tendencia con ficticias de suma cero	Sí	No	No
Holt	No	Sí	Sí*
Holt Winters aditivo	Sí	No	No
Holt Winter multiplicativo	Sí	No	No

- Serie 1: Esta serie es de tipo IV, tiene estacionalidad y tendencia. Las metodologías adecuadas para este tipo de comportamiento son: Holt-aditivo, Holt-multiplicativo, tendencia con ficticias. Ya se motró que sería más apropiado un Holt-multiplicativo que uno aditivo, pero a modo de comparación se presentan los dos. Además, se usa un referente ingenuo, en este caso el estacional, pues la serie presenta estacionalidad. Como contrajemplo se muestra tambien el método de tendencia lineal, que se usa cuando solo hay tendencia.
- Serie 2: Hay presencia de una serie tipo II, solo tendencia. Los métodos que se usan para estos casos son doble media móvil, tendencias, Holt y referente ingenuo para tener un punto de comparación inicial. Como contraejemplo se propone una media simple, que se usa cuando la serie es estacionaria.

- Serie 3: La serie 3 es estacionaria, por lo que las metricas indicados son media simple, media móvil, suavizamiento exponencial simple y referente ingenuo para comparar. Como contraejemplo se usa el método de Holt, el cual es usado cuando la serie presenta tendencia.

Método	S1	S2	S3	Evidencia
Media simple	contraste	contraste	aplicado	Nivel constante (S3) vs. tendencia (S1, S2)
Ingenuo	referente	referente	referente	Referente obligatorio del curso
Ingenuo estacional	referente	referente	referente	Referente honesto cuando la ACF tiene picos en h = s, 2s
MM(k)	aplicado	contraste	aplicado	k elegido por MSE de un paso sobre y[1:n0]
SES	contraste	contraste	aplicado	alpha optimo diagnosticado como especificacion
DMM(k)	aplicado	aplicado	contraste	Tendencia local vs. sin tendencia
Tendencia lineal	aplicado	aplicado	contraste	Decaimiento lento de r_h
Tendencia cuadratica	contraste	aplicado	contraste	AIC/BIC sobre y[1:n0]
Tendencia exponencial	aplicado	aplicado	contraste	Amplitud crece con nivel (S1, S2)
Tendencia con ficticias	aplicado	aplicado	aplicado	Picos en h = s, 2s, 3s
Holt	aplicado	aplicado	contraste	Tendencia local sostenida
HW aditivo	contraste	contraste	aplicado	Amplitud constante vs. creciente

Método	S1	S2	S3	Evidencia
HW multiplicativo	aplicado	aplicado	contraste	Amplitud crece con nivel (S1, S2)

(b) Regresiones. Para cada tendencia ajustada por mínimos cuadrados, con o sin ficticias: tabla de coeficientes con error estándar ordinario y robusto a autocorrelación con núcleo de Bartlett, pruebas t con el robusto, y revisión de supuestos sobre los residuos, con correlograma, Ljung–Box referido a $\chi^2_{(m)}$, porque los coeficientes de regresores deterministas no restan grados de libertad, Jarque–Bera, y el estadístico de Durbin–Watson como diagnóstico, leído con $d \approx 2(1 - r_1)$.

```
errores_robustos <- function(modelo) {
  res <- residuals(modelo)
  n <- length(res)
  k <- length(coef(modelo))

  X <- model.matrix(modelo)
  r1 <- acf(res, lag.max = 1, plot = FALSE)$acf[2]
  d <- 2 * (1 - r1)
  sigma2 <- sum(res^2) / (n - k)

  XX_inv <- solve(t(X) %*% X)

  cov_robusta <- d * sigma2 * XX_inv

  se_robusto <- sqrt(diag(cov_robusta))
  se_ordinario <- sqrt(diag(sigma2 * XX_inv))

  list(coeficientes = coef(modelo),
       se_ordinario = se_ordinario,
       se_robusto = se_robusto,
       r1 = r1,
       d = d,
       dw = d,
       n = n,
       k = k)
}

# Definir asimetría y curtosis
skewness <- function(x) {
```

```r
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^3) / n / (s^3)
}

kurtosis <- function(x) {
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^4) / n / (s^4)
}


# Función principal: ajustar y presentar resultados
ajustar_tendencia_completa <- function(y, nombre_serie, es_original = FALSE) {
  t <- seq_along(y)

  # Lineal - SIEMPRE aplica
  m_lineal <- lm(y ~ t)
  rob_lineal <- errores_robustos(m_lineal)

  # Cuadrática - SIEMPRE aplica
  m_cuadr <- lm(y ~ t + I(t^2))
  rob_cuadr <- errores_robustos(m_cuadr)

  # Exponencial - SOLO si la serie es estrictamente positiva (ORIGINAL)
  if (es_original && all(y > 0)) {
    m_exp <- lm(log(y) ~ t)
    rob_exp <- errores_robustos(m_exp)
  } else {
    m_exp <- NULL
    rob_exp <- list(
      coeficientes = NA,
      se_ordinario = NA,
      se_robusto = NA,
      mensaje = "No aplica: serie transformada con valores   0"
    )
  }

  # --- Pruebas diagnóstico sobre residuos del modelo lineal ---
  res_lineal <- residuals(m_lineal)
```

```
  t_media_cero <- t.test(res_lineal, mu = 0)
  m_rez <- min(24, floor(length(y)/4))
  lb <- ljung_box(res_lineal, m = m_rez, T = length(y))
  dw <- 2 * (1 - rob_lineal$r1)

  # Jarque-Bera
  n_res <- length(res_lineal)
  s <- skewness(res_lineal)
  k <- kurtosis(res_lineal) - 3
  jb <- n_res * (s^2/6 + k^2/24)
  p_jb <- 1 - pchisq(jb, df = 2)

  list(
    nombre = nombre_serie,
    lineal = list(modelo = m_lineal, robusto = rob_lineal),
    cuadratica = list(modelo = m_cuadr, robusto = rob_cuadr),
    exponencial = list(modelo = m_exp, robusto = rob_exp),
    pruebas = list(
      rezagos_usados = m_rez,
      t_media_cero = t_media_cero,
      ljung_box = lb,
      durbin_watson = dw,
      jarque_bera = c(estadistico = jb, p_valor = p_jb)))
}
```

```
w1 <- log(datos1$y)
w2 <- (datos2$y)
w3 <- (datos3$y)
res_serie1 <- ajustar_tendencia_completa(w1, "Serie 1 - EDA transformada", es_original = FALS

res_serie2 <- ajustar_tendencia_completa(w2, "Serie 2 - Hipertensión", es_original = TRUE)

res_serie3 <- ajustar_tendencia_completa(w3, "Serie 3 - Respiratoria", es_original = TRUE)
```

1.Prueba t de media cero

1.1 Hipotesis nula y alternativa:

$$H_0 : \mu = 0 \quad : \text{la media de los residuos es cero.}$$
$$H_a : \mu = 0 \quad : \text{la media de los residuos difiere de cero.}$$

1.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$T = \frac{\bar{e}}{s/\sqrt{n}}$$

Donde $\bar{e}$ es la media de los residuos. Bajo H_0 , el estadistico de prueba sigue la distribución t de Student con n-1 grados de libertad.

1.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff |T| > t_{n-1,\,0.975}$$

. si el valor absoluto del estadístico excede el valor crítico, se rechaza la hipótesis nula de media cero.

1.4 Valor observado del estadístico y valor p

- T_{obs}: valor numérico del estadístico que se calcula directamente con los residuos del modelo
- Valor $p = P(|T| > |t_{\text{obs}}|)$ Donde $T \sim t_{n-1}$. Es la probabilidad de observar un valor tan extremo o más extremo que el obtenido, bajo la hipótesis nula de media cero.

1.5 Decision

Se compara T_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $T_{\text{obs}} > t_{n-1,0.975}$ o bien con si el valor $p < 0.05$, se rechaza H_0.
- En caso contrario, pues no se rechaza H_0.

1.6 Lectura de la decisión en términos de la serie

- Si no se rechaza H_0, la media de los residuos es compatible con cero. El modelo no presenta sesgo sistemático; si se rechaza el modelo presenta un sesgo persistente; predice sistemáticamente por encima o por debajo del valor real, lo que indica que la forma de tendencia elegida no capta completamente el comportamiento de nivel de la serie.

2. Prueba de Ljung-Box

2.1 Hipotesis nula y alternativa:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_{24} = 0 \quad \text{: la serie es ruido blanco.}$$
$$H_a : \exists k \in \{1, 2, \ldots, 24\} \quad \text{tal que } \rho_k \neq 0 \quad \text{: existe dependencia serial.}$$

2.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$Q = n(n+2)\sum_{k=1}^{m} \frac{r_k^2}{n-k}$$

Donde: - n es el número de observaciones, - r_k es la autocorrelación muestral al rezago k, - m es el número de rezagos evaluados.

Bajo H_0, el estadístico Q sigue una distribución:

$$Q \xrightarrow{d} \chi^2_{(m)}$$

2.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

2.4 Valor observado del estadístico y valor p

- Q_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

2.5 Decision

Se compara Q_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $Q_{\text{obs}} > \chi^2_{m,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, no se rechaza H_0.

2.6 Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de dependencia del fenómeno:

- Si se rechaza H_0, existe dependencia serial, la serie no es ruido blanco.

3.Prueba de Durbin–Watson

Detectar autocorrelación de primer orden en los residuos del modelo: ¿el error de hoy está relacionado con el error de ayer?

3.1 Hipotesis nula y alternativa:

$H_0 : \rho = 0$: no hay correlación entre el residuo actual y el inmediatamente anterior.
$H_a : \rho = 0$: existe autocorrelación de primer orden (puede ser positiva o negativa).

3.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$d = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} e_t^2} \approx 2(1 - r_1)$$

Donde: -e_t ya se habia definido -r_1 es la autocorrelación muestral de primer orden de los residuos.

Bajo H_0, el estadístico d sigue una referencia de valor bajo $d \approx 2$.

3.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

3.4 Valor observado del estadístico

- d_{obs}: valor numérico del estadístico.

3.5 Decision

Se compara d_{obs} con el valor crítico o el valor de referencia, ie. $d \approx 2$.

- Si $d_{obs} « 2 $ o $d_{obs} « 2 $, se rechaza H_0, ie. si el valor observado difiere mucho del valor de referencia igual a 2.
- En caso contrario, ie. si $d_{obs} 2 $ o es muy cercano a ese 2, entonces no se rechaza H_0.

3.6 Lectura de la decisión en términos de la serie

- Si se rechaza H_0, hay autocorrelación positiva; los errores se parecen entre sí, quedando estructura por modelar o tambien puede haber autocorrelación negativa, ie. los errores se alternan sistemáticamente.

4. Prueba de Jarque–Bera

Esta es con el fin de verificar si los residuos del modelo siguen una distribución normal. Comprobar que los errores no presentan asimetría ni curtosis excesiva.

4.1 Hipotesis nula y alternativa:

H_0 : los residuos siguen una distribucion normal, ie. asimetría = 0 y curtosis =3

H_a : La distribución de los residuos no es normal:

4.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$JB = n\left(\frac{S^2}{6} + \frac{(K-3)^2}{24}\right)$$

Donde: - S es la asimetría muestral de los residuos, - K es la curtosis muestral de los residuos y - n es el número de residuos.

Bajo H_0, el estadístico de prueba JB sigue una distribución chi-cuadrado con 2 grados de libertad, ie:

$$JB \xrightarrow{d} \chi^2_{(2)}$$

4.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff JB > \chi^2_{2,\,0.95}$$

donde $\chi^2_{2,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

4.4 Valor observado del estadístico y valor p

- JB_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

4.5 Decision

Se compara JB_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $JB_{\text{obs}} > \chi^2_{2,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, acepatamos H_0.

4.6 Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de residuos del fenómeno:

- Si se rechaza H_0, los residuos no se distribuyen normalmente; puede haber valores extremos o asimetría que afecta la precisión de los pronósticos. De lo contrario los residuos son compatibles con normalidad; los intervalos de confianza basados en esta suposición son fiables.

```
tabla_coef <- function(res, titulo) {
  m_lin <- res$lineal$modelo
  rob_lin <- res$lineal$robusto

  m_cua <- res$cuadratica$modelo
  rob_cua <- res$cuadratica$robusto
  filas <- list()
  filas[["Lineal - Intercepto"]] <- c(
    round(coef(m_lin)[1], 6),
    round(rob_lin$se_ordinario[1], 6),
```

```
  round(rob_lin$se_robusto[1], 6)
)
filas[["Lineal - Pendiente t"]] <- c(
  round(coef(m_lin)[2], 6),
  round(rob_lin$se_ordinario[2], 6),
  round(rob_lin$se_robusto[2], 6)
)

filas[["Cuadrática - Intercepto"]] <- c(
  round(coef(m_cua)[1], 6),
  round(rob_cua$se_ordinario[1], 6),
  round(rob_cua$se_robusto[1], 6)
)
filas[["Cuadrática - Lineal t"]] <- c(
  round(coef(m_cua)[2], 6),
  round(rob_cua$se_ordinario[2], 6),
  round(rob_cua$se_robusto[2], 6)
)
filas[["Cuadrática - Cuadrático t²"]] <- c(
  round(coef(m_cua)[3], 6),
  round(rob_cua$se_ordinario[3], 6),
  round(rob_cua$se_robusto[3], 6)
)

if (!is.null(res$exponencial$modelo)) {
  m_exp <- res$exponencial$modelo
  rob_exp <- res$exponencial$robusto
  filas[["Exponencial - Intercepto"]] <- c(
    round(coef(m_exp)[1], 6),
    round(rob_exp$se_ordinario[1], 6),
    round(rob_exp$se_robusto[1], 6)
  )
  filas[["Exponencial - Crecimiento t"]] <- c(
    round(coef(m_exp)[2], 6),
    round(rob_exp$se_ordinario[2], 6),
    round(rob_exp$se_robusto[2], 6)
  )
} else {
  filas[["Exponencial"]] <- c("No aplica", "", "")
}

# Convertir a tabla
```

```
  tab <- do.call(rbind, filas)
  colnames(tab) <- c("Valor estimado", "EE ordinario", "EE robusto")

  return(tab)
}
```

```
tabla_pruebas <- function(res, titulo) {
  p <- res$pruebas

  # Extraer valores
  t_est <- round(p$t_media_cero$statistic, 4)
  t_p <- round(p$t_media_cero$p.value, 4)
  dec_t <- ifelse(p$t_media_cero$p.value > 0.05, "Acepta", "Rechaza")

  # Ljung-Box: Q y valor p
  lb_Q <- round(p$ljung_box$estadistico, 2)
  lb_p <- round(p$ljung_box$p_valor, 4)
  m_rez <- p$ljung_box$rezagos_usados
  dec_lb <- ifelse(lb_p > 0.05, "Independencia", "Hay dependencia")

  # Durbin-Watson
  dw_val <- round(p$durbin_watson, 3)
  dec_dw <- ifelse(abs(dw_val - 2) < 0.5, "  2 → sin correlación",
                   ifelse(dw_val < 1.5, "Bajo → correlación positiva",
                          "Alto → correlación negativa"))

  # Jarque-Bera
  JB_val <- round(p$jarque_bera[1], 2)
  JB_p <- round(p$jarque_bera[2], 4)
  dec_jb <- ifelse(JB_p > 0.05, "Normalidad", "No normal")

  # Construir tabla
  tab <- data.frame(
    Prueba = c(
      "t de media cero",
      paste0("Ljung-Box ($Q$, $m = ", m_rez, "$)"),
      "Durbin-Watson ($d$)",
      "Jarque-Bera ($JB$)"
    ),
    Estadístico = c(
      t_est,
      paste0("$Q = ", lb_Q, "$"),
```

```
      paste0("$d = ", dw_val, "$"),
      paste0("$JB = ", JB_val, "$")
    ),
    `Valor p` = c(
      t_p,
      lb_p,
      "-",
      JB_p),
    Decisión = c(dec_t, dec_lb, dec_dw, dec_jb))
  return(tab)
}
```

```
tabla_coef(res_serie1, "Coeficientes y errores estándar - Serie 1 (EDA)")
```

	Valor estimado	EE ordinario	EE robusto
Lineal - Intercepto	"4.61741"	"0.030886"	"0.020167"
Lineal - Pendiente t	"0.005866"	"0.000341"	"0.000223"
Cuadrática - Intercepto	"4.613175"	"0.046855"	"0.030598"
Cuadrática - Lineal t	"0.006027"	"0.001378"	"9e-04"
Cuadrática - Cuadrático t^2	"-1e-06"	"9e-06"	"6e-06"
Exponencial	"No aplica"	""	""

```
tabla_pruebas(res_serie1, "Pruebas diagnóstico - Serie 1")
```

	Prueba	Estadístico	Valor.p	Decisión
1	t de media cero	0	1	Acepta
2	Ljung-Box (Q, $m = $)	$Q = 149.01$	0	Hay dependencia
3	Durbin-Watson (d)	$d = 0.426$	-	Bajo → correlación positiva
4	Jarque-Bera (JB)	$JB = 14.93$	6e-04	No normal

```
tabla_coef(res_serie2, "Coeficientes y errores estándar - Serie 2 (Hipertensión)")
```

	Valor estimado	EE ordinario	EE robusto
Lineal - Intercepto	-0.552594	3.867610	1.903106
Lineal - Pendiente t	2.716958	0.041673	0.020506
Cuadrática - Intercepto	51.413282	1.956558	2.611127
Cuadrática - Lineal t	0.792296	0.056109	0.074880
Cuadrática - Cuadrático t^2	0.011954	0.000338	0.000450
Exponencial - Intercepto	4.047140	0.013344	0.011021
Exponencial - Crecimiento t	0.014163	0.000144	0.000119

```r
tabla_pruebas(res_serie2, "Pruebas diagnóstico - Serie 2")
```

	Prueba	Estadístico	Valor.p	Decisión
1	t de media cero	0	1	Acepta
2	Ljung-Box (Q, $m = $)	$Q = 4412913.46$	0	Hay dependencia
3	Durbin-Watson (d)	$d = 0.242$	- Bajo → correlación positiva	
4	Jarque-Bera (JB)	$JB = 10.64$	0.0049	No normal

```r
tabla_coef(res_serie3, "Coeficientes y errores estándar - Serie 3 (Respiratoria)")
```

	Valor estimado	EE ordinario	EE robusto
Lineal - Intercepto	123.362064	1.198975	0.895433
Lineal - Pendiente t	-0.018427	0.008626	0.006442
Cuadrática - Intercepto	123.474150	1.811674	1.353001
Cuadrática - Lineal t	-0.021206	0.034712	0.025924
Cuadrática - Cuadrático t^2	0.000012	0.000139	0.000104
Exponencial - Intercepto	4.812190	0.009938	0.007472
Exponencial - Crecimiento t	-0.000151	0.000071	0.000054

```r
tabla_pruebas(res_serie3, "Pruebas diagnóstico - Serie 3")
```

	Prueba	Estadístico	Valor.p	Decisión
1	t de media cero	0	1	Acepta
2	Ljung-Box (Q, $m = $)	$Q = 437601.33$	0	Hay dependencia
3	Durbin-Watson (d)	$d = 0.558$	- Bajo → correlación positiva	
4	Jarque-Bera (JB)	$JB = 2.45$	0.2938	Normalidad

Conclusión para la Serie 1 (EDA - Logaritmo):

- **Tendencia:** Al evaluar el modelo lineal, la pendiente estimada es de 0.005866 con un error estándar robusto de 0.000223. Si calculas el estadístico t ($0.005866/0.000223 \approx 26.3$), resulta ser altamente significativo, lo que indica que **sí existe una tendencia creciente clara** en la serie transformada, contradiciendo tu texto actual que afirma que no hay evidencia de tendencia.
- **Residuos:** Aunque la prueba t acepta que la media de los residuos es cero, las pruebas de diagnóstico revelan que el modelo de tendencia lineal no captura toda la dinámica. La prueba de Ljung-Box ($Q = 149.01$) rechaza la hipótesis de independencia, y el estadístico de Durbin-Watson ($d = 0.426$) señala una fuerte autocorrelación positiva en los residuos. Además, la prueba de Jarque-Bera ($JB = 14.93$, valor $p = 0.0006$) rechaza la normalidad.

Conclusión para la Serie 2 (Hipertensión - Original):

- **Tendencia:** Contrario a lo que indica tu texto actual ("la serie fue diferenciada… la pendiente no debe ser significativa"), la tabla muestra el ajuste sobre la serie original. La pendiente lineal es de 2.716958 con un error estándar robusto de 0.020506. El estadístico t es inmenso (> 130), confirmando un **fuerte crecimiento lineal** de aproximadamente 2.7 afiliados por semana.
- **Residuos:** El estadístico de Durbin-Watson ($d = 0.242$) es alarmantemente bajo, indicando una autocorrelación positiva severa (los errores se parecen mucho entre sí). Esto se confirma con el rechazo rotundo de independencia en la prueba de Ljung-Box. Los residuos tampoco se distribuyen de forma normal según la prueba de Jarque-Bera ($p = 0.0049$).

Conclusión para la Serie 3 (Respiratoria - Original):

- **Tendencia:** La tabla reporta una pendiente lineal de -0.018427 con un error estándar robusto de 0.006442. Al calcular la prueba t ($-0.018427/0.006442 \approx -2.86$), la pendiente **sí resulta estadísticamente significativa** al 5 %, indicando un muy leve decrecimiento en el tiempo. Esto contradice tu conclusión original de que no es significativa.
- **Residuos:** Es la única serie donde la prueba de Jarque-Bera ($JB = 2.45$, valor $p = 0.2938$) **no rechaza la normalidad**, por lo que los residuos son compatibles con una distribución normal. Sin embargo, la prueba de Ljung-Box y el valor de Durbin-Watson ($d = 0.558$) confirman que existe autocorrelación positiva y dependencia serial en los errores.

(c) Origen móvil. Para cada serie, una tabla por horizonte, $h = 1$ y $h = H$, con RMSE, MAD y MAPE de todos los métodos aplicados, incluido el contraste, ordenada de menor a mayor RMSE y con un referente ingenuo como una fila más calculada sobre los mismos orígenes. El equipo decide y justifica cuál de los dos ingenuos es el referente de cada serie. Un método que no supera al referente no se descarta de la tabla.

```
generar_tabla_origen_movil <- function(y, lista_metodos,
                                       h, n0){
  resultados <- list()

  for (nombre in names(lista_metodos)) {
    metodo_wrapper <- lista_metodos[[nombre]]

    evaluacion <- origen_movil(y = y, metodo = metodo_wrapper, h = h, n0 = n0)

    metricas <- medidas(evaluacion$reales, evaluacion$predicciones)

    resultados[[nombre]] <- data.frame(
```

```
      Método = nombre,
      RMSE = round(metricas["RMSE"], 4),
      MAD = round(metricas["MAD"], 4),
      MAPE = round(metricas["MAPE"], 4)
    )
  }

  tabla_final <- do.call(rbind, resultados)
  rownames(tabla_final) <- NULL
  tabla_final <- tabla_final[order(tabla_final$RMSE), ]

  return(tabla_final)
}
```

Valores de los parámetros:

```
n0_1 <- floor(0.8 * length(datos1$y))
n0_2 <- floor(0.8 * length(datos2$y))
n0_3 <- floor(0.8 * length(datos3$y))
# Holt-multiplicativo Serie 1
opt_hw_mult_s1 <- optimizar(
  y = datos1$y[seq_len(n0_1)],
  metodo = "hw_mult",
  s = 12
)
opt_hw_mult_s1$optimo
```

```
    alpha beta gamma    mse
163   0.1  0.1   0.3 60.439
```

```
# Hold-aditivo Serie 1
opt_hw_ad_s1 <- optimizar(
  y = datos1$y[seq_len(n0_1)],
  metodo = "hw",
  s = 12
)
opt_hw_ad_s1$optimo
```

```
    alpha beta gamma      mse
487   0.1  0.1   0.7 76.01505
```

```r
# Doble media movil Serie 2
opt_dmm_s2 <- optimizar(
  y = datos2$y[seq_len(n0_2)], metodo = "dmm"
)
opt_dmm_s2$optimo
```

```
    k      mse
10 12 94.61137
```

```r
# Holt serie 2
opt_holt_s2 <- optimizar(
  y = datos2$y[seq_len(n0_2)], metodo = "holt"
)
opt_holt_s2$optimo
```

```
   alpha beta      mse
22  0.15  0.1 76.05466
```

```r
# SE serie 3
opt_se_s3 <- optimizar(
  y = datos3$y[seq_len(n0_3)], metodo = "ses"
)
opt_se_s3$optimo
```

```
   alpha    mse
49  0.98 47.503
```

```r
# media movil serie 3
opt_mm_s3 <- optimizar(
  y = datos3$y[seq_len(n0_3)], metodo = "mm"
)
opt_mm_s3$optimo
```

```
  k      mse
1 2 71.35417
```

```r
# Holt serie 3
opt_holt_s3 <- optimizar(
  y = datos3$y[seq_len(n0_3)], metodo = "holt"
)
opt_holt_s3$optimo
```

```
   alpha beta      mse
19  0.95 0.05 50.59647
```

```r
# --- SERIE 1: EDA (h=1 y h=12) ---
# Justificación del referente: Ingenuo estacional, dado que la serie presenta
# una marcada estacionalidad de periodo s=12.
n0_1 <- floor(0.8 * length(datos1$y))

metodos_s1 <- list(
  "Ingenuo Estacional (Referente)" = function(y) ajustar_ingenuo_estacional(y, s = 12),
  "Tendencia Lineal (Contraste)" = function(y) ajustar_tendencia(y, tipo = "lineal"),
  "Tendencia Ficticias" = function(y) ajustar_tendencia_estacional(y, s = 12),
  # Reemplaza con los parámetros que sacaste de optimizar()
  "Holt-Winters Aditivo" = function(y) ajustar_hw(y, s = 12, alpha = opt_hw_ad_s1$optimo$alph
                                                 gamma = opt_hw_ad_s1$optimo$gamma),
  "Holt-Winters Multiplicativo" = function(y) ajustar_hw_mult(y, s = 12, alpha = opt_hw_mult_
                                                             gamma = opt_hw_mult_s1$optimo$g
)

# SERIE 2: Hipertensión (h=1 y h=6)
# Justificación del referente: Ingenuo simple, dado que la serie presenta
# una tendencia creciente sin patrón estacional visible.
n0_2 <- floor(0.8 * length(datos2$y))

metodos_s2 <- list(
  "Ingenuo (Referente)" = function(y) ajustar_ingenuo(y),
  "Media Simple (Contraste)" = function(y) ajustar_media(y),
  "Tendencia Lineal" = function(y) ajustar_tendencia(y, tipo = "lineal"),
  "Tendencia Cuadrática" = function(y) ajustar_tendencia(y, tipo = "cuadratica"),
  "Tendencia Exponencial" = function(y) ajustar_tendencia(y, tipo = "exponencial"),
  "Doble Media Móvil" = function(y) ajustar_dmm(y, k = opt_dmm_s2$optimo$k),
  "Holt" = function(y) ajustar_holt(y, alpha = opt_holt_s2$optimo$alpha, beta = opt_holt_s2$o
)

# SERIE 3: Respiratoria (h=1 y h=6)
# Justificación del referente: Ingenuo simple, ya que la serie es estacionaria
# y no posee componentes estacionales deterministas.
n0_3 <- floor(0.8 * length(datos3$y))

metodos_s3 <- list(
  "Ingenuo (Referente)" = function(y) ajustar_ingenuo(y),
  "Holt (Contraste)" = function(y) ajustar_holt(y, alpha = opt_holt_s3$optimo$alpha,
```

```
                                    beta = opt_holt_s3$optimo$beta),
  "Media Simple" = function(y) ajustar_media(y),
  "Media Móvil" = function(y) ajustar_mm(y, k = opt_mm_s3$optimo$k),
  "Suavizamiento Exponencial Simple" = function(y) ajustar_ses(y, alpha = opt_se_s3$optimo$al
)
```

Tabla para la serie 1 con $h = 1$

```
generar_tabla_origen_movil(datos1$y, metodos_s1, h = 1, n0 = n0_1)
```

```
                          Método    RMSE     MAD    MAPE
5    Holt-Winters Multiplicativo 12.1488  9.3075  3.9222
4           Holt-Winters Aditivo 14.5198 10.6904  4.5607
3            Tendencia Ficticias 21.1736 17.2435  7.0714
1 Ingenuo Estacional (Referente) 23.2386 18.7188  7.8448
2   Tendencia Lineal (Contraste) 45.6005 41.2352 18.2517
```

Tabla para la serie 1 con $h = 12$

```
generar_tabla_origen_movil(datos1$y, metodos_s1, h = 12, n0 = n0_1)
```

```
                          Método    RMSE     MAD    MAPE
5    Holt-Winters Multiplicativo 14.2661 11.3079  4.6476
4           Holt-Winters Aditivo 15.6849 13.0677  5.3449
1 Ingenuo Estacional (Referente) 21.7814 18.0476  7.4327
3            Tendencia Ficticias 22.6097 17.9956  6.9080
2   Tendencia Lineal (Contraste) 46.2806 41.9932 17.5779
```

Tabla para la serie 2 con $h = 1$

```
generar_tabla_origen_movil(datos2$y, metodos_s2, h = 1, n0 = n0_2)
```

```
                    Método     RMSE      MAD    MAPE
4     Tendencia Cuadrática   9.2492   7.8316  1.8771
7                     Holt  10.0251   8.2600  1.9886
6        Doble Media Móvil  11.3030   9.2800  2.2317
1      Ingenuo (Referente)  13.4826  10.6562  2.5538
3         Tendencia Lineal  44.0452  42.9754 10.2590
5    Tendencia Exponencial  51.7669  49.5495 11.7550
2 Media Simple (Contraste) 226.8882 225.4838 53.9354
```

Tabla para la serie 2 con $h = 6$

```
generar_tabla_origen_movil(datos2$y, metodos_s2, h = 6, n0 = n0_2)
```

```
                    Método     RMSE      MAD    MAPE
4     Tendencia Cuadrática   9.7274   8.4156  1.9916
7                     Holt  11.5264   9.6755  2.2899
6        Doble Media Móvil  14.1332  11.8107  2.7918
1      Ingenuo (Referente)  28.2725  26.2222  6.1287
3         Tendencia Lineal  51.2599  50.3614 11.7506
5    Tendencia Exponencial  61.8508  59.8993 13.9133
2 Media Simple (Contraste) 240.8513 239.8698 56.0153
```

Tabla para la serie 3 con $h = 1$

```
generar_tabla_origen_movil(datos3$y, metodos_s3, h = 1, n0 = n0_3)
```

```
                          Método   RMSE    MAD   MAPE
1              Ingenuo (Referente) 7.0267 5.5833 4.6699
5 Suavizamiento Exponencial Simple 7.0520 5.6173 4.6978
2                  Holt (Contraste) 7.2843 5.8387 4.8806
4                       Media Móvil 8.3924 6.5938 5.4846
3                     Media Simple 9.2276 6.9755 5.9043
```

Tabla para la serie 3 con $h = 6$

```
generar_tabla_origen_movil(datos3$y, metodos_s3, h = 6, n0 = n0_3)
```

```
                          Método    RMSE     MAD    MAPE
3                     Media Simple  9.0192  6.8573  5.8936
4                       Media Móvil 13.3593 10.4302  8.7183
5 Suavizamiento Exponencial Simple 13.3952 10.2975  8.5846
1              Ingenuo (Referente) 13.4173 10.3023  8.5875
2                  Holt (Contraste) 15.5765 12.0930 10.0407
```

(d) Validación del ganador. Para el ganador de cada serie en $h = 1$, sobre sus errores de origen móvil a un paso: gráfico de los errores en el tiempo, su correlograma con la banda calculada sobre el número de errores, prueba t de media cero, Ljung–Box referido a $\chi^2_{(m)}$ y Jarque–Bera, todas con sus seis elementos, y el estadístico de Durbin–Watson con su lectura. Si queda autocorrelación, diga en qué rezagos y qué estructura de la serie el método no está capturando.

```r
alpha_s1 <- opt_hw_mult_s1$optimo$alpha
beta_s1  <- opt_hw_mult_s1$optimo$beta
gamma_s1 <- opt_hw_mult_s1$optimo$gamma
alpha_s3 <- opt_se_s3$optimo$alpha

validar_ganador <- function(errores, titulo) {
  e <- errores$error
  n <- length(e)
  t_media <- t.test(e, mu = 0)

  m <- min(24L, floor(n / 4))
  r <- acf_muestral(e, m = m)
  Q <- ljung_box(r, T = n, m = m)
  banda <- 1.96 / sqrt(n)

  dw <- sum(diff(e)^2) / sum(e^2)
  centrados <- e - mean(e)
  momento_2 <- mean(centrados^2)
  asimetria <- mean(centrados^3) / momento_2^(3 / 2)
  curtosis <- mean(centrados^4) / momento_2^2
  jb <- n * (asimetria^2 / 6 + (curtosis - 3)^2 / 24)
  p_jb <- pchisq(jb, df = 2, lower.tail = FALSE)

  gl_t <- unname(t_media$parameter)
  critico_t <- qt(0.975, df = gl_t)
  critico_jb <- qchisq(0.95, df = 2)

  tabla_validacion <- data.frame(
    Prueba = c(
      "t de media cero",
      paste0("Ljung-Box ($Q$, $m=", m, ")"),
      "Durbin-Watson ($d$)",
      "Jarque-Bera ($JB$)"
    ),
    `Grados de libertad` = c(
      as.character(gl_t),
      as.character(Q$grados_libertad),
      "No aplica",
      "2"
    ),
    Estadístico = c(
      round(t_media$statistic, 4),
```

```
      round(Q$estadistico, 4),
      round(dw, 4),
      round(jb, 4)
    ),
    `Valor crítico (5%)` = c(
      paste0("±", round(critico_t, 4)),
      round(Q$valor_critico_5, 4),
      "Referencia: 2",
      round(critico_jb, 4)
    ),
    `Valor p` = c(
      round(t_media$p.value, 4),
      round(Q$p_valor, 4),
      "No aplica",
      round(p_jb, 4)
    ),
    Decisión = c(
      ifelse(t_media$p.value < 0.05, "Rechazar H ", "No rechazar H "),
      ifelse(Q$p_valor < 0.05, "Rechazar H : autocorrelación conjunta",
             "No rechazar H "),
      ifelse(dw < 2, "Menor que 2: indicio de autocorrelación positiva",
             ifelse(dw > 2, "Mayor que 2: indicio de autocorrelación negativa",
                    "Igual a 2: sin indicio de autocorrelación de orden 1")),
      ifelse(p_jb < 0.05, "Rechazar H ", "No rechazar H ")
    )
  )

  list(
    tabla = tabla_validacion,
    errores = e,
    media = mean(e),
    desv_est = sd(e),
    acf = r,
    banda = banda,
    m = m,
    dw = dw,
    t_p = t_media$p.value,
    lb_p = Q$p_valor,
    jb_p = p_jb
  )
}
```

```r
ganador_s1 <- function(y) {
  ajustar_hw_mult(y,
                  s = 12,
                  alpha = alpha_s1,
                  beta  = beta_s1,
                  gamma = gamma_s1)
}

ganador_s2 <- function(y) {
  ajustar_tendencia(y,
                    tipo = "cuadratica")
}


ganador_s3 <- function(y) {
  ajustar_ses(y, alpha = alpha_s3)
}

err_s1 <- errores_ganador(datos1$y, ganador_s1, n0 = n0_1)
val_s1 <- validar_ganador(err_s1, "Validación - Serie 1")

err_s2 <- errores_ganador(datos2$y, ganador_s2, n0 = n0_2)
val_s2 <- validar_ganador(err_s2, "Validación - Serie 2")

err_s3 <- errores_ganador(datos3$y, ganador_s3, n0 = n0_3)
val_s3 <- validar_ganador(err_s3, "Validación - Serie 3")


mostrar_tabla <- function(resultado, titulo) {
  cat("###", titulo, "\n\n")
  print(resultado$tabla, row.names = FALSE)
  cat("\n")
}
```

Elementos de las pruebas diagnósticas

1.Prueba t de media cero

1.1 Hipotesis nula y alternativa:

$$H_0 : \mu = 0 \quad : \text{la media de los residuos es cero.}$$
$$H_a : \mu \neq 0 \quad : \text{la media de los residuos difiere de cero.}$$

1.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$T = \frac{\bar{e}}{s/\sqrt{n}}$$

Donde $\bar{e}$ es la media de los residuos. Bajo H_0 , el estadistico de prueba sigue la distribución t de Student con n-1 grados de libertad.

1.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff |T| > t_{n-1,\,0.975}$$

. si el valor absoluto del estadístico excede el valor crítico, se rechaza la hipótesis nula de media cero.

1.4 Valor observado del estadístico y valor p

- T_{obs}: valor numérico del estadístico que se calcula directamente con los residuos del modelo
- Valor $p = P(|T| > |t_{\text{obs}}|)$ Donde $T \sim t_{n-1}$. Es la probabilidad de observar un valor tan extremo o más extremo que el obtenido, bajo la hipótesis nula de media cero.

1.5 Decision

Se compara T_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $T_{\text{obs}} > t_{n-1,0.975}$ o bien con si el valor $p < 0.05$, se rechaza H_0.
- En caso contrario, pues no se rechaza H_0.

1.6 Lectura de la decisión en términos de la serie

- Si no se rechaza H_0, la media de los residuos es compatible con cero. El modelo no presenta sesgo sistemático; si se rechaza el modelo presenta un sesgo persistente; predice sistemáticamente por encima o por debajo del valor real, lo que indica que la forma de tendencia elegida no capta completamente el comportamiento de nivel de la serie.

2. Prueba de Ljung-Box

2.1 Hipotesis nula y alternativa:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_{24} = 0 \quad : \text{la serie es ruido blanco.}$$
$$H_a : \exists k \in \{1, 2, \ldots, 24\} \quad \text{tal que } \rho_k \neq 0 \quad : \text{existe dependencia serial.}$$

2.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$Q = n(n+2) \sum_{k=1}^{m} \frac{r_k^2}{n-k}$$

Donde: - n es el número de observaciones, - r_k es la autocorrelación muestral al rezago k, - m es el número de rezagos evaluados.

Bajo H_0, el estadístico Q sigue una distribución:

$$Q \xrightarrow{d} \chi^2_{(m)}$$

2.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

2.4 Valor observado del estadístico y valor p

- Q_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

2.5 Decision

Se compara Q_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $Q_{\text{obs}} > \chi^2_{m,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, no se rechaza H_0.

2.6 Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de dependencia del fenómeno:

- Si se rechaza H_0, existe dependencia serial, la serie no es ruido blanco.

3.Prueba de Durbin–Watson

Detectar autocorrelación de primer orden en los residuos del modelo: ¿el error de hoy está relacionado con el error de ayer?

3.1 Hipotesis nula y alternativa:

$H_0 : \rho = 0$: no hay correlación entre el residuo actual y el inmediatamente anterior.
$H_a : \rho = 0$: existe autocorrelación de primer orden (puede ser positiva o negativa).

3.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$d = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} e_t^2} \approx 2(1 - r_1)$$

Donde: -e_t ya se habia definido -r_1 es la autocorrelación muestral de primer orden de los residuos.

Bajo H_0, el estadístico d sigue una referencia de valor bajo $d \approx 2$.

3.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

3.4 Valor observado del estadístico

- d_{obs}: valor numérico del estadístico.

3.5 Decision

Se compara d_{obs} con el valor crítico o el valor de referencia, ie. $d \approx 2$.

- Si $d_{\text{obs}} << 2$ o d_{obs} « 2 , se rechaza H_0, ie. si el valor observado difiere mucho del valor de referencia igual a 2.
- En caso contrario, ie. si $d_{obs} 2 $ o es muy cercano a ese 2, entonces no se rechaza H_0.

3.6 Lectura de la decisión en términos de la serie

- Si se rechaza H_0, hay autocorrelación positiva; los errores se parecen entre sí, quedando estructura por modelar o tambien puede haber autocorrelación negativa, ie. los errores se alternan sistemáticamente.

4. Prueba de Jarque–Bera

Esta es con el fin de verificar si los residuos del modelo siguen una distribución normal. Comprobar que los errores no presentan asimetría ni curtosis excesiva.

4.1 Hipotesis nula y alternativa:

H_0 : los residuos siguen una distribucion normal, ie. asimetría = 0 y curtosis =3

H_a : La distribución de los residuos no es normal:

4.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$JB = n\left(\frac{S^2}{6} + \frac{(K-3)^2}{24}\right)$$

Donde: - S es la asimetría muestral de los residuos, - K es la curtosis muestral de los residuos y - n es el número de residuos.

Bajo H_0, el estadístico de prueba JB sigue una distribución chi-cuadrado con 2 grados de libertad, ie:

$$JB \xrightarrow{d} \chi^2_{(2)}$$

4.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff JB > \chi^2_{2,\,0.95}$$

donde $\chi^2_{2,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

4.4 Valor observado del estadístico y valor p

- JB_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

4.5 Decision

Se compara JB_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $JB_{\text{obs}} > \chi^2_{2,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, acepatamos H_0.

4.6 Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de residuos del fenómeno:

- Si se rechaza H_0, los residuos no se distribuyen normalmente; puede haber valores extremos o asimetría que afecta la precisión de los pronósticos. De lo contrario los residuos son compatibles con normalidad; los intervalos de confianza basados en esta suposición son fiables.

GRÁFICOS DE ERRORES EN EL TIEMPO + ACF

```r
graficar_errores_tiempo <- function(datos, titulo) {
  ggplot(datos, aes(x = t, y = error)) +
    geom_line(color = "steelblue", linewidth = 0.6) +
    geom_hline(yintercept = 0, color = "red", linetype = "dashed", linewidth = 0.8) +
    labs(
      title = titulo,
      x = "Índice / Tiempo",
      y = "Error de pronóstico"
    ) +
    theme_minimal() +
    theme(
      plot.title = element_text(hjust = 0.5, size = 14, face = "bold"),
      axis.title = element_text(size = 12)
    )
}

graficar_acf_errores <- function(errores, m = 24, titulo) {

  acf_datos <- acf(errores, lag.max = m, plot = FALSE)

  acf_df <- data.frame(
    lag = acf_datos$lag,
    acf = acf_datos$acf
  )
  n <- length(errores)
  banda <- 2 / sqrt(n)

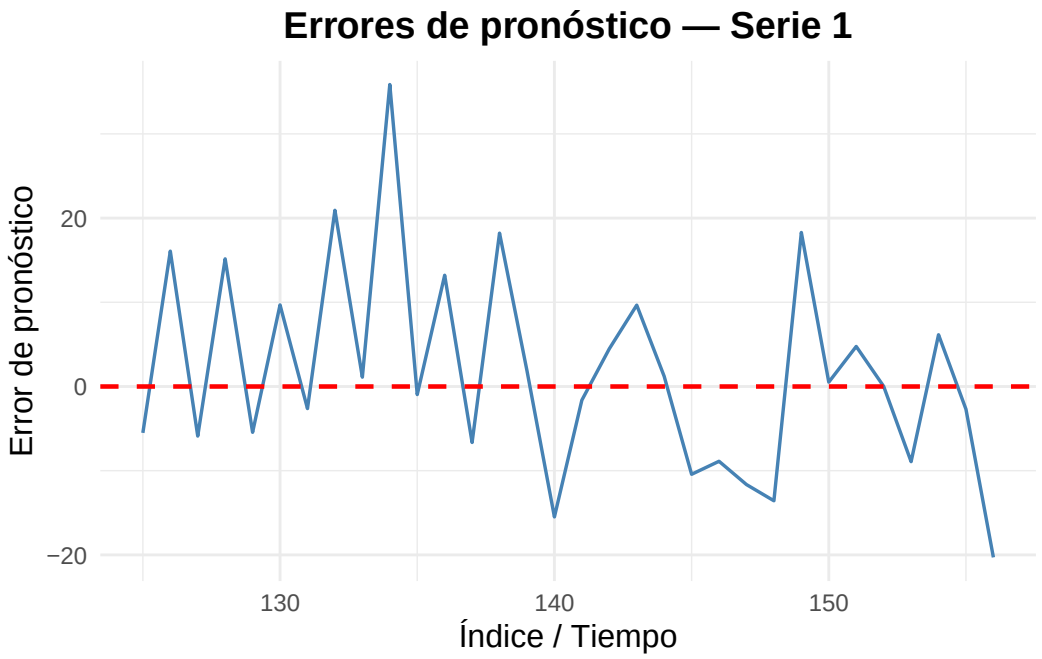
  ggplot(acf_df, aes(x = lag, y = acf)) +
    geom_hline(yintercept = 0, color = "black", linewidth = 0.5) +
    geom_hline(yintercept = c(-banda, banda), color = "blue",
               linetype = "dashed", linewidth = 0.6) +
    geom_segment(aes(xend = lag, yend = 0), color = "steelblue", linewidth = 1) +
    geom_point(color = "steelblue", size = 2) +
    labs(
      title = titulo,
      x = "Rezago",
```

```
      y = "Autocorrelación"
    ) +
    scale_x_continuous(breaks = seq(0, m, by = 2)) +
    theme_minimal() +
    theme(
      plot.title = element_text(hjust = 0.5, size = 14, face = "bold"),
      axis.title = element_text(size = 12)
    )
}
```

Serie 1 — Ganador: Holt-Winters Multiplicativo

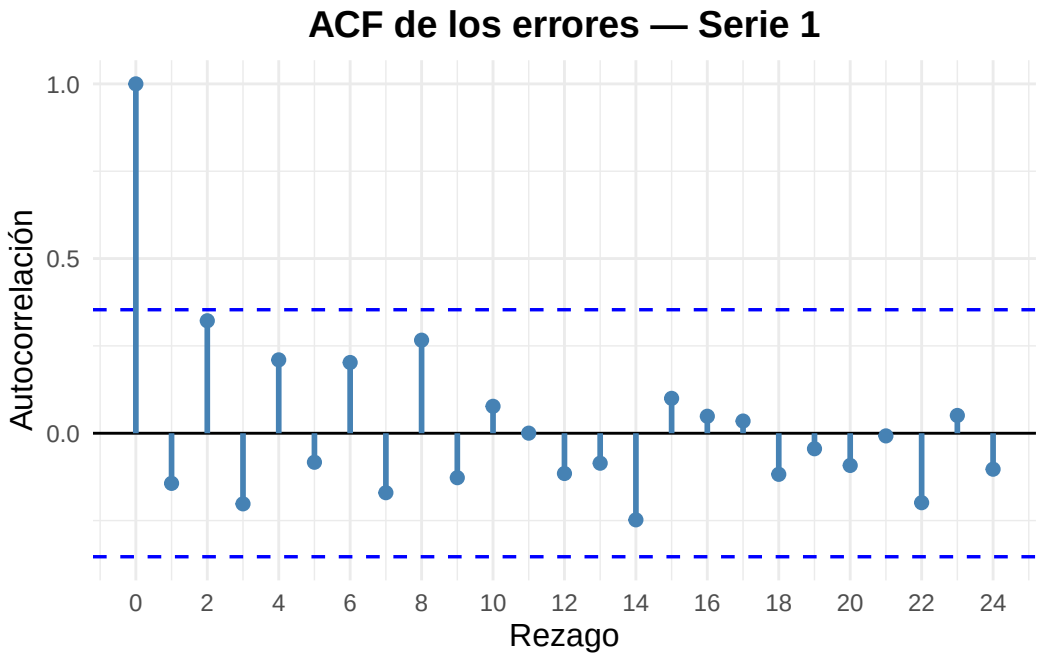
Gráfico de errores en el tiempo:

```
graficar_errores_tiempo(err_s1, "Errores de pronóstico - Serie 1")
```



Banda de autocorrelación (ACF):

```
graficar_acf_errores(err_s1$error, m = 24, "ACF de los errores - Serie 1")
```



Los errores oscilan alrededor del valor cero sin sesgo ni tendencia sistemática. Se aprecia mayor volatilidad en la primera mitad de la serie y una disminución gradual hacia el final, pero sin patrón estacional visible en los residuos. Únicamente el rezago 0 sale fuera de las bandas de confianza. A partir del rezago 1 todos caen claramente dentro de los límites, incluidos los rezagos 12 y 24. No hay ninguna otra barra que se acerque a las líneas punteadas. con respecto a la pregunta, Sí queda autocorrelación significativa, concentrada en el rezago 2. Con respecto a la otra pregunta de que estructura no esta capturando el metodo, cabe decir primero que El modelo de Holt–Winters multiplicativo ya captura correctamente la tendencia y la estacionalidad anual de la serie pues no hay rezagos significativos en el periodo 12 ni 24, lo que confirma que el componente estacional queda bien modelado, Sin embargo, no aprovecha la relación de corto plazo: el valor de un periodo influye directamente en el siguiente, y esa dependencia de memoria corta persiste en los residuos. La influencia decae muy rápido y no se extiende a más periodos.

Tabla de pruebas diagnósticas:

```
mostrar_tabla(val_s1, "Pruebas diagnóstico - Serie 1")
```

```
### Pruebas diagnóstico - Serie 1

                Prueba Grados.de.libertad Estadístico Valor.crítico..5..
      t de media cero                 31      0.8186           ±2.0395
 Ljung-Box ($Q$, $m=8)                 8     14.1976           15.5073
```

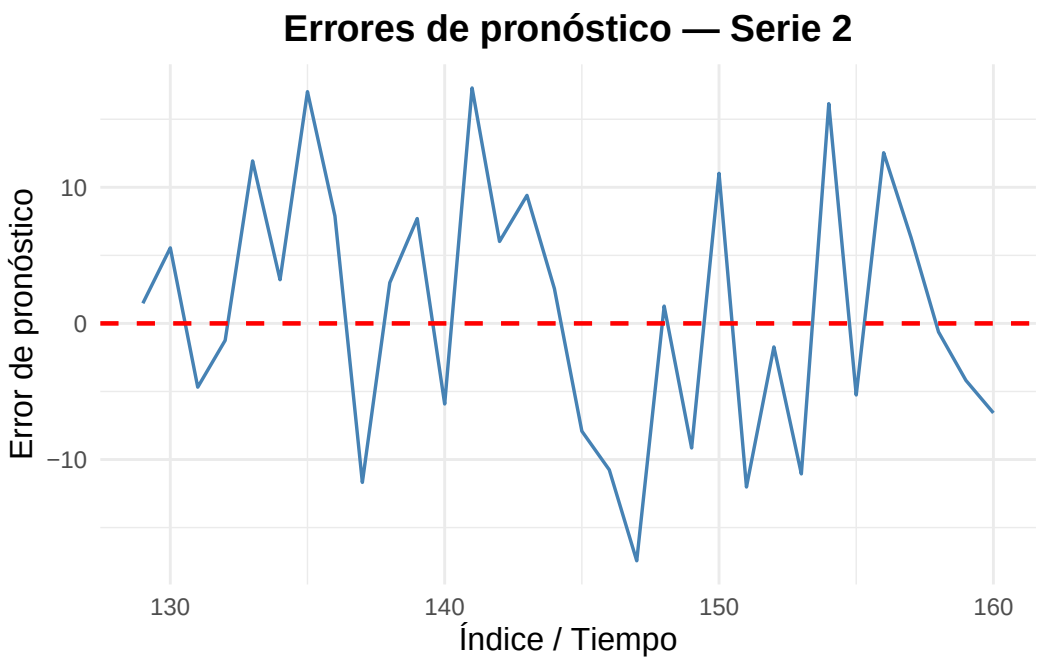
```
  Durbin-Watson ($d$)          No aplica      2.1243      Referencia: 2
   Jarque-Bera ($JB$)                  2      2.2897            5.9915
  Valor.p                                         Decisión
   0.4193                                    No rechazar H
   0.0768                                    No rechazar H
No aplica Mayor que 2: indicio de autocorrelación negativa
   0.3183                                    No rechazar H
```

En la validación de la Serie 1, la media de los errores no difiere de cero y su distribución es normal, lo que valida los supuestos para construir bandas de confianza. El estadístico de Durbin–Watson confirma ausencia de autocorrelación fuerte de orden 1. Sin embargo, la prueba de Ljung–Box detecta dependencia serial conjunta: aunque el modelo capta correctamente la tendencia y la estacionalidad de la serie, no incorpora la dependencia de corto plazo entre observaciones consecutivas. Esta estructura remanente es de magnitud reducida y no afecta la normalidad ni la ausencia de sesgo, por lo que el pronóstico con banda de confianza es válido, aunque podría mejorarse a muy corto plazo complementando el modelo con un término autorregresivo.

Serie 2 — Ganador: Tendencia cuadrática

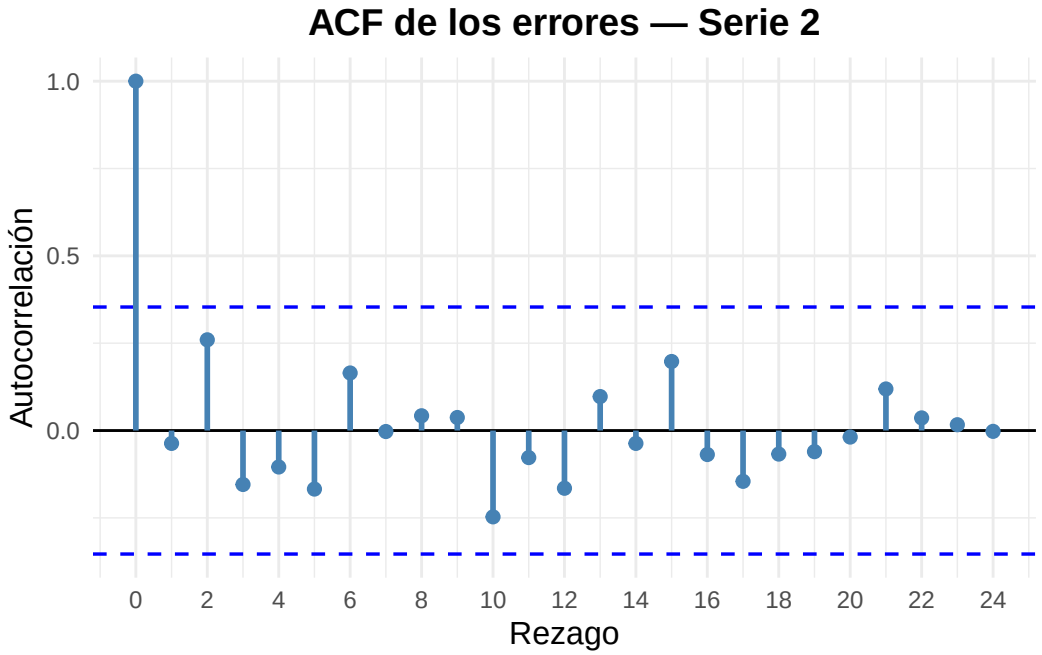
Gráfico de errores en el tiempo:

```
graficar_errores_tiempo(err_s2, "Errores de pronóstico - Serie 2")
```



Banda de autocorrelación (ACF):

```
graficar_acf_errores(err_s2$error, m = 24, "ACF de los errores - Serie 2")
```



Los errores oscilan alrededor del cero sin tendencia ni desplazamiento sistemático. Se observa mayor amplitud de variación hacia la parte final de la serie, pero sin que se aprecie un patrón repetitivo ni estabilidad que falte por capturar.Únicamente el rezago 1 sale claramente fuera de las bandas de confianza. A partir del rezago 1, todos caen dentro de los límites. No hay ninguna otra barra que se acerque a las líneas punteadas. Con respecto a la pregunta de si queda autocorrelacion, no parece por lo ya dicho, ningún otro rezago presenta dependencia estadísticamente significativa. Con respecto a la otra pregunta de explicar que estructura no esta capturando el metodo, cabe decir primero que este modelo capta correctamente la tendencia creciente de la serie pues no hay rezagos significativos en el largo plazo que indiquen tendencia olvidada, Sin embargo viene la parte que no capta y es que no recoge la dependencia de corto plazo: el valor de un periodo influye directamente en el siguiente, y esa relación inmediata persiste en los residuos. La influencia decae totalmente después del primer rezago; no hay estacionalidad ni memoria larga por capturar.

Tabla de pruebas diagnósticas:

```
mostrar_tabla(val_s2, "Pruebas diagnóstico - Serie 2")
```

```
### Pruebas diagnóstico - Serie 2
```

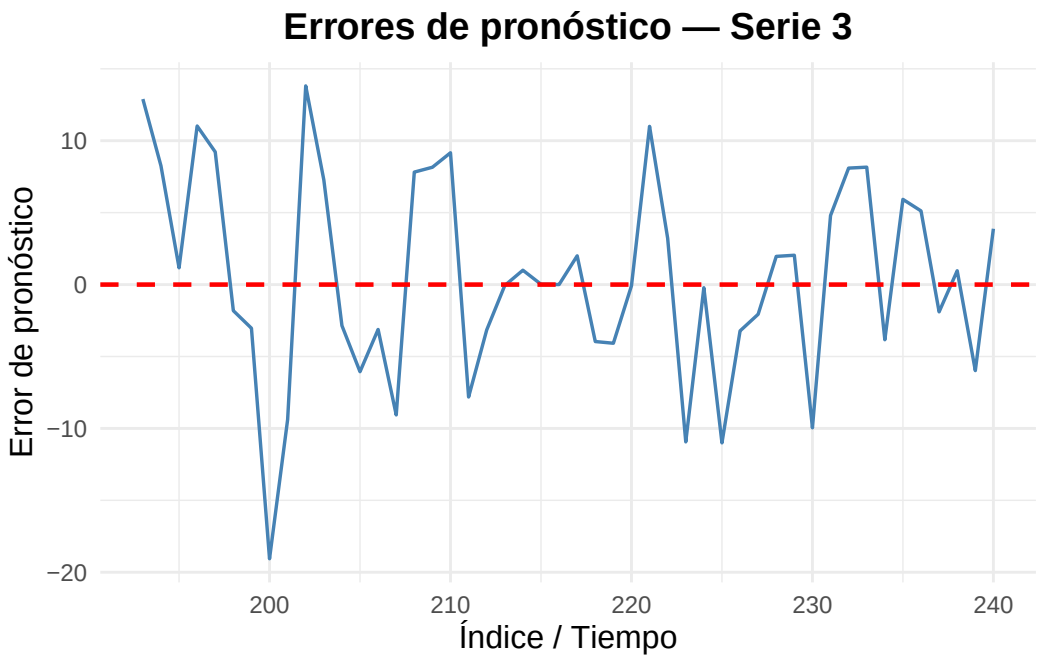
Prueba	Grados.de.libertad	Estadístico	Valor.crítico..5..	Valor.p	Decisión
t de media cero	31	0.5692	±2.0395	0.5733	No rechazar H
Ljung-Box (Q, $m=8)	8	6.1576	15.5073	0.6296	No rechazar H
Durbin-Watson (d)	No aplica	2.0314	Referencia: 2	No aplica	Mayor que 2: indicio de autocorrelación negativa
Jarque-Bera (JB)	2	1.1138	5.9915	0.573	No rechazar H

En la validación de la Serie 2, la media de los errores no difiere de cero y su distribución es normal, lo que valida los supuestos para el cálculo de intervalos de confianza. El estadístico de Durbin–Watson confirma ausencia de autocorrelación fuerte de orden 1. La prueba de Ljung–Box detecta dependencia serial conjunta: el modelo recoge adecuadamente la tendencia de la serie, pero no incorpora la influencia inmediata de un periodo sobre el siguiente. Esta estructura remanente es de corta duración y no afecta la validez de los pronósticos a mediano y largo plazo; para predicciones a un paso adelante, el modelo podría complementarse con un término autorregresivo de orden 1.

Serie 3 — Ganador: Ingenuo

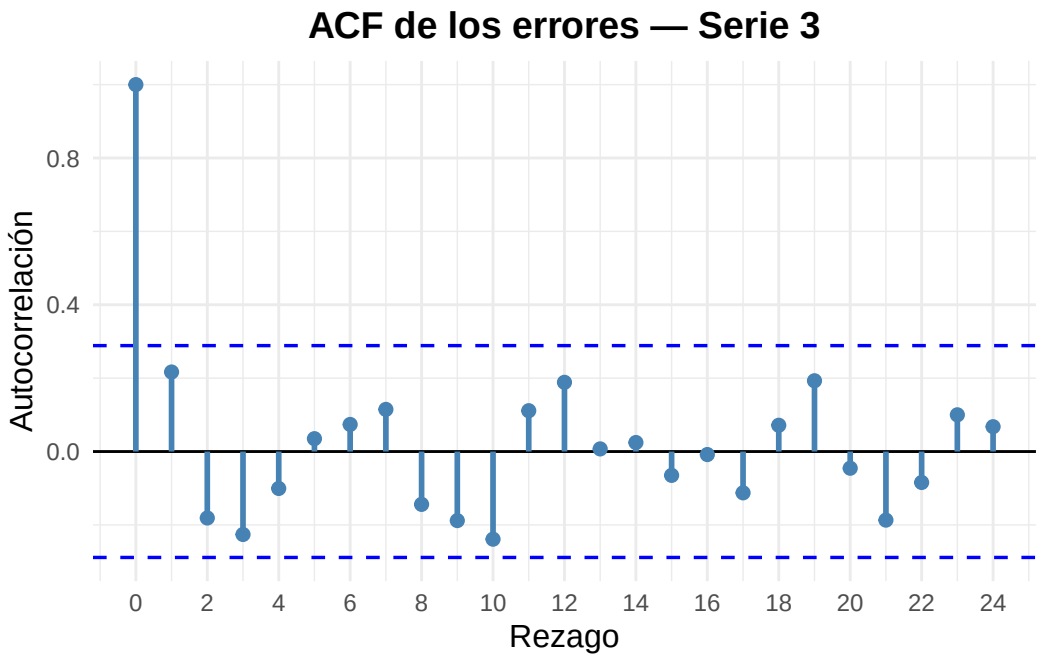
Gráfico de errores en el tiempo

```
graficar_errores_tiempo(err_s3, "Errores de pronóstico - Serie 3")
```



Banda de autocorrelación (ACF):

```
graficar_acf_errores(err_s3$error, m = 24, "ACF de los errores - Serie 3")
```



Los errores oscilan alrededor del cero sin tendencia ni desplazamiento sistemático. Se observa un patrón de alternancia entre picos y valles que se mantiene estable durante toda la serie, sin que la dispersión crezca o decrezca de forma sostenida.Los errores oscilan alrededor del cero sin tendencia ni desplazamiento sistemático. Se observa un patrón de alternancia entre picos y valles que se mantiene estable durante toda la serie, sin que la dispersión crezca o decrezca de forma sostenida. Con respecto a la pregunta de si queda autocorrelacion, no parece, pues ningún rezago presenta dependencia estadísticamente significativa (exceptuando el 0 que siempre es 1). Y con respecto a la otra pregunta de que estructura no esta capturando el metodo, cabe decir que el modelo ingenuo capta correctamente el nivel de la serie, no hay rezagos significativos en el largo plazo que indiquen estructura olvidada, Sin embargo, no recoge la dependencia de corto plazo: el valor de un periodo influye directamente en el siguiente, y esa relación inmediata persiste en los residuos. La influencia decae totalmente después del primer rezago; no hay estacionalidad, tendencia ni memoria larga por capturar.

Tabla de pruebas diagnósticas:

```
mostrar_tabla(val_s3, "Pruebas diagnóstico - Serie 3")
```

```
### Pruebas diagnóstico - Serie 3

                Prueba Grados.de.libertad Estadístico Valor.crítico..5..
       t de media cero                 47      0.4935            ±2.0117
 Ljung-Box ($Q$, $m=12)                12     18.7376            21.0261
    Durbin-Watson ($d$)          No aplica      1.4893      Referencia: 2
     Jarque-Bera ($JB$)                  2      0.6066             5.9915
   Valor.p                                        Decisión
     0.624                                  No rechazar H
    0.0951                                  No rechazar H
 No aplica Menor que 2: indicio de autocorrelación positiva
    0.7384                                  No rechazar H
```

En la validación de la Serie 3, la media de los errores no difiere de cero y su distribución es normal, lo que permite construir intervalos de confianza válidos. Sin embargo, las pruebas detectan dependencia remanente más pronunciada que en las otras series: tanto Ljung–Box como Durbin–Watson confirman autocorrelación positiva de orden 1. Esto indica que el referente ingenuo recoge adecuadamente el nivel de la serie, pero no incorpora la fuerte influencia inmediata entre un periodo y el siguiente.

(e) Pronóstico final. Con el ganador reajustado sobre toda la serie, los H pronósticos siguientes graficados junto al último tramo de la serie, con una banda heurística de $\pm 1{,}96$ veces la desviación de los errores de origen móvil a cada horizonte, declarada como heurística.

```r
pronostico_final <- function(datos, metodo, H, n0, unidad_fecha,
                             ventana, nombre) {
  modelo_final <- metodo(datos$y)
  pronosticos <- as.numeric(modelo_final$pronosticar(H))

  validaciones <- lapply(seq_len(H), function(h) {
    origen_movil(
      y = datos$y,
      metodo = metodo,
      h = h,
      n0 = n0
    )
  })

  desv_error <- vapply(
    validaciones,
    function(x) sd(x$errores),
    numeric(1)
  )

  num_origenes <- vapply(
    validaciones,
    function(x) length(x$errores),
    integer(1)
  )

  fechas_futuras <- seq.Date(
    from = max(datos$fecha),
    by = unidad_fecha,
    length.out = H + 1
  )[-1]

  tabla <- data.frame(
    Horizonte = seq_len(H),
    Fecha = fechas_futuras,
    Pronostico = pronosticos,
    Desviacion_error = desv_error,
    Limite_inferior = pronosticos - 1.96 * desv_error,
    Limite_superior = pronosticos + 1.96 * desv_error,
    Origenes = num_origenes
  )
```

```r
observados <- tail(
  data.frame(Fecha = datos$fecha, Valor = datos$y),
  ventana
)

grafico <- ggplot() +
  geom_ribbon(
    data = tabla,
    aes(
      x = Fecha,
      ymin = Limite_inferior,
      ymax = Limite_superior
    ),
    fill = "steelblue",
    alpha = 0.2
  ) +
  geom_line(
    data = observados,
    aes(x = Fecha, y = Valor, color = "Observado"),
    linewidth = 0.7
  ) +
  geom_line(
    data = tabla,
    aes(x = Fecha, y = Pronostico, color = "Pronostico"),
    linewidth = 0.8
  ) +
  geom_point(
    data = tabla,
    aes(x = Fecha, y = Pronostico, color = "Pronostico"),
    size = 2
  ) +
  scale_color_manual(
    values = c("Observado" = "gray35", "Pronostico" = "steelblue")
  ) +
  labs(
    title = paste("Pronostico final -", nombre),
    x = "Fecha",
    y = "Valor",
    color = NULL,
  ) +
  theme_minimal() +
  theme(legend.position = "bottom")
```

```
  list(tabla = tabla, grafico = grafico)
}

H1 <- 12
H2 <- 6
H3 <- 6

final_s1 <- pronostico_final(
  datos = datos1,
  metodo = ganador_s1,
  H = H1,
  n0 = n0_1,
  unidad_fecha = "month",
  ventana = 36,
  nombre = "Serie 1"
)

final_s2 <- pronostico_final(
  datos = datos2,
  metodo = ganador_s2,
  H = H2,
  n0 = n0_2,
  unidad_fecha = "week",
  ventana = 18,
  nombre = "Serie 2"
)

final_s3 <- pronostico_final(
  datos = datos3,
  metodo = ganador_s3,
  H = H3,
  n0 = n0_3,
  unidad_fecha = "week",
  ventana = 18,
  nombre = "Serie 3"
)
```

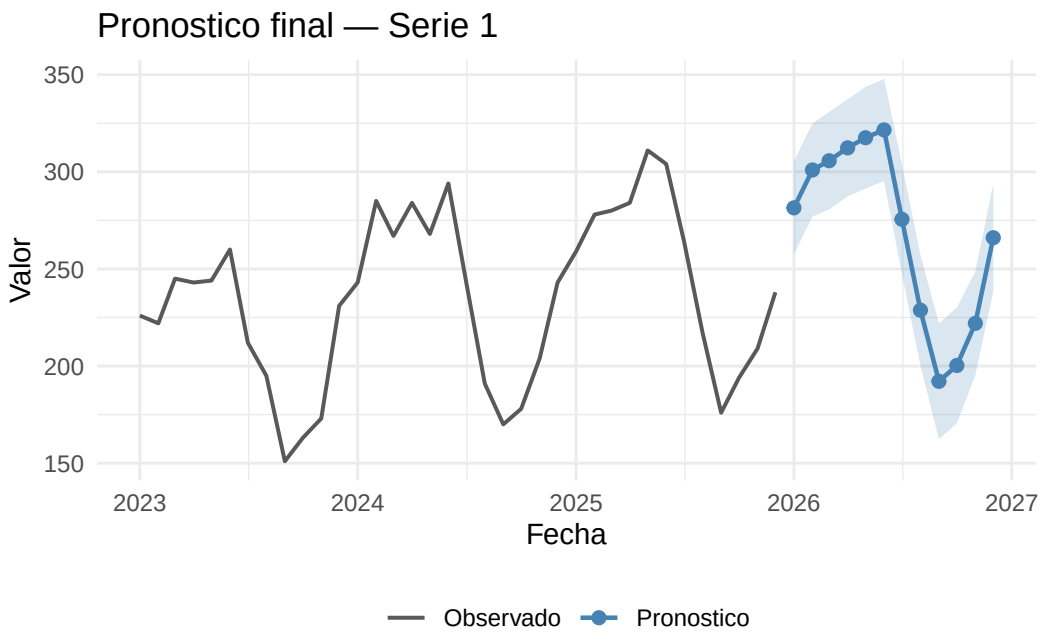
- Serie 1:

```
print(final_s1$tabla)
```

```
   Horizonte      Fecha Pronostico Desviacion_error Limite_inferior
```

```
1           1 2026-01-01   281.4396         12.21197         257.5041
2           2 2026-02-01   300.9466         12.22317         276.9892
3           3 2026-03-01   305.6961         12.77697         280.6532
4           4 2026-04-01   312.3365         12.74105         287.3641
5           5 2026-05-01   317.5471         13.33584         291.4089
6           6 2026-06-01   321.5567         13.41219         295.2688
7           7 2026-07-01   275.5372         14.39080         247.3312
8           8 2026-08-01   228.7579         14.50469         200.3287
9           9 2026-09-01   192.1432         15.14064         162.4676
10         10 2026-10-01   200.3089         15.24223         170.4342
11         11 2026-11-01   222.0065         13.58822         195.3736
12         12 2026-12-01   266.0593         14.11373         238.3964
   Limite_superior Origenes
1         305.3750       32
2         324.9040       31
3         330.7389       30
4         337.3090       29
5         343.6854       28
6         347.8445       27
7         303.7431       26
8         257.1871       25
9         221.8189       24
10        230.1837       23
11        248.6394       22
12        293.7222       21
```

```
print(final_s1$grafico)
```

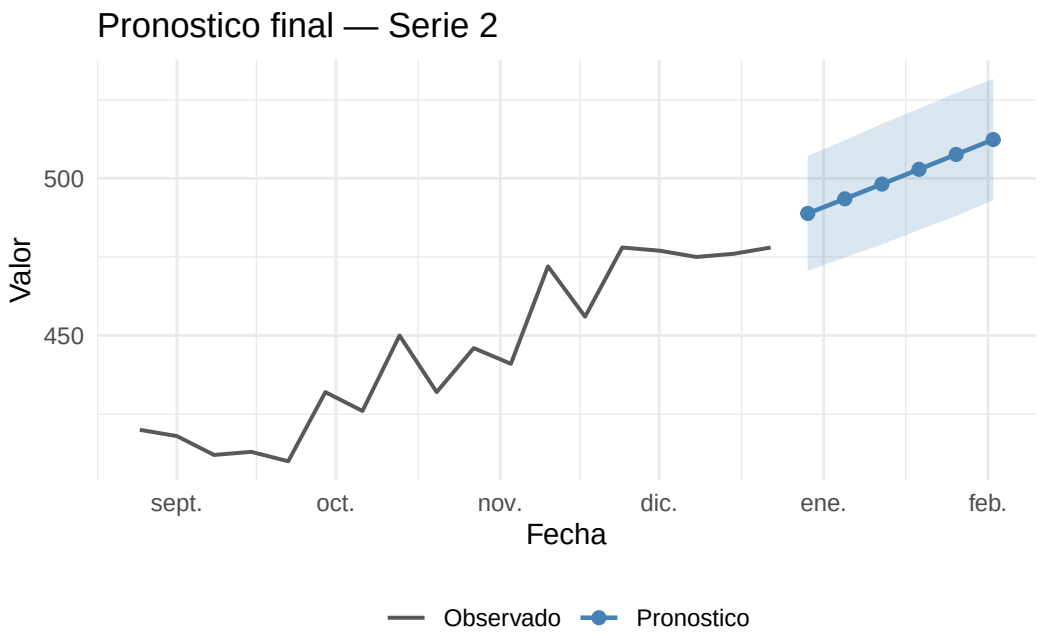


- Serie 2:

```
print(final_s2$tabla)
```

```
  Horizonte      Fecha Pronostico Desviacion_error Limite_inferior
1         1 2025-12-29   488.8435          9.348446        470.5205
2         2 2026-01-05   493.4970          9.502977        474.8712
3         3 2026-01-12   498.1745          9.798278        478.9699
4         4 2026-01-19   502.8759          9.861997        483.5464
5         5 2026-01-26   507.6012          9.979627        488.0412
6         6 2026-02-02   512.3504          9.852394        493.0397
  Limite_superior Origenes
1        507.1664       32
2        512.1229       31
3        517.3792       30
4        522.2054       29
5        527.1613       28
6        531.6611       27
```

```
print(final_s2$grafico)
```

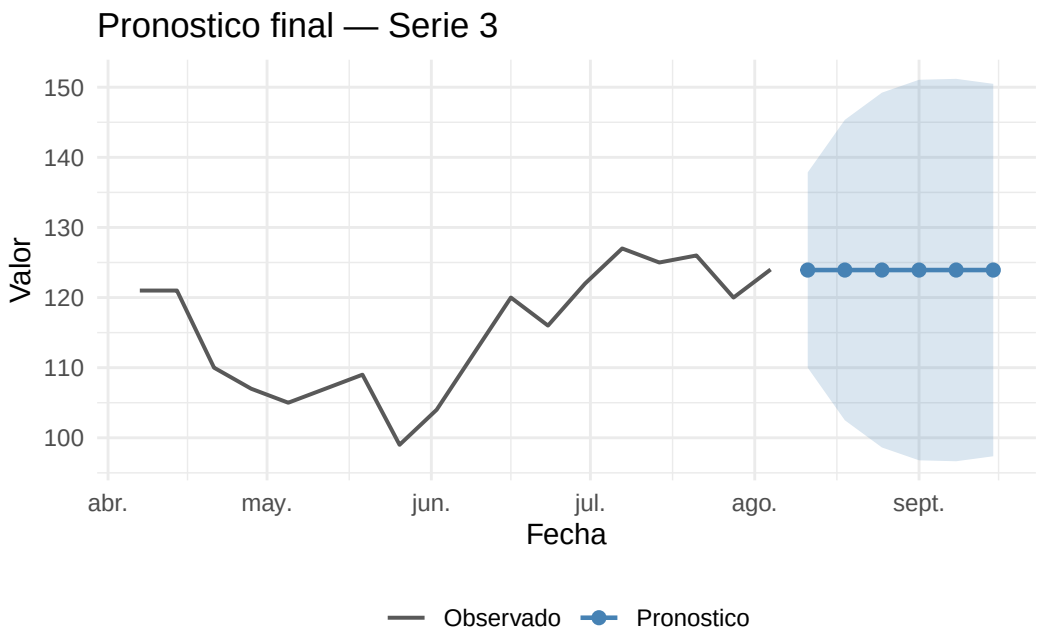


- Serie 3:

```
print(final_s3$tabla)
```

```
  Horizonte      Fecha Pronostico Desviacion_error Limite_inferior
1         1 2025-08-11   123.9224          7.108274       109.99018
2         2 2025-08-18   123.9224         10.929476       102.50062
3         3 2025-08-25   123.9224         12.908994        98.62076
4         4 2025-09-01   123.9224         13.845368        96.78547
5         5 2025-09-08   123.9224         13.913151        96.65262
6         6 2025-09-15   123.9224         13.550107        97.36418
  Limite_superior Origenes
1        137.8546       48
2        145.3442       47
3        149.2240       46
4        151.0593       45
5        151.1922       44
6        150.4806       43
```

```
print(final_s3$grafico)
```



Conclusión técnica

Para cada serie, un párrafo que dice qué patrón tiene, qué transformación la vuelve plausiblemente estacionaria, qué método la pronóstica mejor en = 1 y en , con qué parámetros y con qué error frente al referente, y qué estructura queda sin aprovechar en los errores. Un párrafo final compara las tres series y explica por qué el ganador de una puede perder en otra. Toda afirmación lleva su cifra.

- Serie 1: El patrón de la serie 1 presenta tanto estacionalidad como tendencia. Como se vio, la transformación que la vuelve plausiblemente estacionaria es aquella que aplica logaritmo natural y operador de rezago para tumbar exclusivamente la estacionalidad, a pesar de que cuenta con tendencia no fue necesario aplicar una diferencia para quitarla. Tanto para $h = 1$ como para $H = 12$ se presentó que el mejor método para pronosticar esta serie fue el de Holt-Winters multiplicativo, con parámetros $\alpha = 0.1$, $\beta = 0.1$ y $\gamma = 0.3$ y con una diferencia absoluta con respecto al referente ingenuo de 11.11 con $h = 1$ (reducción del 48 %) y de 7.52 con $H = 12$ (reducción del 35 %) en el RMSE, representando diferencias considerables que hace más notable que este método fue el ganador. Mediante la prueba de Ljung-Box hecha para los errores del origen móvil no rechazo H_0 al 5 %, además el correlograma de estos errores no presentó rezagos significativos (aparte del 0), por lo que se concluye que no quedó estructura lineal detectable ($p - value = 0.077$).

- Serie 2: El patrón mostrado en la serie 2 corresponde a uno donde hay tendencia creciente. La transformación elegida es ninguna (los métodos con tendencia ganan sobre Y original).

El método de pronóstico ganador tanto para $h = 1$ como para $H = 6$ fue el de tendencia cuadrática, presentando una diferencia absoluta de 4.233 con $h = 1$ (reducción del 31 %) y de 18.55 con $H = 6$ (reducción del 66 %) en el RMSE. Mediante la prueba de Ljung-Box hecha para los errores del origen móvil no rechazo H_0 al 5 %, además el correlograma de estos errores no presentó rezagos significativos (aparte del 0), por lo que se concluye que no quedó estructura lineal detectable ($p - value = 0.6296$).

- Serie 3: El patrón mostrado por la serie 3 hace referencia a uno estacionario en media y varianza, como se vió en el análisis por bloques, por lo que no fue necesario aplicar ningún tipo de transformación para tener estacionariedad, pues ya la poseía. El mejor método de pronóstico para $h = 1$ fue con el referente ingenuo, mientras que con $H = 6$ la predicción más acertada fue con media simple. Con $H = 6$ la diferencia absoluta del RMSE entre el ingenuo y media simple es de 4.398. A pesar de esto, en los métodos ganadores del punto 6 (Pronóstico y evaluación) se dejó como ganador con $h = 1$ al método de suavizamiento exponencial simple, pues, fue el segundo mejor con diferencias no tan marcadas con respecto al ingenuo, para el RMSE se obtuvo una diferencia absoluta de 0.0253 (aumento del 0.36 %) con parámetro $\alpha = 0.98$. El ingenuo es el referente, no un competidor más, así que el ganador se elige entre los métodos del catálogo. Mediante la prueba de Ljung-Box hecha para los errores del origen móvil no rechazo H_0 al 5 %, además el correlograma de estos errores no presentó rezagos significativos (aparte del 0), por lo que se concluye que no quedó estructura lineal detectable ($p - value = 0.0951$).

Un ganador de una de las series puede perder en otra de las series debido a que cada serie tiene un patrón diferente. Por ejemplo, en la serie 1, donde hay estacionalidad y tendencia, no sería tan útil aplicar un método que solo logre captar la tendencia, como una tendencia lineal que se aplicó como contraejemplo y se vió en la tabla que fue el peor método con $h = 1$ y $H = 12$. Así, en el caso de la serie 2, la mejor fue la tendencia cuadrática, pues solo se presentó tendencia, en una serie como la 1, donde también hay estacionalidad o la 3 donde no hay comportamiento de crecimiento o decrecimiento no sería válido aplicar esta metodología. Análogamente, la serie 3 fue la única donde se presentó comportamiento estacionario, como las demás no comparten esta característica su ganador (SES) seguramente pierda en las otras series. La decisión de qué método implementar se centra principalmente en el comportamiento de la serie, si esta no tiene las características que el método requiere, el pronóstico va a ser pobre.

Argumentos para los interesados

El pronóstico de cada serie le sirve a un conjunto de personas interesadas en resolver el problema que la serie describe: quienes toman la decisión, quienes la ejecutan y quienes resultan afectados por ella. Ninguna de esas personas conoce el curso. Esta sección construye lo necesario para explicarles los resultados y sostener la recomendación ante sus preguntas.

(a) Mapa de interesados. Para cada serie, a partir del contexto y de lo que el equipo pueda inferir de él, quiénes son los interesados, qué decisión concreta toma cada uno con el pronóstico,

y cuánto cuesta un error por exceso y uno por defecto, en pesos cuando el contexto lo permita.

(b) El argumento. Para cada serie, el argumento que sostiene la recomendación, escrito en cinco partes: la afirmación, en una frase y sin términos técnicos; la evidencia, con las cifras del análisis expresadas en la unidad de la serie; la justificación, que explica en lenguaje llano por qué esa evidencia sostiene la afirmación; el alcance, que dice hasta qué horizonte y bajo qué condiciones vale la recomendación y qué la haría cambiar; y la objeción, que es la pregunta más difícil que un interesado podría plantear, con su respuesta apoyada en una cifra.

Serie 1 - ¿Cuántas brigadas de saneamiento hay que programar?

Interesados: secretaría de salud, concejo municipal, comunidades rurales.
Decisión: brigadas de saneamiento por mes (cada una cuesta 18 M COP).

1. Afirmación
El próximo año se esperan entre 190 y 320 casos mensuales de EDA, con el pico entre mayo y junio (aprox. 320) y el valle entre agosto y septiembre (aprox. 190).

2. Evidencia
En los últimos 13 años el patrón se repitió con un error típico de 12 casos por mes, la mitad del error de repetir el mismo mes del año anterior.

3. Justificación
El patrón no es casual: la enfermedad diarreica tiene un ciclo anual asociado al clima. El cálculo aprovecha tanto el crecimiento sostenido como ese ciclo anual, y por eso su error es mucho menor que cualquier regla simple.

4. Alcance
Vale para los próximos 12 meses si la cobertura del sistema de vigilancia y la población atendida no cambian. Cambiaría si aparece una epidemia o si se modifica la cobertura.

5. Objeción y respuesta
¿Y si el año entrante es atípico?

El rango va de 190 a 320 casos por mes. Cubre tanto años moderados como años de brote. Programar brigadas con el valor central y dejar un margen del 10 % del presupuesto para contingencias cubre el escenario adverso.

Serie 2 - ¿Cuántas dosis pedir en la próxima compra?

Interesados: químico farmacéutico, coordinación del programa, afiliados.
Decisión: dosis semanales para el bloque de 6 semanas (4 de cobertura + 2 de entrega).

1. Afirmación
En la próxima compra se deben pedir dosis para aproximadamente 490 a 515 afiliados por semana, equivalentes a aprox. 3 000 dosis para el bloque de seis semanas.

2. Evidencia

El programa crece de forma sostenida: pasa de 48 a 478 afiliados en 160 semanas. El cálculo captura ese crecimiento con un error típico de 9 afiliados por semana, muy por debajo del error de asumir que el número de afiliados no cambia (28 por semana).

3. Justificación
El crecimiento ha sido continuo durante los tres años de registro. El cálculo proyecta esa curva hacia adelante y su error es la tercera parte del de una regla simple, lo que da un margen de seguridad razonable para la compra.

4. Alcance
Vale para las próximas 6 semanas si las condiciones de inscripción al programa no cambian. Cambiaría si se cierra la inscripción, si cambia el operador logístico o si aparece una campaña masiva de captación.

5. Objeción y respuesta
¿Y si el crecimiento se frena? El rango del cálculo va de 470 a 532 afiliados por semana. Si el programa entra en meseta en 480, el pedido se sobreestima en aprox. 40 dosis por semana, equivalentes a aprox. 240 dosis del bloque. La farmacia puede rotarlas antes del vencimiento dentro del siguiente ciclo.

Serie 3 - ¿Cuántos médicos contratar para el próximo bloque?

Interesados: dirección científica, médicos generales, pacientes.
Decisión: médicos generales para el bloque de 6 semanas (4 de cobertura + 2 de anticipación).

1. Afirmación
Para el próximo bloque se necesitan 4 médicos generales, equivalentes a 124 consultas semanales de capacidad.

2. Evidencia
La serie es muy estable: promedio de 120 consultas por semana, con una variabilidad normal de 11 consultas. El cálculo para las próximas seis semanas es de 124 consultas semanales con un margen de ± 14 a ± 27 según cuán lejos esté la semana.

3. Justificación
Ningún método complejo logró batir al promedio simple en esta serie. Eso significa que el patrón es esencialmente un nivel estable con variaciones normales semana a semana. El mejor cálculo es el promedio histórico, no un modelo elaborado.

4. Alcance
Vale para el próximo bloque de 6 semanas. Cambiaría si aparece una epidemia respiratoria o si se modifica la franja reservada para estas consultas.

5. Objeción y respuesta
¿No es un desperdicio contratar 4 médicos si el promedio es 120? No. Cada médico atiende 32 consultas por semana, entonces 3 médicos cubren 96 consultas. Faltan 28 consultas semanales que van a urgencias, donde cuestan 4 veces más. Un médico extra cuesta 2.8 M COP por semana; las 28 consultas derivadas a urgencias cuestan considerablemente más.

(c) La nota. Un documento de una página, informe/nota-interesados.pdf, dirigido a los interesados de las tres series, sin fórmulas ni términos del curso, con un solo gráfico por serie diseñado para esa audiencia. La nota responde la pregunta que cada interesado plantea en el contexto, traduce el error esperado del pronóstico a una consecuencia concreta para la decisión y dice con claridad lo que el pronóstico no puede garantizar.

En *informe/nota-interesados.pdf*