


# Trabajo 1 - Tres series: descripción, operador de rezago, dependencia, pronóstico y argumentación

**Por: Daniel Bustamante Cortés, Andrés Felipe López Díaz y Viviana Astrid León Oróstogue**

Departamento de Estadística, Facultad de Ciencias
Universidad Nacional de Colombia – Sede Medellín

Series de Tiempo (3009297)

Docente: Juan Pablo Valencia Arango

Octubre 15, 2026

## Tabla de contenidos


Las tres series y la pregunta de pronóstico . . . . . 3
Descripción del patrón . . . . . 5
Operador de rezago . . . . . 12
Dependencia y estacionariedad . . . . . 21

## Las tres series y la pregunta de pronóstico

**(a)** Para cada serie, una ficha verificada con código: nombre, unidad, frecuencia, fecha inicial y final, $T$, mínimo, máximo y media.

- Ficha técnica para la serie 1:

| Atributo | Valor |
|---|---|
| **Nombre** | Casos mensuales de enfermedad diarreica aguda notificados |
| **Unidad** | Casos de enfermedad diarreica aguda notificados |
| **Frecuencia** | Mensual |
| **Fecha inicial** | 2013-01-01 |
| **Fecha final** | 2025-12-01 |
| **Número de observaciones** ($T$) | 156 |
| **Mínimo** | 74 |
| **Máximo** | 311 |
| **Media** | 169.0448718 |

- Ficha técnica para la serie 2:

| Atributo | Valor |
|---|---|
| **Nombre** | Afiliados activos a un programa de control de hipertensión |
| **Unidad** | Personas inscritas y activas en el programa de control de hipertensión arterial |
| **Frecuencia** | Semanal |
| **Fecha inicial** | 2022-12-05 |
| **Fecha final** | 2025-12-22 |
| **Número de observaciones** ($T$) | 160 |
| **Mínimo** | 48 |
| **Máximo** | 478 |
| **Media** | 218.1625 |

- Ficha técnica para la serie 3:

| Atributo | Valor |
|---|---|
| **Nombre** | Consultas semanales por enfermedad respiratoria en un hospital |

| Atributo | Valor |
|---|---|
| **Unidad** | Consultas de medicina general cuyo motivo principal es una enfermedad respiratoria |
| **Frecuencia** | Semanal |
| **Fecha inicial** | 2021-01-04 |
| **Fecha final** | 2025-08-04 |
| **Número de observaciones ($T$)** | 240 |
| **Mínimo** | 99 |
| **Máximo** | 146 |
| **Media** | 121.1416667 |

**(b)** Para cada serie, a partir del contexto, la pregunta de pronóstico escrita por el equipo, la decisión que depende de la respuesta y el horizonte $H$ que esa decisión exige, en dos o tres líneas y coherente con la unidad y la frecuencia de la serie.

- Para la serie 1: *¿Cuántos casos mensuales de EDA se esperarán el siguiente año?* La idea es pronosticar mensualmente los casos para los próximos 12 meses ($H = 12$). La decisión es programar con tres meses de anticipación las brigadas y las compras de sales, con el fin de asignar el presupuesto anual aprobado en noviembre y evitar el doble de costo que implicarían las contrataciones de urgencia ante un brote. El horizonte cubre un año completo, lo cual permite planificar el presupuesto y las brigadas para cada mes del año que sigue.
- Para la serie 2: *¿Cuántas dosis de medicamento semanales para la hipertensión se deben considerar para la siguiente compra?* La decisión es hallar la cantidad de medicamento que logre un equilibrio entre escasez y vencimiento de las dosis. Se desea pronosticar semanalmente los afiliados para las próximas 6 semanas ($H = 6$), pues la compra se hace cada cuatro semanas y hay un plazo de entrega de dos.
- Para la serie 3: *¿Cuántas consultas por enfermedades respiratorias se esperan en la semana del próximo bloque, y por tanto, cuántos médicos adicionales se deben contratar para tratar estas consultas?* La decisión es encontrar el número óptimo de médicos que minimize el número de pacientes en urgencias, sin representar una carga económica elevada por el número de personal. El objetivo es pronosticar semanalmente la cantidad de médicos a contratar para las siguientes 6 semanas ($H = 6$), debido a que los médicos adicionales se contratan por cuatro semanas con dos de anticipación.

**(c)** Una tabla de las tres series con la partición de la sección de reglas: $n_0$, $H$, número de orígenes para $h = 1$ y para $H$, y fechas que delimitan cada tramo.

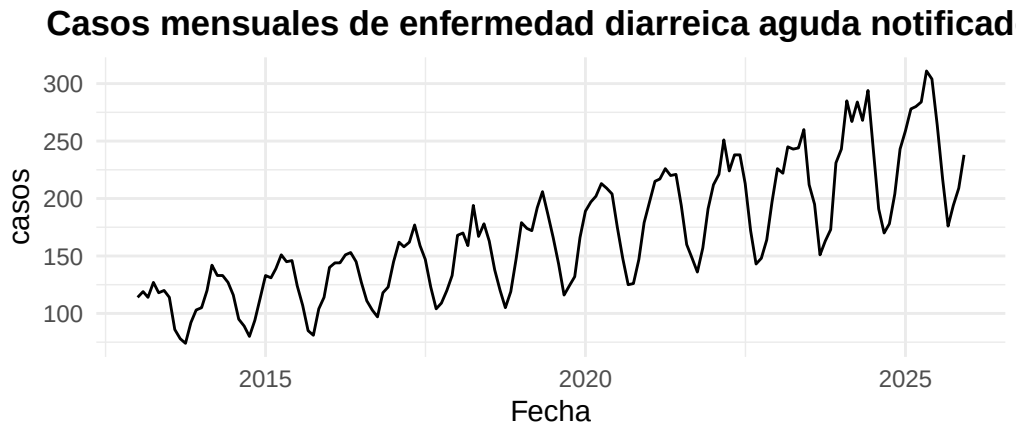
| Serie | $n_0$ | $H$ | Número de orígenes $h = 1$ | Número de orígenes $h = H$ | Fechas de entrena-miento | Fechas de evaluación |
|---|---|---|---|---|---|---|
| 1 | 124 | 12 | 32 | 21 | 2013-01-01 hasta 2023-04-01 | 2023-05-01 hasta 2025-12-01 |
| 2 | 128 | 6 | 32 | 27 | 2022-12-05 hasta 2025-05-12 | 2025-05-19 hasta 2025-12-22 |
| 3 | 192 | 6 | 48 | 43 | 2021-01-04 hasta 2024-09-02 | 2024-09-09 hasta 2025-08-04 |

## Descripción del patrón

**(a)** Para cada serie, el gráfico en el tiempo, con título, ejes con nombre y unidad, eje de fechas legible y un caption con el número de observaciones, y el gráfico de rezagos de $y_t$ contra $y_{t-k}$ para los rezagos que el equipo juzgue informativos, justificando la elección.

Para definir el número de rezagos en cada gráfico de rezagos para las 3 series se tuvo en cuenta la información previamente definida del horizonte $H$, en cada caso. En la serie 1, 12 rezagos permiten ver el comportamiento dentro de un año, en la serie 2 y 3, al ser semanales y ambas tener un horizonte de 6 un rezago igual a este valor permite observar que pasa en este lapso de tiempo, que es el de interés.

```
g1 <- graficar_serie(datos1, titulo = "Casos mensuales de enfermedad diarreica aguda notifica
g2 <- grafico_rezagos(datos = datos1, k = 12)
g1 / g2
```




Número de observaciones: 156




La serie de casos mensuales de EDA presenta una tendencia creciente a lo largo del tiempo, junto a un patrón estacional. El gráfico de rezagos muestra una relación lineal positiva entre las observaciones presentes ($y_t$) y pasadas ($y_{t-12}$), lo que confirma una alta autocorrelación y una fuerte dependencia estructural en los datos.

```
g1 <- graficar_serie(datos2, titulo = "Afiliados activos al programa de control de hipertensi
g2 <- grafico_rezagos(datos = datos2, k = 6)
g1 / g2
```

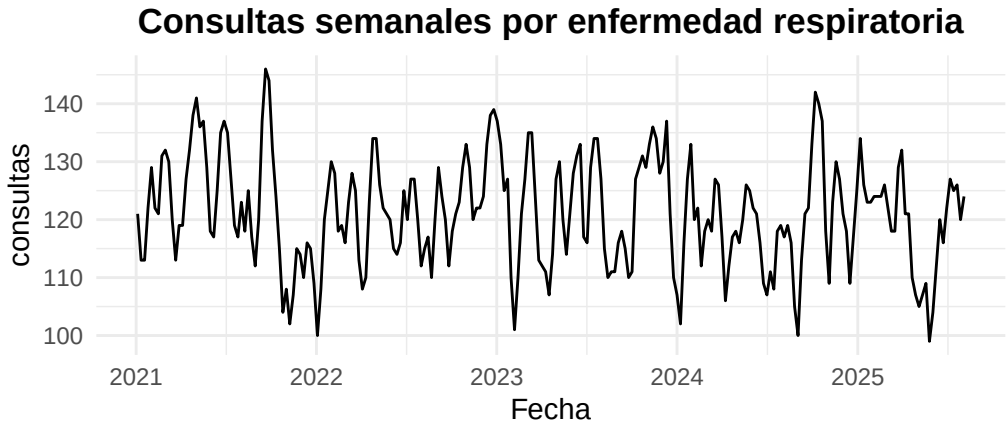



Número de observaciones: 160

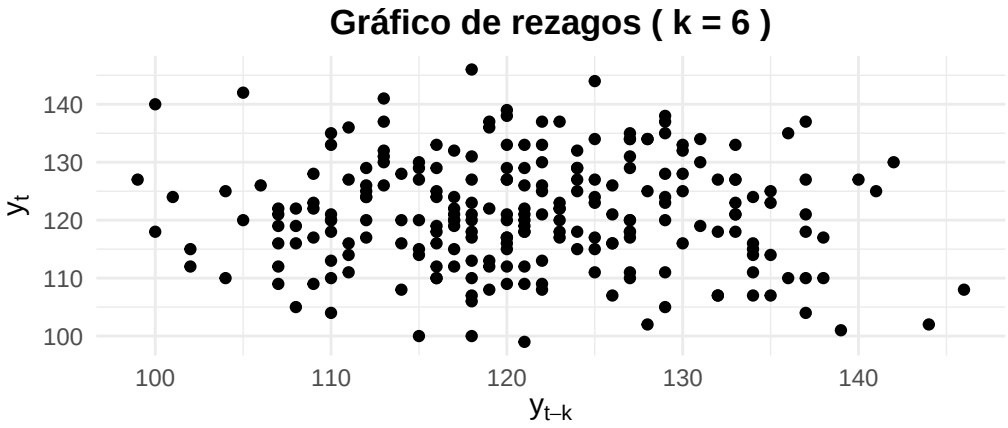



La serie de afiliados activos del programa de control de hipertensión presenta una tendencia creciente a lo largo del tiempo. El gráfico de rezagos muestra una relación lineal positiva entre las observaciones presentes ($y_t$) y pasadas ($y_{t-6}$), lo que confirma una alta autocorrelación y una fuerte dependencia estructural en los datos.

```
g1 <- graficar_serie(datos3, titulo = "Consultas semanales por enfermedad respiratoria")
g2 <- grafico_rezagos(datos = datos3, k = 6)
g1 / g2
```




Número de observaciones: 240



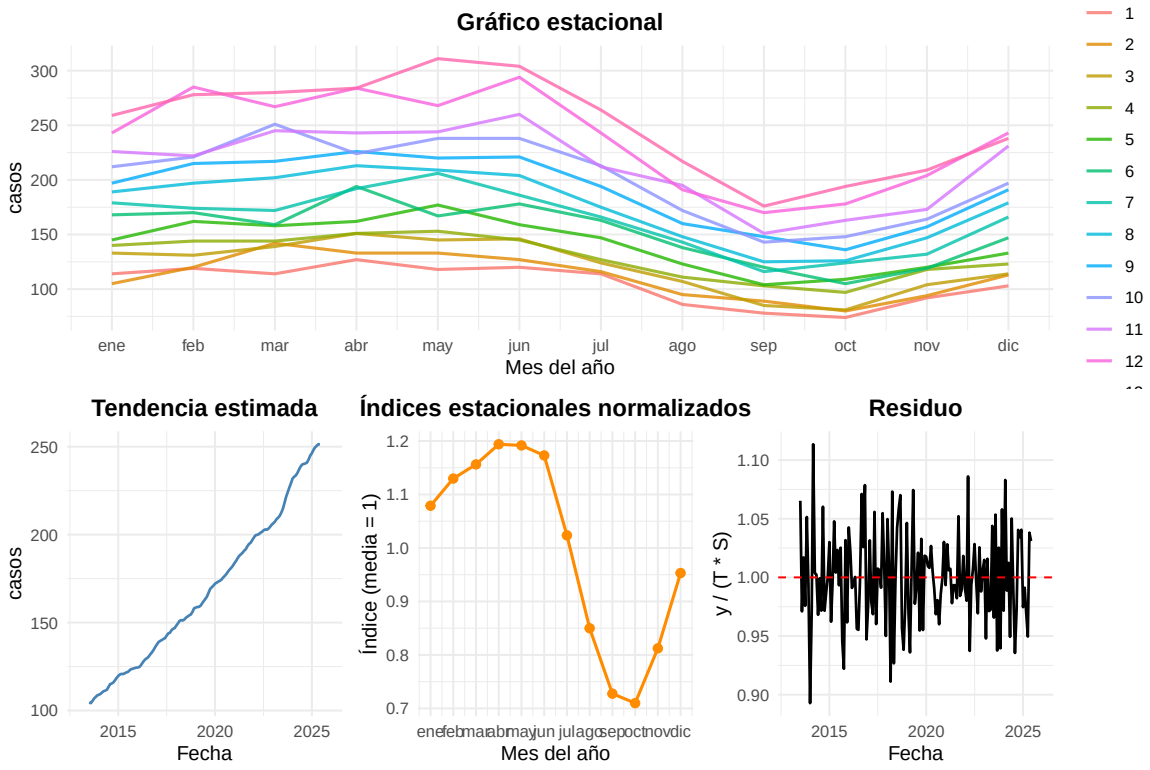

La serie de consultas semanales por enfermedad respiratoria no parece presentar ni tendencia ni estacionalidad. El gráfico de rezagos no muestra una relación lineal entre las observaciones presentes ($y_t$) y pasadas ($y_{t-6}$), por lo que no parece haber una fuerte dependencia estructural en los datos.

**(b)** Para cada serie, la decisión argumentada sobre si tiene estacionalidad y, si la tiene, cuál es su período. Toda serie a la cual el equipo le atribuya estacionalidad lleva el gráfico estacional, con un trazo por ciclo sobre el índice de estación, y una descomposición clásica programada a mano con una media móvil centrada, en la versión aditiva o multiplicativa, cuya elección se justifica con evidencia gráfica y numérica; se muestran la tendencia estimada, los índices estacionales normalizados y el residuo. Toda serie a la cual no se le atribuya estacionalidad lleva la evidencia que lo sostiene.

Como se vió en el punto anterior, la única serie que parece tener estacionalidad es la 1, con período $s = 12$, pues hay un solo ciclo por año, se nota un solo pico y un solo valle por año. Además, la amplitud estacional crece con el nivel general, por lo que se elige una descomposición

multiplicativa: $y_t = T_t \times S_t \times R_t$. La media móvil centrada suaviza la tendencia y, al sacar la tendencia, los índices estacionales normalizados muestran que los meses de marzo a junio son sistemáticamente superiores a la media anual, mientras que septiembre y octubre son los más bajos. El residuo se mantiene alrededor de cero sin un patrón anual claro, lo que refuerza la decisión de atribuir estacionalidad a la serie 1.

```
grafico_estacional(datos = datos1, s = 12, tipo = "multiplicativo")
```

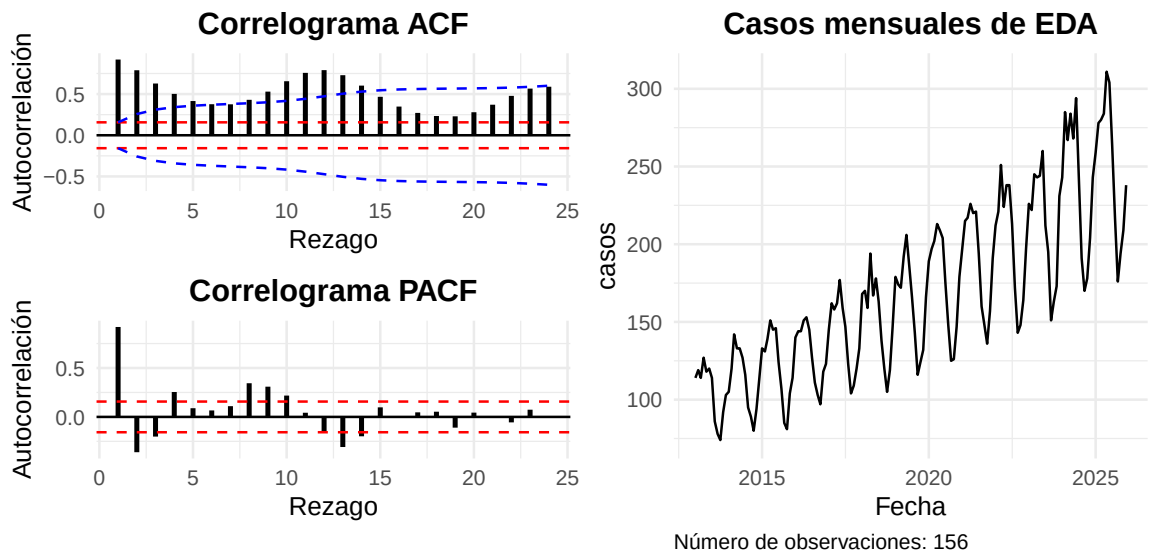



En la descomposición, la tendencia estimada es creciente a lo largo del periodo, los índices estacionales normalizados tienen valores alrededor de 1 y capturan la estructura anual del brote diarreico, y el residuo no presenta un patrón sistemático restante. Por tanto, la serie 1 se clasifica como una serie con tendencia creciente y estacionalidad anual de tipo multiplicativo.

**(c)** Para cada serie, la clasificación de su patrón, apoyada en el gráfico y en el correlograma de la serie sin transformar con $m = mn\lfloor T/4 \rfloor, 24$ rezagos, con la lectura de la forma de ese correlograma.

- Para la serie 1:

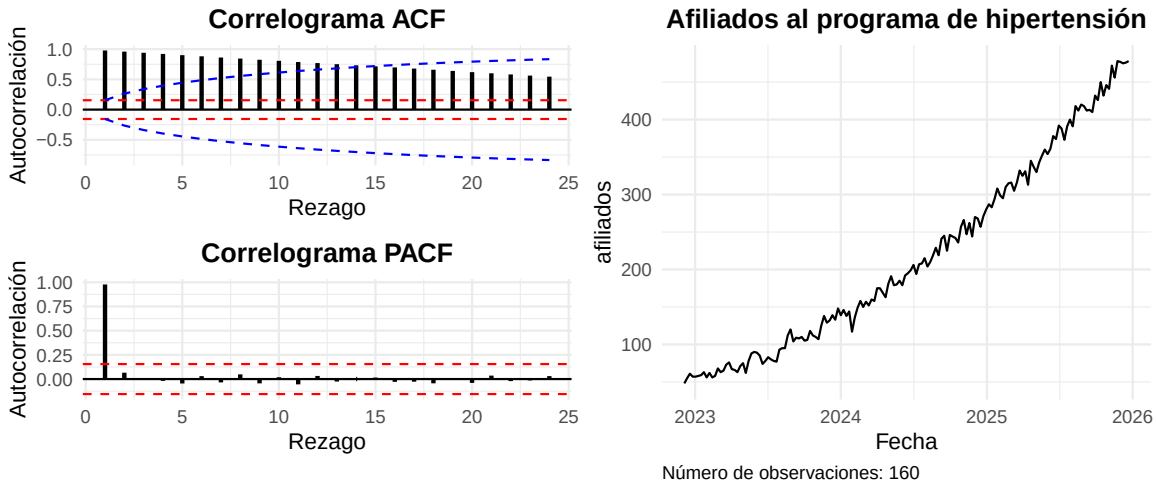
```
m <- min(length(datos1$y), 24)
a <- correlograma(datos1, m)
b <- graficar_serie(datos1, titulo = "Casos mensuales de EDA")
a | b
```




En los primeros rezagos, el correlograma tiene autocorrelaciones altamente significativas, las cuales van disminuyendo lentamente a medida que el rezago crece, esto indica tendencia. Por otro lado, sobre el comportamiento descrito se notan picos cuando el rezago es multiplo de 12 (serie mensual), por lo que la serie parece tener estacionalidad. Estas características son aún más claras en la serie.

- Para la serie 2:

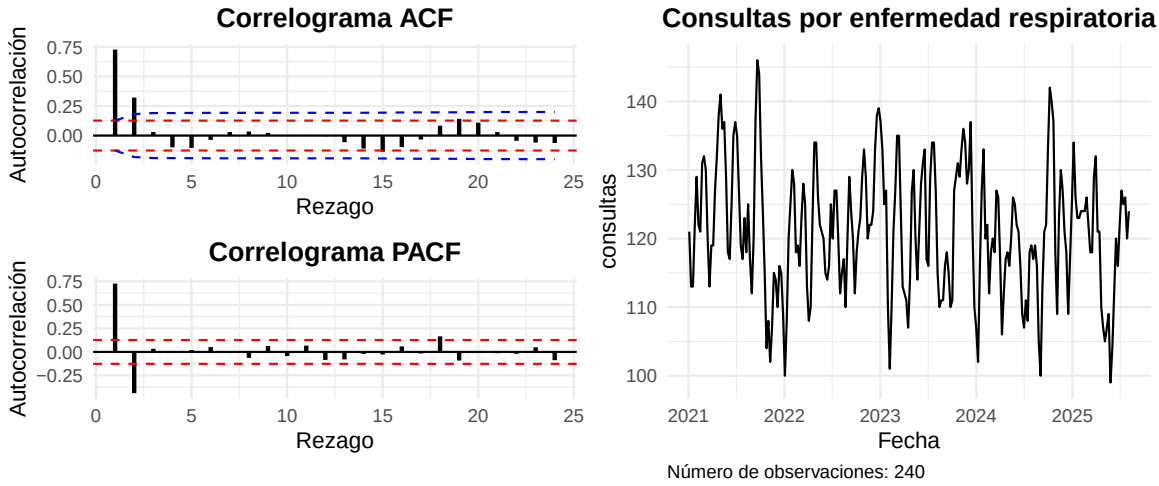
```
m <- min(length(datos2$y), 24)
a <- correlograma(datos2, m)
b <- graficar_serie(datos2, titulo = "Afiliados al programa de hipertensión")
a | b
```




El comportamiento de decaimiento lento en el correlograma es evidencia clara de que la serie sin transformaciones tiene tendencia. Con base en el gráfico de la serie se recalca lo ya dicho y se observa que la tendencia es de crecimiento.

- Para la serie 3:

```
m <- min(length(datos3$y), 24)
a <- correlograma(datos3, m)
b <- graficar_serie(datos3, titulo = "Consultas por enfermedad respiratoria")
a | b
```




Para este caso no se logran identificar patrones de estacionalidad o tendencia de la serie relacionada a las consultas por enfermedades respiratorias. No parece haber una estructura

visible clara ni muchos rezagos que superen la banda. Aunque si se nota un nivel constante, pues en el gráfico de la serie se nota que se oscila siempre sobre 120 aproximadamente.

### Operador de rezago

**(a)** Escriba `diferenciar(y, d, D, s)`, que aplica $(1-B)^d(1-B^s)^D$ sin usar `diff()`, y `polinomio_rezago(coef)`, que recibe los coeficientes de $c(B) = 1 + c_1B + \cdots + c_pB^p$ y devuelve sus raíces con su módulo. Verifique `diferenciar()` contra `diff()` en un bloque de verificación.

```
# Código de verificación de diferenciar() vs. diff()
set.seed(67)
y_prueba <- rnorm(15)

d_prueba <- 1
D_prueba <- 1
s_prueba <- 12

res_manual <- diferenciar(y_prueba, d = d_prueba, D = D_prueba, s = s_prueba)

res_diff <- diff(y_prueba, lag = s_prueba, differences = D_prueba)
res_diff <- diff(res_diff, lag = 1, differences = d_prueba)
print("diferenciar vs. diff")
```

```
[1] "diferenciar vs. diff"
```

```
print(res_manual);print(res_diff)
```

```
[1] 0.02991735 1.71525811
```

```
[1] 0.02991735 1.71525811
```

```
print("c(B) = 1 - 2B + 3B^2")
```

```
[1] "c(B) = 1 - 2B + 3B^2"
```

```
print("Raíces y módulos del polinomio de prueba:")
```

```
[1] "Raíces y módulos del polinomio de prueba:"
```

```
print(polinomio_rezago(c(-2, 3)))
```

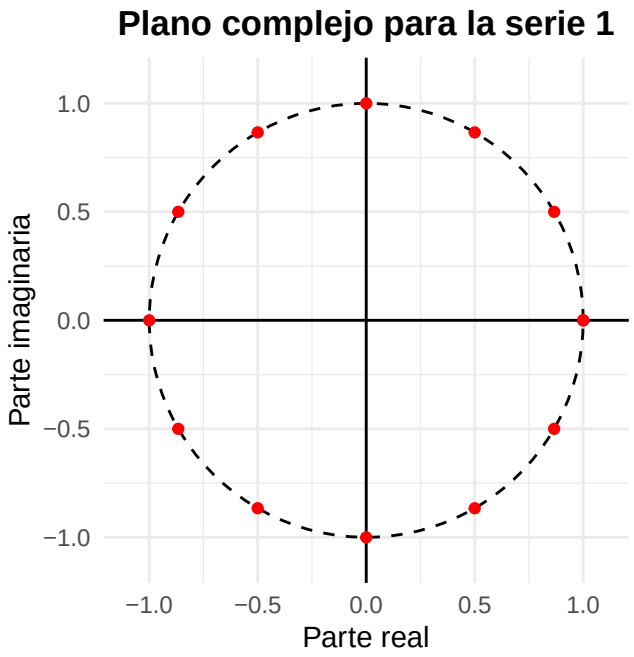
```
                  Raiz    Modulo
1 0.3333333+0.4714045i 0.5773503
2 0.3333333-0.4714045i 0.5773503
```

**(b)** Para cada serie, proponga las transformaciones candidatas que su diagnóstico sugiere, incluidas las transformaciones previas de escala si las hay, y escriba cada una como polinomio en B. Calcule las raíces de cada polinomio con `polinomio_rezago()`, ubíquelas en el plano complejo y explique qué componente determinista elimina cada factor.

- Serie 1: Ya vimos que esta serie tiene tendencia y estacionalidad con período 12, por lo que se aplica una diferencia para quitar la tendencia y una estacional para la estacionalidad. Además, esta serie tiene comportamiento multiplicativo, pues a medida que pasa el tiempo la amplitud de las variaciones estacionales crece, debido a esto lo ideal es aplicar una transformación a los datos, un logaritmo natural. Se tendría entonces,

$$\nabla_1 \nabla_{12} \ln(y_t) = (1-B)(1-B^{12}) = 1 - B^{12} - B + B^{13} = 1 - B - B^{12} + B^{13}$$

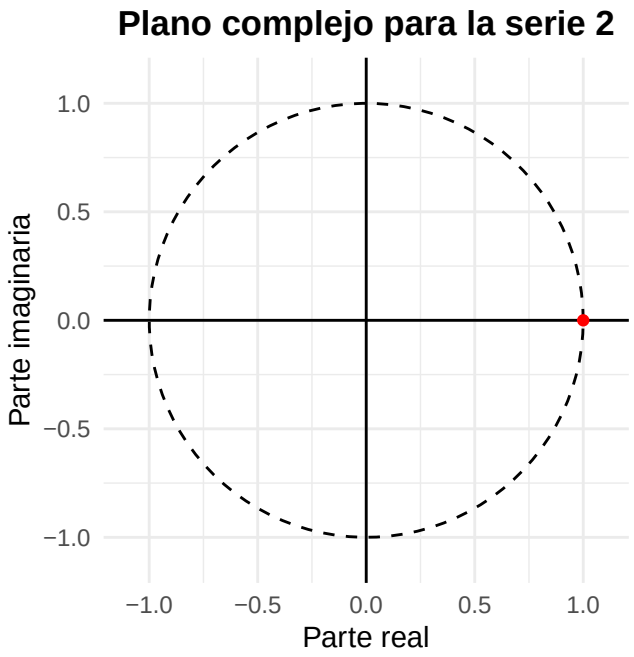
```
datos1$log <- log(datos1$y)
coefs_1 <- c(-1, rep(0, 10), -1, 1)
raices_1 <- polinomio_rezago(coefs_1)
df1 <- data.frame(Parte_Real = Re(raices_1$Raiz),
                  Parte_imaginaria = Im(raices_1$Raiz))
ggplot(df1, aes(x = Parte_Real, y = Parte_imaginaria)) +
  annotate("path", x = cos(seq(0, 2*pi, length.out = 100)),
           y = sin(seq(0, 2*pi, length.out = 100)), linetype = "dashed") +
  geom_hline(yintercept = 0) +
  geom_vline(xintercept = 0) +
  geom_point(color = "red") +
  labs(title = "Plano complejo para la serie 1", x = "Parte real",
       y = "Parte imaginaria") +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5)) +
  coord_fixed(ratio = 1, xlim = c(-1.1, 1.1), ylim = c(-1.1, 1.1))
```




- Serie 2: Esta serie cuanta con tendencia, por lo que es suficiente aplicar una diferencia para eliminarla:

$$\nabla_1 = (1 - B)$$

```
coefs_2 <- c(-1)
raices_2 <- polinomio_rezago(coefs_2)
df2 <- data.frame(Parte_Real = Re(raices_2$Raiz),
                  Parte_imaginaria = Im(raices_2$Raiz))
ggplot(df2, aes(x = Parte_Real, y = Parte_imaginaria)) +
  annotate("path", x = cos(seq(0, 2*pi, length.out = 100)),
           y = sin(seq(0, 2*pi, length.out = 100)), linetype = "dashed") +
  geom_hline(yintercept = 0) +
  geom_vline(xintercept = 0) +
  geom_point(color = "red") +
  labs(title = "Plano complejo para la serie 2", x = "Parte real",
       y = "Parte imaginaria") +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5)) +
  coord_fixed(ratio = 1, xlim = c(-1.1, 1.1), ylim = c(-1.1, 1.1))
```




- Serie 3: No es necesario aplicar transformaciones, pues no se presentó ni estacionalidad ni tendencia. El polinomio sería igual a 1, por tanto no tiene sentido hacer la gráfica ya que no habría puntos.

**(c)** Para cada serie, una tabla con la varianza muestral y $r_1$ de la serie y de cada transformación candidata. Elija la transformación con la cual la serie resultante es plausiblemente estacionaria, que puede ser ninguna, y defienda que no aplica diferencias de más, con la identidad $Var(\nabla Y_t) = 2\gamma(0) - 2\gamma(1)$ y con lo que le ocurre a $r_1$ cuando se diferencia una serie que ya era estacionaria. Verifique sobre los datos que la media de la serie transformada coincide con lo que la transformación debe dejar.

- Serie 1:

```
resumen_serie <- function(x){
  x <- na.omit(x)
  n <- length(x)
  if (n < 2) return(c(media=NA, varianza=NA, r1=NA))
  media <- mean(x)
  varianza <- var(x) * (n-1)/n
  r1 <- cor(x[-1], x[-n])
  return(c(media = media, varianza = varianza, r1 = r1))
}
```

```r
datos1$logy <- log(datos1$y)
datos1$dif1_logy <- c(NA, diferenciar(datos1$logy, d = 1, D = 0, s = 12))
datos1$dif12_logy <- c(rep(NA, 12), diferenciar(datos1$logy, d = 0, D = 1, s = 12))
datos1$dif_est_logy <- c(rep(NA, 13), diferenciar(datos1$logy, d = 1, D = 1, s = 12))

datos2$dif_y <- c(NA, diferenciar(datos2$y, d = 1, D = 0, s = 1))
datos3$dif_y <- c(NA, diferenciar(datos3$y, d = 1, D = 0, s = 1))
```

Por el inciso anterior se sabe que para la serie 1 la transformacion que se aplica es una diferencia para quitar la tendencia y una estacional para la estacionalidad, sin embargo vamos a ilustrar una tabla con cuatro escenarios, es decir, serie original comparada ante las transformaciones para esta serie, con el fin de ver el paso a paso:

```r
s1_ori   <- resumen_serie(datos1$y)
s1_log   <- resumen_serie(datos1$logy)
s1_d1    <- resumen_serie(datos1$dif1_logy)
s1_d12 <- resumen_serie(datos1$dif12_logy)
s1_d1d12 <- resumen_serie(datos1$dif_est_logy)
t1 <- data.frame(
  row.names = c("Original", "Logaritmo", "Log + Dif(1)", "Log + Dif(12)", "Log + Dif(1) + Di
  media = c(s1_ori["media"], s1_log["media"], s1_d1["media"], s1_d12["media"],  s1_d1d12["me
  varianza  = c(s1_ori["varianza"],s1_log["varianza"],s1_d1["varianza"],s1_d12["varianza"],s
  r1 = c(s1_ori["r1"], s1_log["r1"], s1_d1["r1"], s1_d12["r1"], s1_d1d12["r1"]))

round(t1, 4)
```

```
                          media  varianza      r1
Original                169.0449 2970.1711  0.9271
Logaritmo                 5.0779    0.1062  0.9269
Log + Dif(1)              0.0047    0.0155  0.4181
Log + Dif(12)             0.0727    0.0037 -0.0678
Log + Dif(1) + Dif(12)    0.0004    0.0077 -0.5580
```

La diferencia estacional del logaritmo tiene $r_1$ cercano a cero y varianza muestral aproximada de 0.00370. Al agregar la diferencia ordinaria, la varianza sube a aproximadamente 0.00771 y $r_1$ cae a aproximadamente -0.558. Esta combinación de aumento de varianza y autocorrelación negativa marcada es una señal de que la diferencia ordinaria adicional puede estar sobrando. Por tanto, con la evidencia disponible, la elección preferible es $\nabla_{12} \log(Y_t)$

$$\hat{\gamma}(1) = r_1 \times \hat{\gamma}(0) = (-0.0678 \times 0.0037) = -0.0002509$$
$$2\hat{\gamma}(0) - 2\hat{\gamma}(1) \approx 2(0.0037) - 2(-0.0002509) \approx 0.007902$$

La varianza muestral observada de la diferencia ordinaria adicional es aproximadamente 0.0077, cercana a ese valor teórico aproximado. Esto indica que una diferencia más duplica la varianza muestral de la serie 1, no aportando evidencia a favor de usarla.

La media resultante es aproximadamente (0.0727), se interpreta como el incremento logarítmico anual promedio, no como una media que la transformación deba forzar a cero. En la escala original equivale a un crecimiento anual promedio aproximado de 7.5 %.

```
n <- length(datos1$logy)
(sum(tail(datos1$logy, 12)) - sum(head(datos1$logy, 12))) / (n - 12)
```

```
[1] 0.07272296
```

- Serie 2:

```
s2_ori  <- resumen_serie(datos2$y)
s2_d1   <- resumen_serie(datos2$dif_y)

t2 <- data.frame(
  row.names = c("Original", "Dif(1)"),
  media     = c(s2_ori["media"],  s2_d1["media"]),
  varianza  = c(s2_ori["varianza"],s2_d1["varianza"]),
  r1        = c(s2_ori["r1"],      s2_d1["r1"]))
round(t2, 4)
```

```
            media   varianza      r1
Original 218.1625 16332.6861  0.9964
Dif(1)     2.7044   117.3151 -0.4455
```

La serie original presenta $r_1 = 0.9964$, lo que evidencia una tendencia determinista fuerte y confirma que no es estacionaria. La varianza elevada (tendencia hace que los valores se alejen de la media) y la media no estable refuerzan la necesidad de transformación. La gran reducción de varianza (de 16332 a 118) prueba que la primera diferencia era necesaria para extraer la señal de la tendencia. Una segunda diferencia no tendría tendencia que eliminar y solo introduciría ruido. En cuanto a la media, este valor no es cero, sino que representa el crecimiento promedio semanal de los afiliados, lo cual es exactamente lo que debe dejar una primera diferencia cuando la serie original crece de forma constante.

PASO 1: calcular para la serie original

$$\begin{aligned}\gamma(1) &= 0.9964 \times 16332.6861 = 16273.89 \\ \text{Var}(\nabla Y_t)_{\text{teórica}} &= 2(16332.6861) - 2(16273.89) \\ &= 32665.37 - 32547.78 = \mathbf{117.59}\end{aligned}$$

Se observa que la varianza cae drásticamente, por lo que se confirma que la primera diferencia remueve la tendencia.

PASO 2: calcular sobre la serie ya diferenciada(dif1)

$$\begin{aligned}\gamma(0) &= 117.3151, \quad r_1 = -0.4455 \\ \gamma(1) &= -0.4455 \times 117.3151 = -52.26 \\ \text{Var}(\nabla^2 Y_t)_{\text{teórica}} &= 2(117.3151) - 2(-52.26) \\ &= 234.63 + 104.52 = \mathbf{339.15}\end{aligned}$$

Se observa que la varianza subiría de 117.32 a 339.15 claramente aumenta, lo cual es una señal de sobrediferenciación. Así que se para en este punto.

La media no se espera que sea cero, porque la serie crece de forma casi constante. Lo que deja una primera diferencia es la pendiente promedio y la verificación confirma que ese número sale solo de los extremos de la serie.

```
y <- datos2$y
n <- length(y)

media_dif <- mean(datos2$dif_y, na.rm = TRUE)
media_teor<- (y[n] - y[1]) / (n - 1)

c(observada = media_dif, teorica = media_teor)
```

```
observada   teorica
 2.704403  2.704403
```

- Serie 3:

Ahora para la serie 3 vamos a calcular la tabla suponiendo que SI se aplicara una sola diferencia solo para hacer una comparacion y defender que no se usan diferencias en este caso.

```r
s3_ori <- resumen_serie(datos3$y)
s3_d1 <- resumen_serie(datos3$dif_y)

t3 <- data.frame(
  row.names = c("Original", "Dif(1)"),
  media     = c(s3_ori["media"],  s3_d1["media"]),
  varianza  = c(s3_ori["varianza"],s3_d1["varianza"]),
  r1        = c(s3_ori["r1"],      s3_d1["r1"]))

round(t3, 4)
```

```
            media varianza     r1
Original 121.1417  86.6299 0.7271
Dif(1)     0.0126  47.4768 0.2445
```

La varianza baja al diferenciar, pero eso no es evidencia a favor de diferenciar. Por la identidad, la varianza disminuye siempre que r $> 0.5$, y aquí r $= 0.7271$. La identidad se cumple: $2\gamma(0) - 2\gamma(1) = 2 * 86.63 - 2 * (0.7271 * 86.63) = 47.28 \approx (\nabla Y_t)$,pero es un chequeo algebraico, no una prueba de estacionariedad. En esta serie el criterio de varianza no sirve para detectar sobrediferenciación, así que la decisión se apoya en el diagnóstico: no hay tendencia ni estacionalidad en el gráfico, el nivel oscila alrededor de 121 y la ACF cae rápido tras el rezago 2. No hay ninguna componente determinista que una diferencia deba eliminar. Diferenciar solo destruiría el nivel, pues la media pasa de 121.14 a 0.0126, y el r de 0.7271 a 0.2445.

Su media ($\bar{x} = 121.1417$) representa el nivel promedio estable de consultas respiratorias. Si se aplicara diferencia, la media pasaría a ser 0, perdiendo toda interpretación del nivel.

```r
y <- datos3$y
n <- length(y)
c(media_dif = mean(diferenciar(y, 1, 0, 1)),
  teorica_dif = (y[n] - y[1]) / (n - 1))
```

```
  media_dif teorica_dif
  0.0125523   0.0125523
```

**(d)** A mano, en el informe. Pruebe que la función de pronóstico de Holt, $\hat{Y}_{T+h} = L_T + \hat{T}_T h$, satisface $(1-B)^2 \hat{Y}_{T+h} = 0$ para $h \geq 3$, y que la de Holt–Winters aditivo con período $s$, $\hat{Y}_{T+h} = L_T + \hat{T}_T h + S_{T+h-s\lceil h/s \rceil}$, satisface $(1 - B)(1 - B^s)\hat{Y}_{T+h} = 0$ para $h \geq s + 2$, con el operador actuando sobre $h$. Escriba la solución general de cada ecuación en diferencias y diga qué raíces del polinomio característico corresponden a la tendencia y cuáles a la estacionalidad.

- Demostración de que $\hat{Y}_{T+h} = L_T + \hat{T}_T h$ satisface $(1-B)^2\hat{Y}_{T+h} = 0$ para $h \geq 3$:

$$\begin{aligned}(1-B)^2\hat{Y}_{T+h} &= (1-2B+B^2)\hat{Y}_{T+h}\\ &= \hat{Y}_{T+h} - 2B\hat{Y}_{T+h} + B^2\hat{Y}_{T+h}\\ &= \hat{Y}_{T+h} - 2\hat{Y}_{T+h-1} + \hat{Y}_{T+h-2}\\ &= L_T + \hat{T}_T h - 2[L_T + \hat{T}_T(h-1)] + L_T + \hat{T}_T(h-2)\\ &= L_T + \hat{T}_T h - 2L_T - 2\hat{T}_T h + 2\hat{T}_T + L_T + \hat{T}_T h - 2\hat{T}_T\\ &= (2L_T - 2L_T) + (2\hat{T}_T h - 2\hat{T}_T h) + (2\hat{T} - 2\hat{T})\\ &= 0\end{aligned}$$

- Demostración de que $\hat{Y}_{T+h} = L_T + \hat{T}_T h + S_{T+h-s\lceil h/s\rceil}$, satisface $(1-B)(1-B^s)\hat{Y}_{T+h} = 0$ para $h \geq s+2$:

$$\begin{aligned}(1-B^s)\hat{Y}_{T+h} &= \hat{Y}_{T+h} - \hat{Y}_{T+h-s}\\ &= L_T + \hat{T}_T h + S_{T+h-s\lceil h/s\rceil} - L_T - \hat{T}_T(h-s) - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T h - \hat{T}_T h + \hat{T}_T s + S_{T+h-s\lceil h/s\rceil}\\ &\quad - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T s + S_{T+h-s\lceil h/s\rceil} - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T s + S_{T+h-s\lceil h/s\rceil} - S_{T+h-s\lceil h/s\rceil}\\ &= \hat{T}_T s\end{aligned}$$

$$\begin{aligned}(1-B)(1-B^s)\hat{Y}_{T+h} &= (1-B)(\hat{T}_T s)\\ &= \hat{T}_T s - \hat{T}_T s \ (No\ depende\ de\ h)\\ &= 0\end{aligned}$$

Se tiene que $h \geq s+2$, pues asegura que el menor valor posible para $h-s-1$ sea 1, un horizonte menor a 1 no tiene sentido.

Para Holt $(1-B)^2 = 0$ la raíz es $B = 1$ con multiplicidad 2. La solución general para una raíz como esta está dada por:

$\hat{Y}_{T+h} = c_1 + c_2 h$

Para Holt-Winters $(1-B)(1-B^s) = 0$ el factor $(1-B)$ aporta una raíz $B = 1$ y el factor $(1-B^s)$ aporta $s$ raíces de la forma $B = e^{i2\pi k/s},\ k = 0, 1, 2, ..., s-1$. Hay $s+1$ raíces, con solución general:

$\hat{Y}_{T+h} = c_1 + c_2 h + \sum_{k=1}^{\lfloor s/2\rfloor} \alpha_k cos(\frac{2\pi kh}{s}) + \beta_k sin(\frac{2\pi kh}{s})$ La raíz $B = 1$ corresponde a la tendencia de la serie, mientras que las raíces $B = e^{i2\pi k/s}$ se refieren a la estacionalidad de período s.

## Dependencia y estacionariedad

**(a)** Escriba `pacf_dl(r)`, la autocorrelación parcial muestral por la recursión de Durbin y Levinson a partir de $r_1, ..., r_m$, y verifíquela contra `pacf()` con máxima diferencia absoluta menor que $10^{-10}$. Para cada serie presente ACF y PACF muestrales hasta el rezago $m$, con la banda de ruido blanco $\pm 1,96/\sqrt{n}$ y la banda de Bartlett $\pm 1,96\sqrt{(1+2\sum_{i<h} r_i^2)/n}$, y diga cuál de las dos corresponde a cada pregunta que se le hace al correlograma.

Para comparar `pacf()` contra `pacf_dl(r)` se usa los datos de la serie 1 transformada (logaritmo y diferencia estacional) con 24 rezagos :

```
a <- na.omit(datos1$dif12_logy)
acfs <- acf_muestral(a, m = 24)
pacf_dl_ <- pacf_dl(r = acfs)
pacf_R <- pacf(a, lag.max = 24, plot = FALSE)$acf[, 1, 1]

max_dif <- max(abs(pacf_dl_ - pacf_R))
print(paste("Máxima diferencia absoluta: ", max_dif))
```

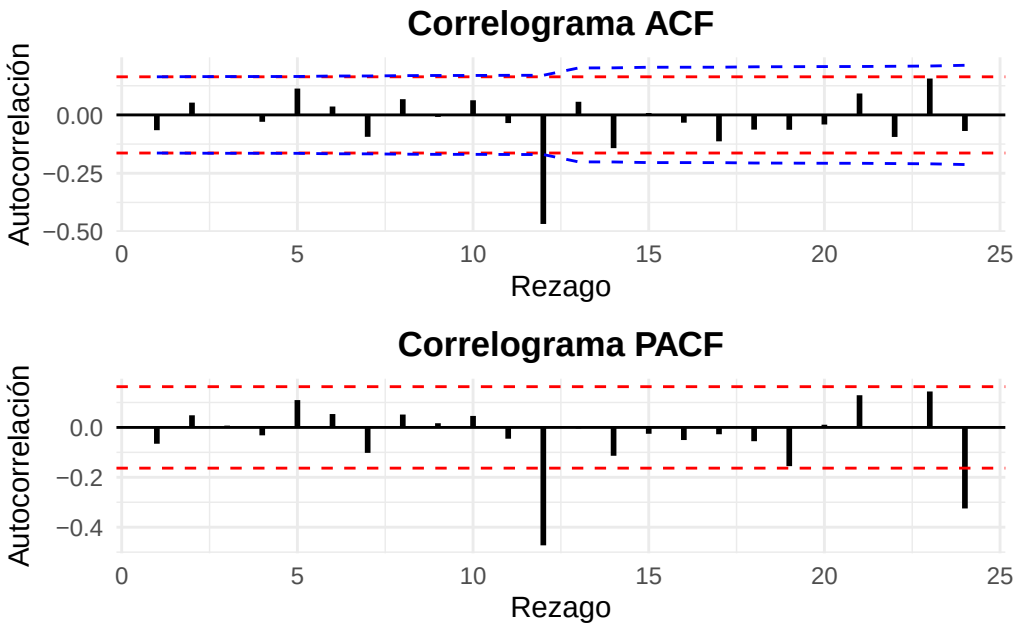
```
[1] "Máxima diferencia absoluta:  8.32667268468867e-16"
```

A continuación se presentan ACF y PACF muestrales para cada una de las series. Para esto se crea una nueva función, `correlograma_muestral(y, m)`, que usa las autocorrelaciones parciales determinadas con `pacf_dl(r)` en lugar de la función base de R `pacf()` como lo hace `correlograma()`. Esta función se creó en el archivo `informe.qmd`, sin embargo, se decidió no mostrarlo en el archivo pdf debido al tamaño extendido del código.

La banda de ruido blanco (roja) responde a ¿La serie es ruido blanco puro? Mientras que la banda de Bartlett responde a ¿El rezago $h$ aporta algo significativo dado que los anteriores son reales?

- Para la serie 1:

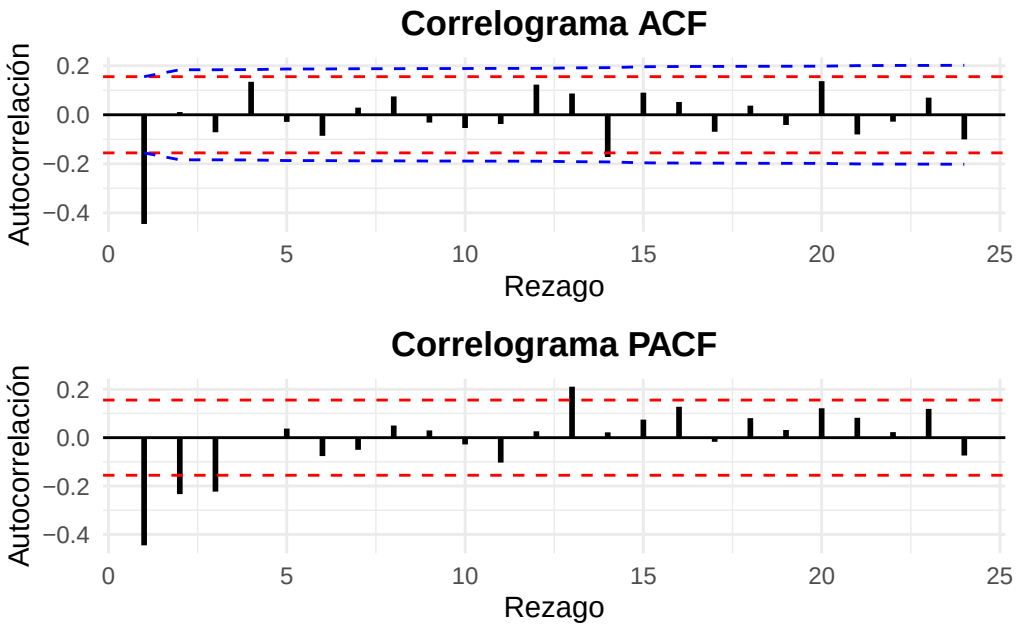
```
correlograma_muestral(y = datos1$dif12_logy, m = 24)
```




A partir del correlograma se nota que la ACF muestral es compatible con ruido blanco en todos los rezagos salvo el 12, donde supera tanto la banda de ruido blanco como la de Bartlett. La PACF presenta picos negativos en los rezagos 12 y 24 que decaen. Esa forma (ACF que se corta tras el rezago estacional y PACF que decae en múltiplos de 12) es la de una media móvil estacional de orden 1. No quedan tendencia ni dependencia de corto plazo relevante: los rezagos 1 a 11 están dentro de las bandas.

- Para la serie 2:

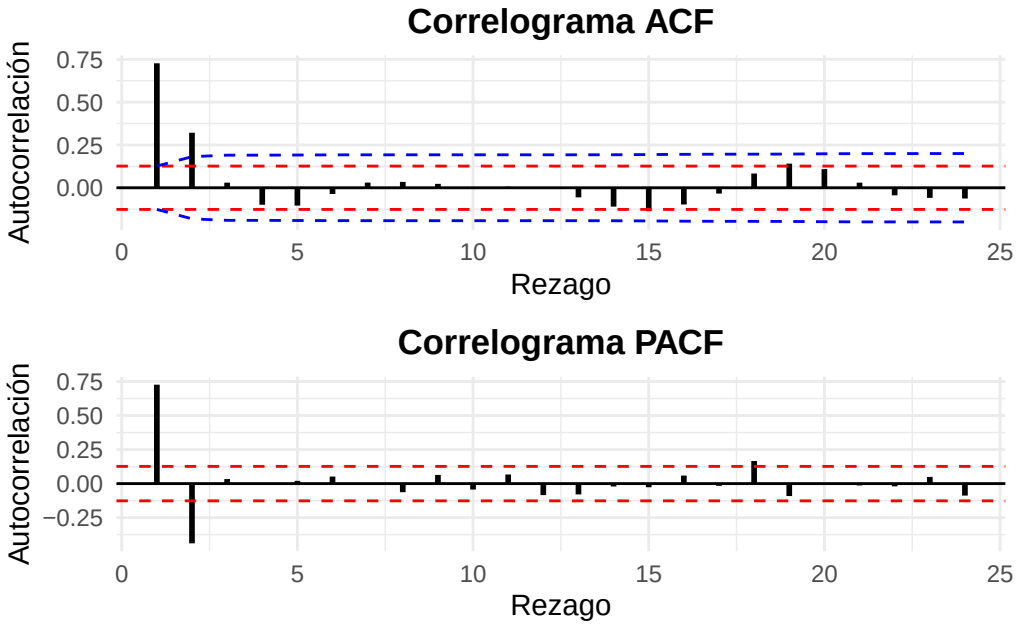
```
correlograma_muestral(y = datos2$dif_y, m = 24)
```




La ACF muestral se corta después del rezago 1 y los demás rezagos están dentro de las bandas, excepto el rezago 14. La PACF decae con signo negativo (en los rezagos 1 a 3). Esa forma es la de una media móvil de orden 1, MA(1), con coeficiente negativo. No hay picos en múltiplos de ningún período, así que no se observa estacionalidad.

- Para la serie 3:

```
correlograma_muestral(y = datos3$y, m = 24)
```




En cuanto a la banda de ruido blanco, se puede observar que los rezagos 1 y 2 tienen autocorrelaciones significativas, por lo que sí parece haber estructura temporal. Los rezagos 1 y 2 se salen de la banda de Bartlett, pero a partir del rezago 3, las autocorrelaciones caen y se mantienen dentro de esta banda, esto es evidencia de que la memoria de la serie se apaga rápidamente y se corta después del segundo periodo.

**(b)** Para cada serie, la prueba de Ljung–Box con sus seis elementos, con $m$ elegido y justificado, y la lectura de la forma de la ACF y de la PACF. Diga con qué proceso de los estudiados en clase es compatible esa forma y con cuáles no, y por qué.

Los seis elementos de la prueba de Ljung-Box para las tres series son:

**1. Hipotesis nula y alternativa**:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_{24} = 0 \quad : \text{la serie es ruido blanco.}$$
$$H_a : \exists k \in \{1, 2, \ldots, 24\} \quad \text{tal que } \rho_k \neq 0 \quad : \text{existe dependencia serial.}$$

**2. Estadístico de prueba**, su fórmula y su distribución bajo la hipótesis nula:

$$Q = n(n+2) \sum_{k=1}^{m} \frac{r_k^2}{n-k}$$

Donde: - $n$ es el número de observaciones, - $r_k$ es la autocorrelación muestral al rezago $k$, - $m$ es el número de rezagos evaluados.

Bajo $H_0$, el estadístico $Q$ sigue una distribución:

$$Q \xrightarrow{d} \chi^2_{(m)}$$

**3. Region de rechazo** al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

**4. Valor observado del estadístico** y valor $p$

- $Q_{\text{obs}}$: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si $H_0$ fuera cierta.

**5. Decision**

Se compara $Q_{\text{obs}}$ con el valor crítico o el valor $p$ con el nivel de significancia $\alpha = 0.05$:

- Si $Q_{\text{obs}} > \chi^2_{m,0.95}$ o $p < 0.05$, se rechaza $H_0$.
- En caso contrario, no se rechaza $H_0$.

**6. Lectura de la decisión en términos de la serie**

Se traduce el resultado estadístico a la estructura de dependencia del fenómeno:

- Si se rechaza $H_0$, existe dependencia serial, la serie no es ruido blanco, presenta estructura temporal compatible con procesos autorregresivos, de media móvil o mixtos ARMA.
- Si no se rechaza $H_0$, no hay evidencia de dependencia serial, la serie se comporta como ruido blanco, no hay patrón temporal predecible.

**Serie 1: Casos mensuales de EDA (transformada):**

$$w_t = (1 - B^{12}) \ln(y_t)$$

- PASO 1: elección de m

Se toma $m = 24$ rezagos, justificado por:

- Regla del trabajo: $m = \text{mín}\left(\left\lfloor \frac{T}{4} \right\rfloor, 24\right) = \text{mín}(36,\, 24) = 24$.
- La serie tiene período estacional $s = 12$; revisar dos ciclos completos permite detectar estructura de dependencia estacional remanente.

- PASO 2: aplicar la prueba

```
z <- as.numeric(na.omit(datos1$dif12_logy))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 56.73398

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 0.0001819201
```

Se rechaza $H_0$ por tanto hay evidencia estadistica para sugerir que aunque se eliminó la tendencia y la estacionalidad anual, persiste estructura de dependencia remanente: las autocorrelaciones conjuntas no son nulas. El patrón sugiere que la serie transformada aún guarda memoria, por lo que un modelo autorregresivo estacional podría capturar esa dependencia y mejorar el pronóstico respecto a métodos más simples. Los valores de casos en meses anteriores siguen informando sobre los casos futuros, más allá del comportamiento anual y el crecimiento general.

**Serie 2: Afiliados activos al programa de hipertensión (transformada):**

$$w_t = (1 - B)y_t$$

- PASO 1: elección de m

$m = \text{mín}\left(\frac{159}{4}, 24\right) = 24$. Suficiente para capturar dependencia semanal sin exceder un cuarto de la muestra.

- PASO 2: aplicar la prueba

```
z <- as.numeric(na.omit(datos2$dif_y))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 59.52425

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 7.453714e-05
```

Como podemos observar se rechaza $H_0$ por tanto hay evidencia estadistica para sugerir que la diferencia eliminó el crecimiento, pero no convirtió la serie en ruido blanco: subsiste dependencia serial significativa (relacionado con los valores anteriores), concentrada principalmente en los primeros rezagos. Esto significa que el número de afiliados de semanas anteriores sigue siendo un buen predictor del número de afiliados de la semana siguiente. Un modelo autorregresivo de orden bajo puede aprovechar esa inercia para afinar la estimación de la demanda de medicamento.

**Serie 3: Consultas por enfermedad respiratoria (sin transformación):**

$$w_t = y_t$$

PASO 1: elección de m

Se toma $m = 24$ rezagos, justificado por:

- $T = 240, \quad m = \text{mín}\left(\frac{240}{4}, 24\right) = \text{mín}(60, 24) = 24$. Cubre casi que medio año de observaciones semanales.
- Suficiente para capturar dependencia semanal sin exceder un cuarto de la muestra.

PASO 2: aplicar la prueba

```r
z <- as.numeric(na.omit(datos1$y))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 1220.311

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 1.146461e-242
```

Se rechaza $H_0$, esto confirma que existe dependencia serial conjunta, concentrada en los primeros dos rezagos: las consultas de una semana influyen en las de la siguiente. La estructura es de memoria corta: la influencia se apaga rápidamente, por lo que el pronóstico a corto plazo puede mejorarse aprovechando la semana inmediatamente anterior, pero la previsión a más largo plazo se aproxima a la media. No se requieren transformaciones, pero sí un modelo que recoja la dependencia de corto plazo.