

Trabajo 1 - Tres series: descripción, operador de rezago, dependencia, pronóstico y argumentación

Por: Daniel Bustamante Cortés, Andrés Felipe López Díaz y Viviana Astrid León Oróstogue

Departamento de Estadística, Facultad de Ciencias
Universidad Nacional de Colombia – Sede Medellín

Series de Tiempo (3009297)

Docente: Juan Pablo Valencia Arango

Octubre 15, 2026

Tabla de contenidos

Las tres series y la pregunta de pronóstico 3
Descripción del patrón 5
Operador de rezago 12
Dependencia y estacionariedad 21
Pronóstico y evaluación 34

Las tres series y la pregunta de pronóstico

(a) Para cada serie, una ficha verificada con código: nombre, unidad, frecuencia, fecha inicial y final, T, mínimo, máximo y media.

- Ficha técnica para la serie 1:

Atributo	Valor
Nombre	Casos mensuales de enfermedad diarreica aguda notificados
Unidad	Casos de enfermedad diarreica aguda notificados
Frecuencia	Mensual
Fecha inicial	2013-01-01
Fecha final	2025-12-01
Número de observaciones (T)	156
Mínimo	74
Máximo	311
Media	169.0448718

- Ficha técnica para la serie 2:

Atributo	Valor
Nombre	Afiliados activos a un programa de control de hipertensión
Unidad	Personas inscritas y activas en el programa de control de hipertensión arterial
Frecuencia	Semanal
Fecha inicial	2022-12-05
Fecha final	2025-12-22
Número de observaciones (T)	160
Mínimo	48
Máximo	478
Media	218.1625

- Ficha técnica para la serie 3:

Atributo	Valor
Nombre	Consultas semanales por enfermedad respiratoria en un hospital

Atributo	Valor
Unidad	Consultas de medicina general cuyo motivo principal es una enfermedad respiratoria
Frecuencia	Semanal
Fecha inicial	2021-01-04
Fecha final	2025-08-04
Número de observaciones (T)	240
Mínimo	99
Máximo	146
Media	121.1416667

(b) Para cada serie, a partir del contexto, la pregunta de pronóstico escrita por el equipo, la decisión que depende de la respuesta y el horizonte H que esa decisión exige, en dos o tres líneas y coherente con la unidad y la frecuencia de la serie.

- Para la serie 1: *¿Cuántos casos mensuales de EDA se esperarán el siguiente año?* La idea es pronosticar mensualmente los casos para los próximos 12 meses ($H = 12$). La decisión es programar con tres meses de anticipación las brigadas y las compras de sales, con el fin de asignar el presupuesto anual aprobado en noviembre y evitar el doble de costo que implicarían las contrataciones de urgencia ante un brote. El horizonte cubre un año completo, lo cual permite planificar el presupuesto y las brigadas para cada mes del año que sigue.
- Para la serie 2: *¿Cuántas dosis de medicamento semanales para la hipertensión se deben considerar para la siguiente compra?* La decisión es hallar la cantidad de medicamento que logre un equilibrio entre escasez y vencimiento de las dosis. Se desea pronosticar semanalmente los afiliados para las próximas 6 semanas ($H = 6$), pues la compra se hace cada cuatro semanas y hay un plazo de entrega de dos.
- Para la serie 3: *¿Cuántas consultas por enfermedades respiratorias se esperan en la semana del próximo bloque, y por tanto, cuántos médicos adicionales se deben contratar para tratar estas consultas?* La decisión es encontrar el número óptimo de médicos que minimize el número de pacientes en urgencias, sin representar una carga económica elevada por el número de personal. El objetivo es pronosticar semanalmente la cantidad de médicos a contratar para las siguientes 6 semanas ($H = 6$), debido a que los médicos adicionales se contratan por cuatro semanas con dos de anticipación.

(c) Una tabla de las tres series con la partición de la sección de reglas: n_0, H, número de orígenes para $h = 1$ y para H, y fechas que delimitan cada tramo.

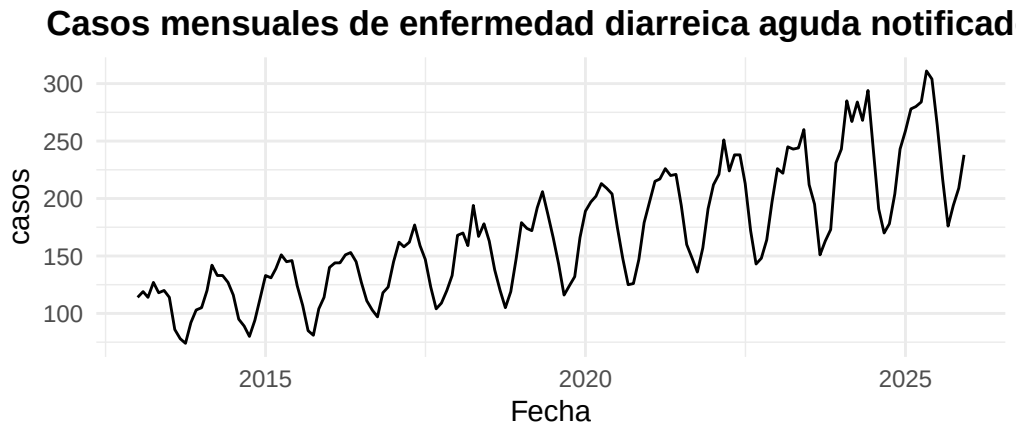
Serie	n_0	H	Número de orígenes $h = 1$	Número de orígenes $h = H$	Fechas de entrena-miento	Fechas de evaluación
1	124	12	32	21	2013-01-01 hasta 2023-04-01	2023-05-01 hasta 2025-12-01
2	128	6	32	27	2022-12-05 hasta 2025-05-12	2025-05-19 hasta 2025-12-22
3	192	6	48	43	2021-01-04 hasta 2024-09-02	2024-09-09 hasta 2025-08-04

Descripción del patrón

(a) Para cada serie, el gráfico en el tiempo, con título, ejes con nombre y unidad, eje de fechas legible y un caption con el número de observaciones, y el gráfico de rezagos de y_t contra y_{t-k} para los rezagos que el equipo juzgue informativos, justificando la elección.

Para definir el número de rezagos en cada gráfico de rezagos para las 3 series se tuvo en cuenta la información previamente definida del horizonte H, en cada caso. En la serie 1, 12 rezagos permiten ver el comportamiento dentro de un año, en la serie 2 y 3, al ser semanales y ambas tener un horizonte de 6 un rezago igual a este valor permite observar que pasa en este lapso de tiempo, que es el de interés.

```
g1 <- graficar_serie(datos1, titulo = "Casos mensuales de enfermedad diarreica aguda notifica
g2 <- grafico_rezagos(datos = datos1, k = 12)
g1 / g2
```



Número de observaciones: 156



La serie de casos mensuales de EDA presenta una tendencia creciente a lo largo del tiempo, junto a un patrón estacional. El gráfico de rezagos muestra una relación lineal positiva entre las observaciones presentes (y_t) y pasadas (y_{t-12}), lo que confirma una alta autocorrelación y una fuerte dependencia estructural en los datos.

```
g1 <- graficar_serie(datos2, titulo = "Afiliados activos al programa de control de hipertensi
g2 <- grafico_rezagos(datos = datos2, k = 6)
g1 / g2
```

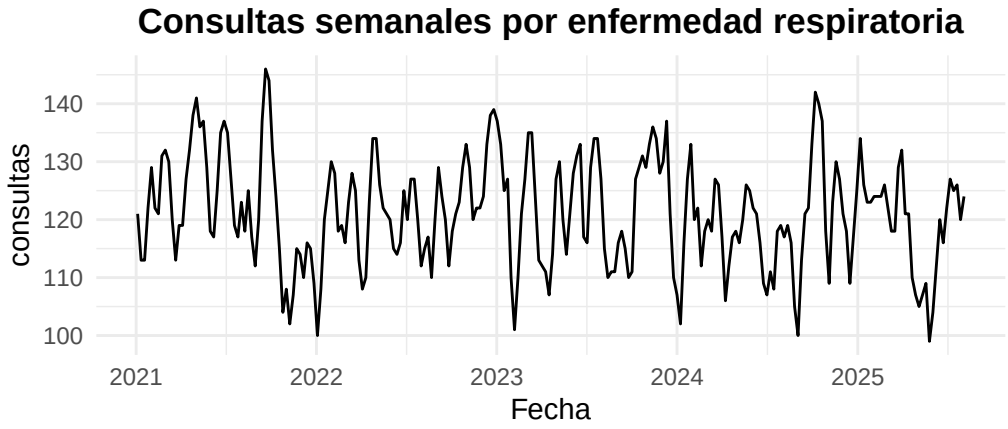


Número de observaciones: 160

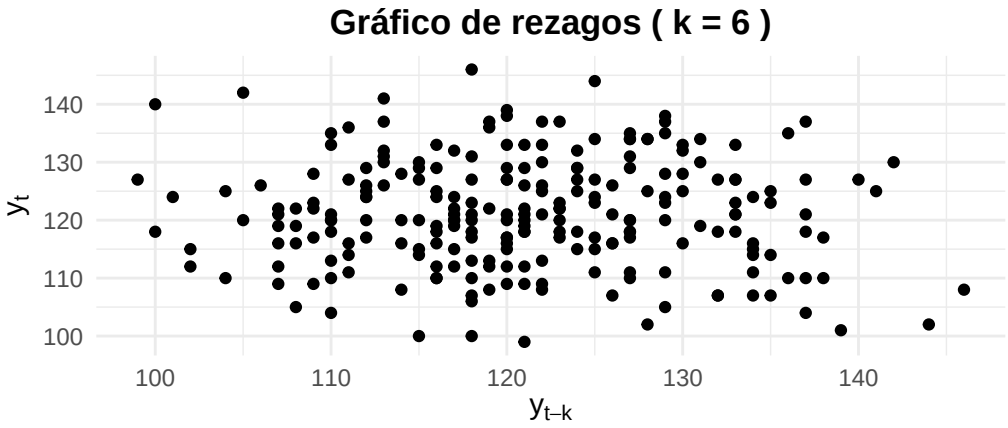


La serie de afiliados activos del programa de control de hipertensión presenta una tendencia creciente a lo largo del tiempo. El gráfico de rezagos muestra una relación lineal positiva entre las observaciones presentes (y_t) y pasadas (y_{t-6}), lo que confirma una alta autocorrelación y una fuerte dependencia estructural en los datos.

```
g1 <- graficar_serie(datos3, titulo = "Consultas semanales por enfermedad respiratoria")
g2 <- grafico_rezagos(datos = datos3, k = 6)
g1 / g2
```



Número de observaciones: 240



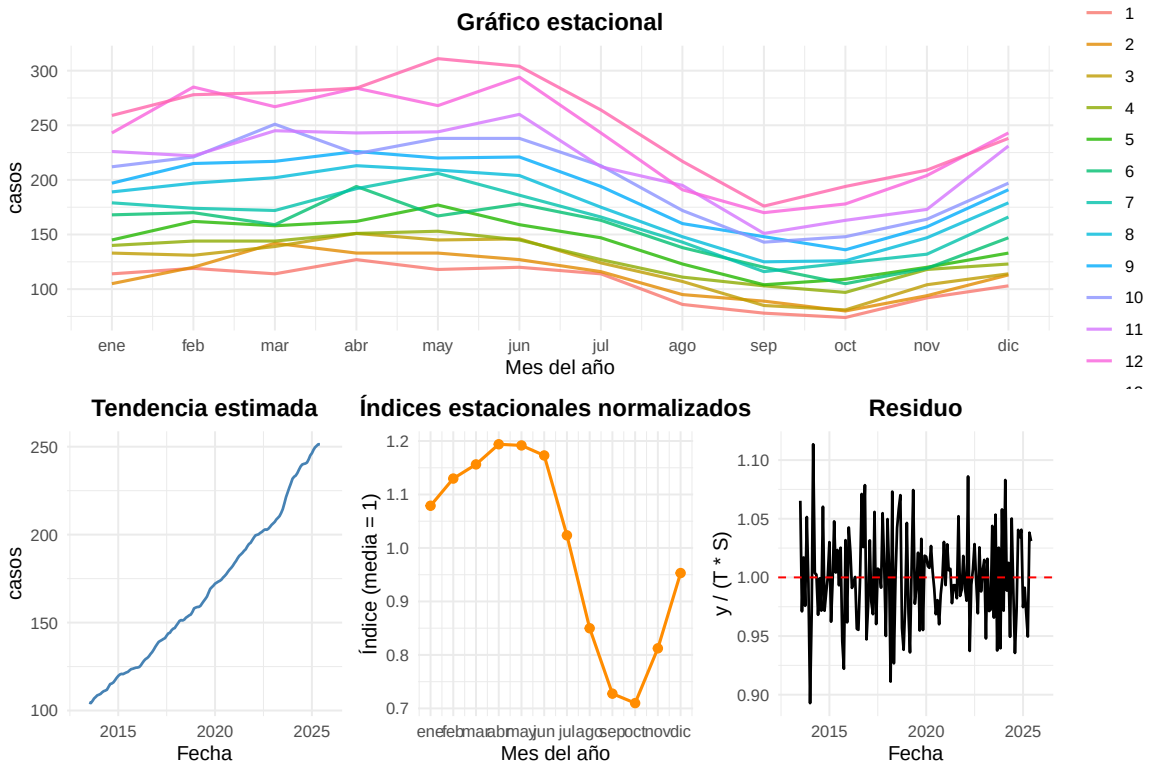
La serie de consultas semanales por enfermedad respiratoria no parece presentar ni tendencia ni estacionalidad. El gráfico de rezagos no muestra una relación lineal entre las observaciones presentes (y_t) y pasadas (y_{t-6}), por lo que no parece haber una fuerte dependencia estructural en los datos.

(b) Para cada serie, la decisión argumentada sobre si tiene estacionalidad y, si la tiene, cuál es su período. Toda serie a la cual el equipo le atribuya estacionalidad lleva el gráfico estacional, con un trazo por ciclo sobre el índice de estación, y una descomposición clásica programada a mano con una media móvil centrada, en la versión aditiva o multiplicativa, cuya elección se justifica con evidencia gráfica y numérica; se muestran la tendencia estimada, los índices estacionales normalizados y el residuo. Toda serie a la cual no se le atribuya estacionalidad lleva la evidencia que lo sostiene.

Como se vió en el punto anterior, la única serie que parece tener estacionalidad es la 1, con período $s = 12$, pues hay un solo ciclo por año, se nota un solo pico y un solo valle por año. Además, la amplitud estacional crece con el nivel general, por lo que se elige una descomposición

multiplicativa: $y_t = T_t \times S_t \times R_t$. La media móvil centrada suaviza la tendencia y, al sacar la tendencia, los índices estacionales normalizados muestran que los meses de marzo a junio son sistemáticamente superiores a la media anual, mientras que septiembre y octubre son los más bajos. El residuo se mantiene alrededor de cero sin un patrón anual claro, lo que refuerza la decisión de atribuir estacionalidad a la serie 1.

```
grafico_estacional(datos = datos1, s = 12, tipo = "multiplicativo")
```

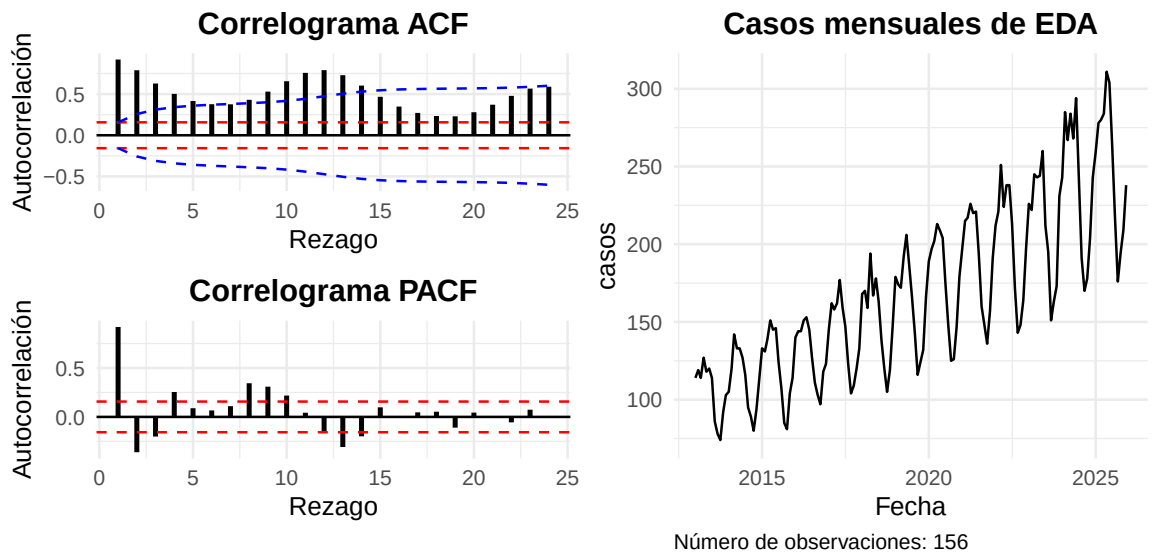


En la descomposición, la tendencia estimada es creciente a lo largo del periodo, los índices estacionales normalizados tienen valores alrededor de 1 y capturan la estructura anual del brote diarreico, y el residuo no presenta un patrón sistemático restante. Por tanto, la serie 1 se clasifica como una serie con tendencia creciente y estacionalidad anual de tipo multiplicativo.

(c) Para cada serie, la clasificación de su patrón, apoyada en el gráfico y en el correlograma de la serie sin transformar con $m = mn\lfloor T/4 \rfloor, 24$ rezagos, con la lectura de la forma de ese correlograma.

- Para la serie 1:

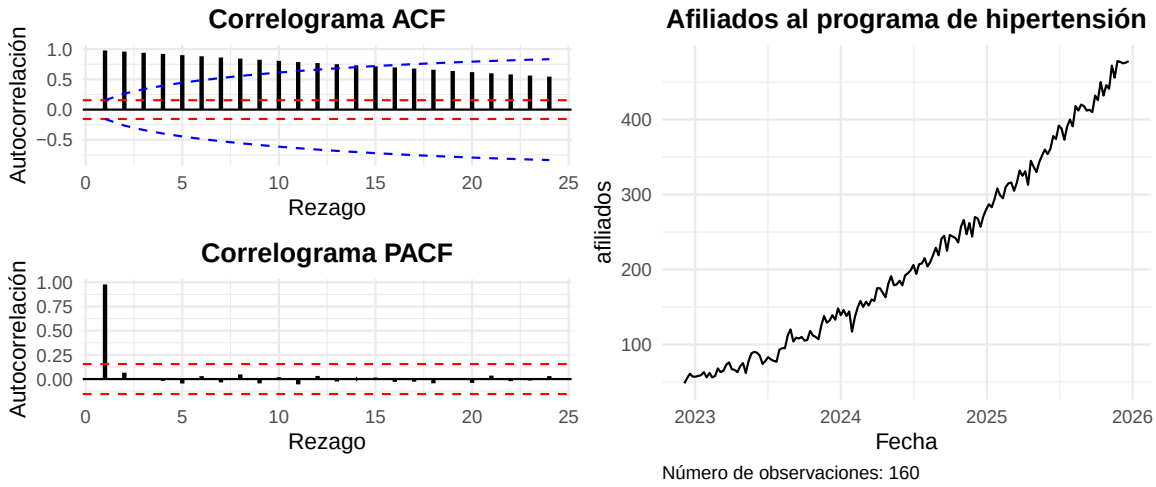
```
m <- min(length(datos1$y), 24)
a <- correlograma(datos1, m)
b <- graficar_serie(datos1, titulo = "Casos mensuales de EDA")
a | b
```



En los primeros rezagos, el correlograma tiene autocorrelaciones altamente significativas, las cuales van disminuyendo lentamente a medida que el rezago crece, esto indica tendencia. Por otro lado, sobre el comportamiento descrito se notan picos cuando el rezago es multiplo de 12 (serie mensual), por lo que la serie parece tener estacionalidad. Estas características son aún más claras en la serie.

- Para la serie 2:

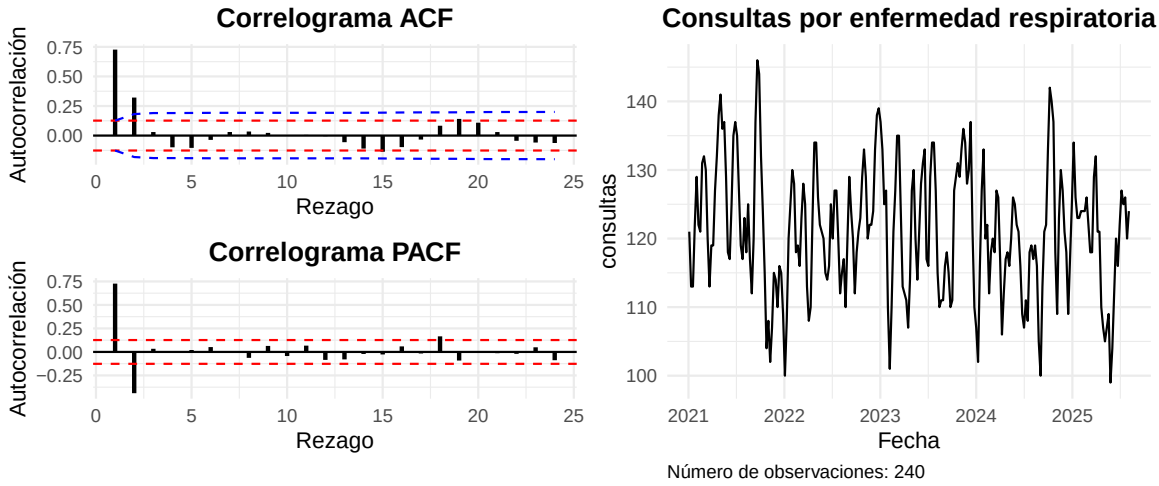
```
m <- min(length(datos2$y), 24)
a <- correlograma(datos2, m)
b <- graficar_serie(datos2, titulo = "Afiliados al programa de hipertensión")
a | b
```



El comportamiento de decaimiento lento en el correlograma es evidencia clara de que la serie sin transformaciones tiene tendencia. Con base en el gráfico de la serie se recalca lo ya dicho y se observa que la tendencia es de crecimiento.

- Para la serie 3:

```
m <- min(length(datos3$y), 24)
a <- correlograma(datos3, m)
b <- graficar_serie(datos3, titulo = "Consultas por enfermedad respiratoria")
a | b
```



Para este caso no se logran identificar patrones de estacionalidad o tendencia de la serie relacionada a las consultas por enfermedades respiratorias. No parece haber una estructura

visible clara ni muchos rezagos que superen la banda. Aunque si se nota un nivel constante, pues en el gráfico de la serie se nota que se oscila siempre sobre 120 aproximadamente.

Operador de rezago

(a) Escriba `diferenciar(y, d, D, s)`, que aplica $(1-B)^d(1-B^s)^D$ sin usar `diff()`, y `polinomio_rezago(coef)`, que recibe los coeficientes de $c(B) = 1 + c_1B + \cdots + c_pB^p$ y devuelve sus raíces con su módulo. Verifique `diferenciar()` contra `diff()` en un bloque de verificación.

```
# Código de verificación de diferenciar() vs. diff()
set.seed(67)
y_prueba <- rnorm(15)

d_prueba <- 1
D_prueba <- 1
s_prueba <- 12

res_manual <- diferenciar(y_prueba, d = d_prueba, D = D_prueba, s = s_prueba)

res_diff <- diff(y_prueba, lag = s_prueba, differences = D_prueba)
res_diff <- diff(res_diff, lag = 1, differences = d_prueba)
print("diferenciar vs. diff")
```

```
[1] "diferenciar vs. diff"
```

```
print(res_manual);print(res_diff)
```

```
[1] 0.02991735 1.71525811
```

```
[1] 0.02991735 1.71525811
```

```
print("c(B) = 1 - 2B + 3B^2")
```

```
[1] "c(B) = 1 - 2B + 3B^2"
```

```
print("Raíces y módulos del polinomio de prueba:")
```

```
[1] "Raíces y módulos del polinomio de prueba:"
```

```
print(polinomio_rezago(c(-2, 3)))
```

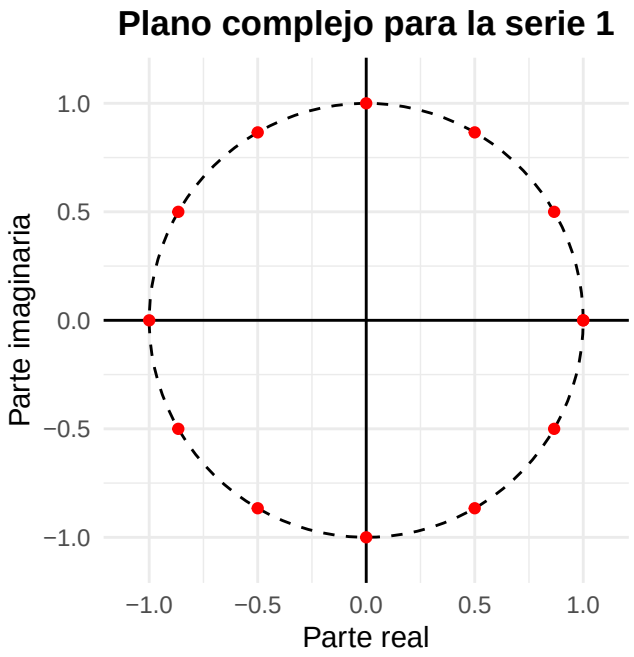
```
                  Raiz    Modulo
1 0.3333333+0.4714045i 0.5773503
2 0.3333333-0.4714045i 0.5773503
```

(b) Para cada serie, proponga las transformaciones candidatas que su diagnóstico sugiere, incluidas las transformaciones previas de escala si las hay, y escriba cada una como polinomio en B. Calcule las raíces de cada polinomio con `polinomio_rezago()`, ubíquelas en el plano complejo y explique qué componente determinista elimina cada factor.

- Serie 1: Ya vimos que esta serie tiene tendencia y estacionalidad con período 12, por lo que se aplica una diferencia para quitar la tendencia y una estacional para la estacionalidad. Además, esta serie tiene comportamiento multiplicativo, pues a medida que pasa el tiempo la amplitud de las variaciones estacionales crece, debido a esto lo ideal es aplicar una transformación a los datos, un logaritmo natural. Se tendría entonces,

$$\nabla_1 \nabla_{12} \ln(y_t) = (1-B)(1-B^{12}) = 1 - B^{12} - B + B^{13} = 1 - B - B^{12} + B^{13}$$

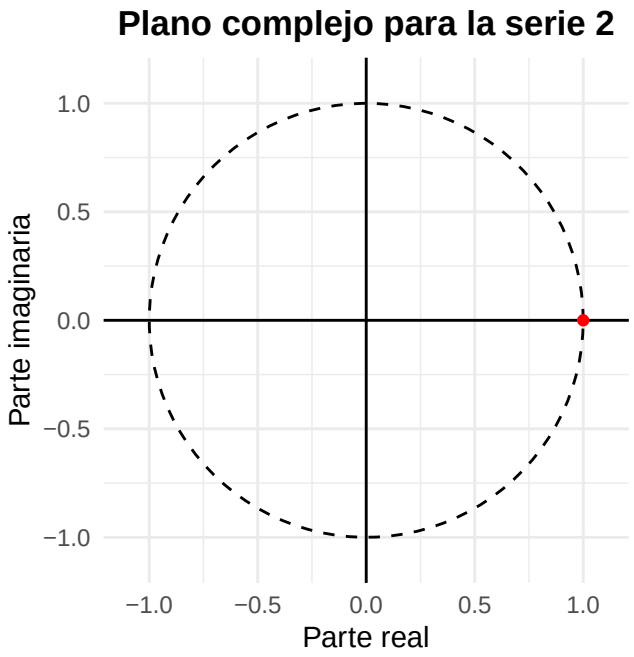
```
datos1$log <- log(datos1$y)
coefs_1 <- c(-1, rep(0, 10), -1, 1)
raices_1 <- polinomio_rezago(coefs_1)
df1 <- data.frame(Parte_Real = Re(raices_1$Raiz),
                  Parte_imaginaria = Im(raices_1$Raiz))
ggplot(df1, aes(x = Parte_Real, y = Parte_imaginaria)) +
  annotate("path", x = cos(seq(0, 2*pi, length.out = 100)),
           y = sin(seq(0, 2*pi, length.out = 100)), linetype = "dashed") +
  geom_hline(yintercept = 0) +
  geom_vline(xintercept = 0) +
  geom_point(color = "red") +
  labs(title = "Plano complejo para la serie 1", x = "Parte real",
       y = "Parte imaginaria") +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5)) +
  coord_fixed(ratio = 1, xlim = c(-1.1, 1.1), ylim = c(-1.1, 1.1))
```



- Serie 2: Esta serie cuanta con tendencia, por lo que es suficiente aplicar una diferencia para eliminarla:

$$\nabla_1 = (1 - B)$$

```
coefs_2 <- c(-1)
raices_2 <- polinomio_rezago(coefs_2)
df2 <- data.frame(Parte_Real = Re(raices_2$Raiz),
                  Parte_imaginaria = Im(raices_2$Raiz))
ggplot(df2, aes(x = Parte_Real, y = Parte_imaginaria)) +
  annotate("path", x = cos(seq(0, 2*pi, length.out = 100)),
           y = sin(seq(0, 2*pi, length.out = 100)), linetype = "dashed") +
  geom_hline(yintercept = 0) +
  geom_vline(xintercept = 0) +
  geom_point(color = "red") +
  labs(title = "Plano complejo para la serie 2", x = "Parte real",
       y = "Parte imaginaria") +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5)) +
  coord_fixed(ratio = 1, xlim = c(-1.1, 1.1), ylim = c(-1.1, 1.1))
```



- Serie 3: No es necesario aplicar transformaciones, pues no se presentó ni estacionalidad ni tendencia. El polinomio sería igual a 1, por tanto no tiene sentido hacer la gráfica ya que no habría puntos.

(c) Para cada serie, una tabla con la varianza muestral y r_1 de la serie y de cada transformación candidata. Elija la transformación con la cual la serie resultante es plausiblemente estacionaria, que puede ser ninguna, y defienda que no aplica diferencias de más, con la identidad $Var(\nabla Y_t) = 2\gamma(0) - 2\gamma(1)$ y con lo que le ocurre a r_1 cuando se diferencia una serie que ya era estacionaria. Verifique sobre los datos que la media de la serie transformada coincide con lo que la transformación debe dejar.

- Serie 1:

```
resumen_serie <- function(x){
  x <- na.omit(x)
  n <- length(x)
  if (n < 2) return(c(media=NA, varianza=NA, r1=NA))
  media <- mean(x)
  varianza <- var(x) * (n-1)/n
  r1 <- cor(x[-1], x[-n])
  return(c(media = media, varianza = varianza, r1 = r1))
}
```

```r
datos1$logy <- log(datos1$y)
datos1$dif1_logy <- c(NA, diferenciar(datos1$logy, d = 1, D = 0, s = 12))
datos1$dif12_logy <- c(rep(NA, 12), diferenciar(datos1$logy, d = 0, D = 1, s = 12))
datos1$dif_est_logy <- c(rep(NA, 13), diferenciar(datos1$logy, d = 1, D = 1, s = 12))

datos2$dif_y <- c(NA, diferenciar(datos2$y, d = 1, D = 0, s = 1))
datos3$dif_y <- c(NA, diferenciar(datos3$y, d = 1, D = 0, s = 1))
```

Por el inciso anterior se sabe que para la serie 1 la transformacion que se aplica es una diferencia para quitar la tendencia y una estacional para la estacionalidad, sin embargo vamos a ilustrar una tabla con cuatro escenarios, es decir, serie original comparada ante las transformaciones para esta serie, con el fin de ver el paso a paso:

```r
s1_ori   <- resumen_serie(datos1$y)
s1_log   <- resumen_serie(datos1$logy)
s1_d1    <- resumen_serie(datos1$dif1_logy)
s1_d12 <- resumen_serie(datos1$dif12_logy)
s1_d1d12 <- resumen_serie(datos1$dif_est_logy)
t1 <- data.frame(
  row.names = c("Original", "Logaritmo", "Log + Dif(1)", "Log + Dif(12)", "Log + Dif(1) + Di
  media = c(s1_ori["media"], s1_log["media"], s1_d1["media"], s1_d12["media"],  s1_d1d12["me
  varianza  = c(s1_ori["varianza"],s1_log["varianza"],s1_d1["varianza"],s1_d12["varianza"],s
  r1 = c(s1_ori["r1"], s1_log["r1"], s1_d1["r1"], s1_d12["r1"], s1_d1d12["r1"]))

round(t1, 4)
```

```
                          media  varianza      r1
Original                169.0449 2970.1711  0.9271
Logaritmo                 5.0779    0.1062  0.9269
Log + Dif(1)              0.0047    0.0155  0.4181
Log + Dif(12)             0.0727    0.0037 -0.0678
Log + Dif(1) + Dif(12)    0.0004    0.0077 -0.5580
```

La diferencia estacional del logaritmo tiene r_1 cercano a cero y varianza muestral aproximada de 0.00370. Al agregar la diferencia ordinaria, la varianza sube a aproximadamente 0.00771 y r_1 cae a aproximadamente -0.558. Esta combinación de aumento de varianza y autocorrelación negativa marcada es una señal de que la diferencia ordinaria adicional puede estar sobrando. Por tanto, con la evidencia disponible, la elección preferible es $\nabla_{12} \log(Y_t)$

$$\hat{\gamma}(1) = r_1 \times \hat{\gamma}(0) = (-0.0678 \times 0.0037) = -0.0002509$$
$$2\hat{\gamma}(0) - 2\hat{\gamma}(1) \approx 2(0.0037) - 2(-0.0002509) \approx 0.007902$$

La varianza muestral observada de la diferencia ordinaria adicional es aproximadamente 0.0077, cercana a ese valor teórico aproximado. Esto indica que una diferencia más duplica la varianza muestral de la serie 1, no aportando evidencia a favor de usarla.

La media resultante es aproximadamente (0.0727), se interpreta como el incremento logarítmico anual promedio, no como una media que la transformación deba forzar a cero. En la escala original equivale a un crecimiento anual promedio aproximado de 7.5 %.

```
n <- length(datos1$logy)
(sum(tail(datos1$logy, 12)) - sum(head(datos1$logy, 12))) / (n - 12)
```

```
[1] 0.07272296
```

- Serie 2:

```
s2_ori  <- resumen_serie(datos2$y)
s2_d1   <- resumen_serie(datos2$dif_y)

t2 <- data.frame(
  row.names = c("Original", "Dif(1)"),
  media     = c(s2_ori["media"],  s2_d1["media"]),
  varianza  = c(s2_ori["varianza"],s2_d1["varianza"]),
  r1        = c(s2_ori["r1"],      s2_d1["r1"]))
round(t2, 4)
```

```
            media   varianza      r1
Original 218.1625 16332.6861  0.9964
Dif(1)     2.7044   117.3151 -0.4455
```

La serie original presenta $r_1 = 0.9964$, lo que evidencia una tendencia determinista fuerte y confirma que no es estacionaria. La varianza elevada (tendencia hace que los valores se alejen de la media) y la media no estable refuerzan la necesidad de transformación. La gran reducción de varianza (de 16332 a 118) prueba que la primera diferencia era necesaria para extraer la señal de la tendencia. Una segunda diferencia no tendría tendencia que eliminar y solo introduciría ruido. En cuanto a la media, este valor no es cero, sino que representa el crecimiento promedio semanal de los afiliados, lo cual es exactamente lo que debe dejar una primera diferencia cuando la serie original crece de forma constante.

PASO 1: calcular para la serie original

$$\begin{aligned}\gamma(1) &= 0.9964 \times 16332.6861 = 16273.89 \\ \text{Var}(\nabla Y_t)_{\text{teórica}} &= 2(16332.6861) - 2(16273.89) \\ &= 32665.37 - 32547.78 = \mathbf{117.59}\end{aligned}$$

Se observa que la varianza cae drásticamente, por lo que se confirma que la primera diferencia remueve la tendencia.

PASO 2: calcular sobre la serie ya diferenciada(dif1)

$$\begin{aligned}\gamma(0) &= 117.3151, \quad r_1 = -0.4455 \\ \gamma(1) &= -0.4455 \times 117.3151 = -52.26 \\ \text{Var}(\nabla^2 Y_t)_{\text{teórica}} &= 2(117.3151) - 2(-52.26) \\ &= 234.63 + 104.52 = \mathbf{339.15}\end{aligned}$$

Se observa que la varianza subiría de 117.32 a 339.15 claramente aumenta, lo cual es una señal de sobrediferenciación. Así que se para en este punto.

La media no se espera que sea cero, porque la serie crece de forma casi constante. Lo que deja una primera diferencia es la pendiente promedio y la verificación confirma que ese número sale solo de los extremos de la serie.

```
y <- datos2$y
n <- length(y)

media_dif <- mean(datos2$dif_y, na.rm = TRUE)
media_teor<- (y[n] - y[1]) / (n - 1)

c(observada = media_dif, teorica = media_teor)
```

```
observada   teorica
 2.704403  2.704403
```

- Serie 3:

Ahora para la serie 3 vamos a calcular la tabla suponiendo que SI se aplicara una sola diferencia solo para hacer una comparacion y defender que no se usan diferencias en este caso.

```r
s3_ori <- resumen_serie(datos3$y)
s3_d1 <- resumen_serie(datos3$dif_y)

t3 <- data.frame(
  row.names = c("Original", "Dif(1)"),
  media     = c(s3_ori["media"],  s3_d1["media"]),
  varianza  = c(s3_ori["varianza"],s3_d1["varianza"]),
  r1        = c(s3_ori["r1"],      s3_d1["r1"]))

round(t3, 4)
```

```
            media varianza     r1
Original 121.1417  86.6299 0.7271
Dif(1)     0.0126  47.4768 0.2445
```

La varianza baja al diferenciar, pero eso no es evidencia a favor de diferenciar. Por la identidad, la varianza disminuye siempre que r > 0.5, y aquí r $= 0.7271$. La identidad se cumple: $2\gamma(0) - 2\gamma(1) = 2 * 86.63 - 2 * (0.7271 * 86.63) = 47.28 \approx (\nabla Y_t)$,pero es un chequeo algebraico, no una prueba de estacionariedad. En esta serie el criterio de varianza no sirve para detectar sobrediferenciación, así que la decisión se apoya en el diagnóstico: no hay tendencia ni estacionalidad en el gráfico, el nivel oscila alrededor de 121 y la ACF cae rápido tras el rezago 2. No hay ninguna componente determinista que una diferencia deba eliminar. Diferenciar solo destruiría el nivel, pues la media pasa de 121.14 a 0.0126, y el r de 0.7271 a 0.2445.

Su media ($\bar{x} = 121.1417$) representa el nivel promedio estable de consultas respiratorias. Si se aplicara diferencia, la media pasaría a ser 0, perdiendo toda interpretación del nivel.

```r
y <- datos3$y
n <- length(y)
c(media_dif = mean(diferenciar(y, 1, 0, 1)),
  teorica_dif = (y[n] - y[1]) / (n - 1))
```

```
  media_dif teorica_dif
  0.0125523   0.0125523
```

(d) A mano, en el informe. Pruebe que la función de pronóstico de Holt, $\hat{Y}_{T+h} = L_T + \hat{T}_T h$, satisface $(1-B)^2 \hat{Y}_{T+h} = 0$ para $h \geq 3$, y que la de Holt–Winters aditivo con período s, $\hat{Y}_{T+h} = L_T + \hat{T}_T h + S_{T+h-s\lceil h/s \rceil}$, satisface $(1 - B)(1 - B^s)\hat{Y}_{T+h} = 0$ para $h \geq s + 2$, con el operador actuando sobre h. Escriba la solución general de cada ecuación en diferencias y diga qué raíces del polinomio característico corresponden a la tendencia y cuáles a la estacionalidad.

- Demostración de que $\hat{Y}_{T+h} = L_T + \hat{T}_T h$ satisface $(1-B)^2\hat{Y}_{T+h} = 0$ para $h \geq 3$:

$$\begin{aligned}(1-B)^2\hat{Y}_{T+h} &= (1-2B+B^2)\hat{Y}_{T+h}\\ &= \hat{Y}_{T+h} - 2B\hat{Y}_{T+h} + B^2\hat{Y}_{T+h}\\ &= \hat{Y}_{T+h} - 2\hat{Y}_{T+h-1} + \hat{Y}_{T+h-2}\\ &= L_T + \hat{T}_T h - 2[L_T + \hat{T}_T(h-1)] + L_T + \hat{T}_T(h-2)\\ &= L_T + \hat{T}_T h - 2L_T - 2\hat{T}_T h + 2\hat{T}_T + L_T + \hat{T}_T h - 2\hat{T}_T\\ &= (2L_T - 2L_T) + (2\hat{T}_T h - 2\hat{T}_T h) + (2\hat{T} - 2\hat{T})\\ &= 0\end{aligned}$$

- Demostración de que $\hat{Y}_{T+h} = L_T + \hat{T}_T h + S_{T+h-s\lceil h/s\rceil}$, satisface $(1-B)(1-B^s)\hat{Y}_{T+h} = 0$ para $h \geq s+2$:

$$\begin{aligned}(1-B^s)\hat{Y}_{T+h} &= \hat{Y}_{T+h} - \hat{Y}_{T+h-s}\\ &= L_T + \hat{T}_T h + S_{T+h-s\lceil h/s\rceil} - L_T - \hat{T}_T(h-s) - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T h - \hat{T}_T h + \hat{T}_T s + S_{T+h-s\lceil h/s\rceil}\\ &\quad - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T s + S_{T+h-s\lceil h/s\rceil} - S_{T+(h-s)-s\lceil (h-s)/s\rceil}\\ &= \hat{T}_T s + S_{T+h-s\lceil h/s\rceil} - S_{T+h-s\lceil h/s\rceil}\\ &= \hat{T}_T s\end{aligned}$$

$$\begin{aligned}(1-B)(1-B^s)\hat{Y}_{T+h} &= (1-B)(\hat{T}_T s)\\ &= \hat{T}_T s - \hat{T}_T s \ (No\ depende\ de\ h)\\ &= 0\end{aligned}$$

Se tiene que $h \geq s+2$, pues asegura que el menor valor posible para $h-s-1$ sea 1, un horizonte menor a 1 no tiene sentido.

Para Holt $(1-B)^2 = 0$ la raíz es $B = 1$ con multiplicidad 2. La solución general para una raíz como esta está dada por:

$\hat{Y}_{T+h} = c_1 + c_2 h$

Para Holt-Winters $(1-B)(1-B^s) = 0$ el factor $(1-B)$ aporta una raíz $B = 1$ y el factor $(1-B^s)$ aporta s raíces de la forma $B = e^{i2\pi k/s},\ k = 0, 1, 2, ..., s-1$. Hay $s+1$ raíces, con solución general:

$\hat{Y}_{T+h} = c_1 + c_2 h + \sum_{k=1}^{\lfloor s/2\rfloor} \alpha_k cos(\frac{2\pi kh}{s}) + \beta_k sin(\frac{2\pi kh}{s})$ La raíz $B = 1$ corresponde a la tendencia de la serie, mientras que las raíces $B = e^{i2\pi k/s}$ se refieren a la estacionalidad de período s.

Dependencia y estacionariedad

(a) Escriba `pacf_dl(r)`, la autocorrelación parcial muestral por la recursión de Durbin y Levinson a partir de $r_1, ..., r_m$, y verifíquela contra `pacf()` con máxima diferencia absoluta menor que 10^{-10}. Para cada serie presente ACF y PACF muestrales hasta el rezago m, con la banda de ruido blanco $\pm 1,96/\sqrt{n}$ y la banda de Bartlett $\pm 1,96\sqrt{(1+2\sum_{i<h} r_i^2)/n}$, y diga cuál de las dos corresponde a cada pregunta que se le hace al correlograma.

Para comparar `pacf()` contra `pacf_dl(r)` se usa los datos de la serie 1 transformada (logaritmo y diferencia estacional) con 24 rezagos :

```
a <- na.omit(datos1$dif12_logy)
acfs <- acf_muestral(a, m = 24)
pacf_dl_ <- pacf_dl(r = acfs)
pacf_R <- pacf(a, lag.max = 24, plot = FALSE)$acf[, 1, 1]

max_dif <- max(abs(pacf_dl_ - pacf_R))
print(paste("Máxima diferencia absoluta: ", max_dif))
```

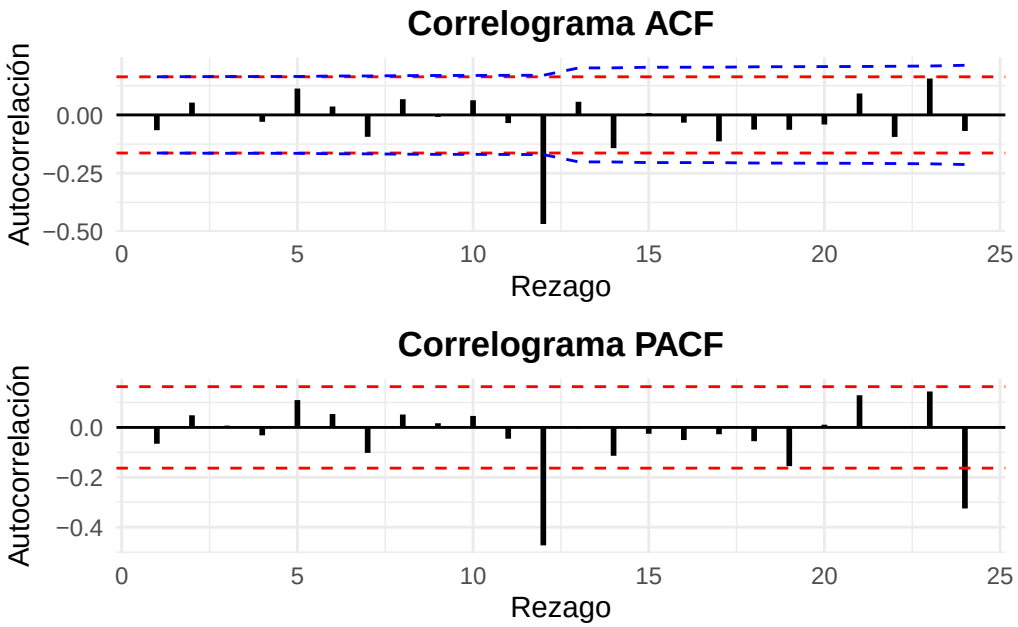
```
[1] "Máxima diferencia absoluta:  8.32667268468867e-16"
```

A continuación se presentan ACF y PACF muestrales para cada una de las series. Para esto se crea una nueva función, `correlograma_muestral(y, m)`, que usa las autocorrelaciones parciales determinadas con `pacf_dl(r)` en lugar de la función base de R `pacf()` como lo hace `correlograma()`. Esta función se creó en el archivo `informe.qmd`, sin embargo, se decidió no mostrarlo en el archivo pdf debido al tamaño extendido del código.

La banda de ruido blanco (roja) responde a ¿La serie es ruido blanco puro? Mientras que la banda de Bartlett responde a ¿El rezago h aporta algo significativo dado que los anteriores son reales?

- Para la serie 1:

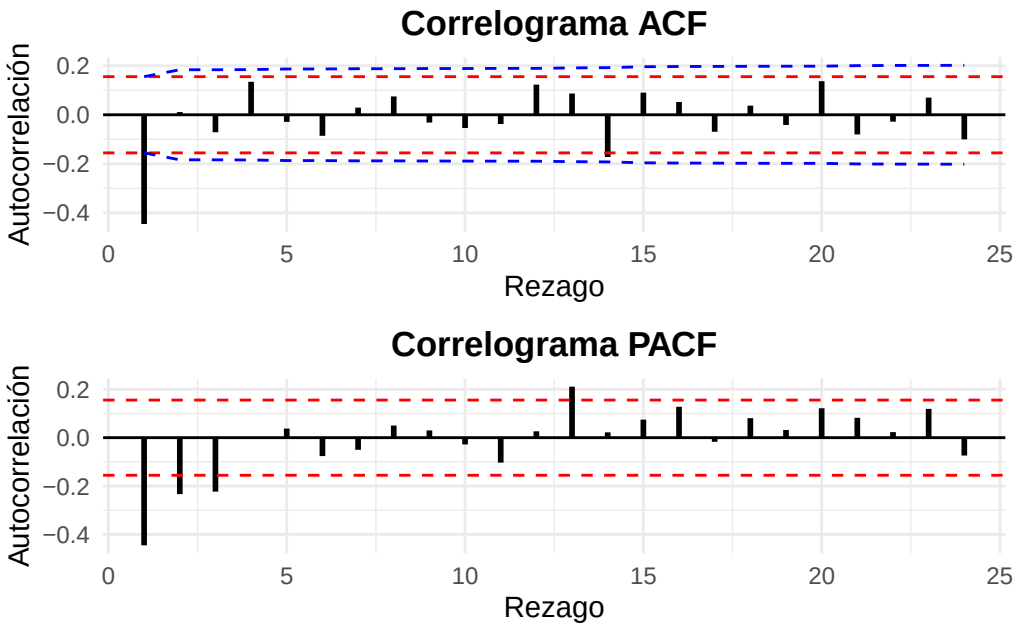
```
correlograma_muestral(y = datos1$dif12_logy, m = 24)
```



A partir del correlograma se nota que la ACF muestral es compatible con ruido blanco en todos los rezagos salvo el 12, donde supera tanto la banda de ruido blanco como la de Bartlett. La PACF presenta picos negativos en los rezagos 12 y 24 que decaen. Esa forma (ACF que se corta tras el rezago estacional y PACF que decae en múltiplos de 12) es la de una media móvil estacional de orden 1. No quedan tendencia ni dependencia de corto plazo relevante: los rezagos 1 a 11 están dentro de las bandas.

- Para la serie 2:

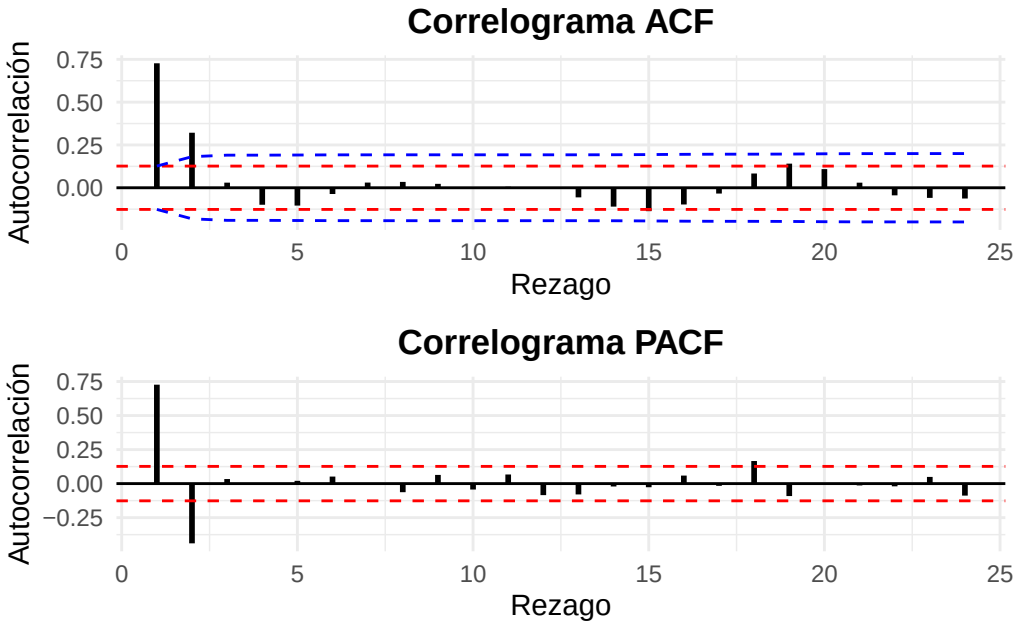
```
correlograma_muestral(y = datos2$dif_y, m = 24)
```



La ACF muestral se corta después del rezago 1 y los demás rezagos están dentro de las bandas, excepto el rezago 14. La PACF decae con signo negativo (en los rezagos 1 a 3). Esa forma es la de una media móvil de orden 1, MA(1), con coeficiente negativo. No hay picos en múltiplos de ningún período, así que no se observa estacionalidad.

- Para la serie 3:

```
correlograma_muestral(y = datos3$y, m = 24)
```



En cuanto a la banda de ruido blanco, se puede observar que los rezagos 1 y 2 tienen autocorrelaciones significativas, por lo que sí parece haber estructura temporal. Los rezagos 1 y 2 se salen de la banda de Bartlett, pero a partir del rezago 3, las autocorrelaciones caen y se mantienen dentro de esta banda, esto es evidencia de que la memoria de la serie se apaga rápidamente y se corta después del segundo periodo.

(b) Para cada serie, la prueba de Ljung–Box con sus seis elementos, con m elegido y justificado, y la lectura de la forma de la ACF y de la PACF. Diga con qué proceso de los estudiados en clase es compatible esa forma y con cuáles no, y por qué.

Los seis elementos de la prueba de Ljung-Box para las tres series son:

1. Hipotesis nula y alternativa:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_{24} = 0 \quad : \text{la serie es ruido blanco.}$$
$$H_a : \exists k \in \{1, 2, \ldots, 24\} \quad \text{tal que } \rho_k \neq 0 \quad : \text{existe dependencia serial.}$$

2. Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$Q = n(n+2) \sum_{k=1}^{m} \frac{r_k^2}{n-k}$$

Donde: - n es el número de observaciones, - r_k es la autocorrelación muestral al rezago k, - m es el número de rezagos evaluados.

Bajo H_0, el estadístico Q sigue una distribución:

$$Q \xrightarrow{d} \chi^2_{(m)}$$

3. Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

4. Valor observado del estadístico y valor p

- Q_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

5. Decision

Se compara Q_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $Q_{\text{obs}} > \chi^2_{m,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, no se rechaza H_0.

6. Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de dependencia del fenómeno:

- Si se rechaza H_0, existe dependencia serial, la serie no es ruido blanco, presenta estructura temporal compatible con procesos autorregresivos, de media móvil o mixtos ARMA.
- Si no se rechaza H_0, no hay evidencia de dependencia serial, la serie se comporta como ruido blanco, no hay patrón temporal predecible.

Serie 1: Casos mensuales de EDA (transformada):

$$w_t = (1 - B^{12}) \ln(y_t)$$

- PASO 1: elección de m

Se toma $m = 24$ rezagos, justificado por:

- Regla del trabajo: $m = \text{mín}\left(\left\lfloor \frac{T}{4} \right\rfloor, 24\right) = \text{mín}(36,\, 24) = 24$.
- La serie tiene período estacional $s = 12$; revisar dos ciclos completos permite detectar estructura de dependencia estacional remanente.

- PASO 2: aplicar la prueba

```
z <- as.numeric(na.omit(datos1$dif12_logy))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 56.73398

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 0.0001819201
```

Se rechaza H_0 por tanto hay evidencia estadistica para sugerir que aunque se eliminó la tendencia y la estacionalidad anual, persiste estructura de dependencia remanente: las autocorrelaciones conjuntas no son nulas. El patrón sugiere que la serie transformada aún guarda memoria, por lo que un modelo autorregresivo estacional podría capturar esa dependencia y mejorar el pronóstico respecto a métodos más simples. Los valores de casos en meses anteriores siguen informando sobre los casos futuros, más allá del comportamiento anual y el crecimiento general.

Como se vió en el punto anterior el comportamiento presentado en los correlogramas es la de un proceso de Media Móvil Estacional de orden 1 ($SMA(1)$). No es compatible ruido una media móvil $MA(q)$ (la ACF sería distinta de cero en los rezagos 1 a q, no solo en el 12) y un $AR(p)$ (la PACF tiene picos en 12 y 24, no se corta).

Serie 2: Afiliados activos al programa de hipertensión (transformada):

$$w_t = (1 - B)y_t$$

- PASO 1: elección de m

$m = \text{mín}\left(\frac{159}{4}, 24\right) = 24$. Suficiente para capturar dependencia semanal sin exceder un cuarto de la muestra.

- PASO 2: aplicar la prueba

```r
z <- as.numeric(na.omit(datos2$dif_y))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 59.52425

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 7.453714e-05
```

Como podemos observar se rechaza H_0 por tanto hay evidencia estadistica para sugerir que la diferencia eliminó el crecimiento, pero no convirtió la serie en ruido blanco: subsiste dependencia serial significativa (relacionado con los valores anteriores), concentrada principalmente en los primeros rezagos. Esto significa que el número de afiliados de semanas anteriores sigue siendo un buen predictor del número de afiliados de la semana siguiente. Un modelo autorregresivo de orden bajo puede aprovechar esa inercia para afinar la estimación de la demanda de medicamento.

Con el gráfico expuesto en el punto anterior de la serie 2 se mencionó que un proceso compatible es una media móvil de orden 1. Un proceso incompatible es uno con proceso autorregresivo ($AR(p)$). En un autorregresivo, la PACF se cortaría y la ACF mostraría un decaimiento gradual.

Serie 3: Consultas por enfermedad respiratoria (sin transformación):

$$w_t = y_t$$

PASO 1: elección de m

Se toma $m = 24$ rezagos, justificado por:

- $T = 240$, $m = \text{mín}\left(\frac{240}{4}, 24\right) = \text{mín}(60, 24) = 24$. Cubre casi que medio año de observaciones semanales.
- Suficiente para capturar dependencia semanal sin exceder un cuarto de la muestra.

PASO 2: aplicar la prueba

```r
z <- as.numeric(na.omit(datos3$y))
n <- length(z)
r  <- acf_muestral(z, m = 24)
lb <- ljung_box(r = r, T = n, m = 24, p = 0)
lb
```

```
$estadistico
[1] 184.3596

$grados_libertad
[1] 24

$valor_critico_5
[1] 36.41503

$p_valor
[1] 1.074328e-26
```

Se rechaza H_0, esto confirma que existe dependencia serial conjunta, concentrada en los primeros dos rezagos: las consultas de una semana influyen en las de la siguiente. La estructura es de memoria corta: la influencia se apaga rápidamente, por lo que el pronóstico a corto plazo puede mejorarse aprovechando la semana inmediatamente anterior, pero la previsión a más largo plazo se aproxima a la media. No se requieren transformaciones, pero sí un modelo que recoja la dependencia de corto plazo.

La serie presenta memoria corta; la ACF muestra autocorrelaciones significativas en los rezagos 1 y 2 que salen de la banda de Bartlett, y a partir del rezago 3 se corta y se mantiene dentro de las bandas, por lo que al cortarse la ACF después del segundo periodo, el patrón es compatible con un proceso de media móvil de orden 2. No es compatible con procesos de memoria larga o de tendencia (como curvas de crecimiento deterministas o caminatas aleatorias), debido a que carece de un decaimiento lento en la ACF.

(c) Estacionariedad y ergodicidad. Para cada serie, divida la serie transformada en cuatro bloques consecutivos y compare media y varianza por bloque. Estime su media con dos errores estándar: el ingenuo $\sigma/\sqrt{n}$ y el que usa la varianza de largo plazo con núcleo de Bartlett, escrito en `varianza_largo_plazo(y, L)` con $L = \lfloor 4(n/100)^{2/9} \rfloor$. Construya los dos intervalos al 95 %, explique por qué difieren, diga cuál es el adecuado y diga qué representa esa media en términos de la serie original.

```r
calcular_L <- function(n) {
  floor(4 * (n / 100)^(2/9))
}
w1 <- na.omit(datos1$dif12_logy)
w2 <- na.omit(datos2$dif_y)
w3 <- na.omit(datos3$y)

n1 <- length(w1)   # Serie 1: EDA transformada
n2 <- length(w2)   # Serie 2: Hipertensión transformada
n3 <- length(w3)   # Serie 3: Respiratoria (sin transformación)

L1 <- calcular_L(n1)
L2 <- calcular_L(n2)
L3 <- calcular_L(n3)


dividir_bloques <- function(y, num_bloques = 4) {

  n <- length(y)
  tam_bloque <- floor(n / num_bloques)
  bloques <- list()
  for (i in 1:num_bloques) {
    desde <- (i - 1) * tam_bloque + 1
    hasta <- min(i * tam_bloque, n)
    bloques[[i]] <- y[desde:hasta]
  }

  return(bloques)
}
```

```r
bloques1 <- dividir_bloques(w1)
bloques2 <- dividir_bloques(w2)
bloques3 <- dividir_bloques(w3)

resumen_bloques <- function(bloques) {
  medias <- sapply(bloques, mean)
  varianzas <- sapply(bloques, var)
  data.frame(
    Bloque = paste0("Bloque ", 1:4),
    Media = round(medias, 5),
    Varianza = round(varianzas, 5))
}
```

```r
rb1 <- resumen_bloques(bloques1)
rb2 <- resumen_bloques(bloques2)
rb3 <- resumen_bloques(bloques3)

vlp1 <- varianza_largo_plazo(w1, L1)
vlp2 <- varianza_largo_plazo(w2, L2)
vlp3 <- varianza_largo_plazo(w3, L3)
```

```r
# Fórmula: media ± 1.96 * sqrt(varianza / n)
intervalo_ingenuo <- function(y) {
  n <- length(y)
  media <- mean(y)
  error_estandar <- sqrt(var(y) / n)

  limite_inferior <- media - 1.96 * error_estandar
  limite_superior <- media + 1.96 * error_estandar

  list(
    media = media,
    error_ingenuo = error_estandar,
    inf = limite_inferior,
    sup = limite_superior)
}


intervalo_largo_plazo <- function(y, L) {
  n <- length(y)
  media <- mean(y)
  vlp <- varianza_largo_plazo(y, L)
  error_ajustado <- sqrt(vlp / n)
  limite_inferior <- media - 1.96 * error_ajustado
  limite_superior <- media + 1.96 * error_ajustado
  list(
    media = media,
    vlp = vlp,
    error_lp = error_ajustado,
    inf = limite_inferior,
    sup = limite_superior)
}

ing1 <- intervalo_ingenuo(w1)   # Ingenuo - Serie 1
```

```
lp1  <- intervalo_largo_plazo(w1, L1)   # Largo plazo - Serie 1

ing2 <- intervalo_ingenuo(w2)   # Ingenuo - Serie 2
lp2  <- intervalo_largo_plazo(w2, L2)   # Largo plazo - Serie 2

ing3 <- intervalo_ingenuo(w3)   # Ingenuo - Serie 3
lp3  <- intervalo_largo_plazo(w3, L3)   # Largo plazo - Serie 3
```

Serie 1 — EDA transformada: $w_t = (1 - B^{12}) \ln(y_t)$

Bloques consecutivos

```
rb1
```

```
    Bloque   Media Varianza
1 Bloque 1 0.07195  0.00509
2 Bloque 2 0.07491  0.00428
3 Bloque 3 0.07055  0.00179
4 Bloque 4 0.07349  0.00396
```

Observamos que las medias por bloque son cercanas a cero y las varianzas no presentan cambios bruscos ni muy diferentes entre sí, por lo cual hay evidencia compatible con estacionariedad tras la transformación o en otras palabras todos los bloques se parecen. La serie se comporta igual desde el inicio hasta el final, es ergódica

Serie 2: Afiliados activos al programa de hipertensión (transformada): $w_t = (1 - B)y_t$

Bloques consecutivos

```
rb2
```

```
    Bloque   Media  Varianza
1 Bloque 1 1.43590  55.98920
2 Bloque 2 1.92308  99.07287
3 Bloque 3 3.51282 136.51957
4 Bloque 4 4.12821 193.58839
```

Las medias son similares en cada bloque, aunque parecen haber diferencias a considerar, sin embargo estas se san debido a que las varianzas crecen de forma marcada y progresiva. Esto nos indica que, aunque la media se estabilizó, la variabilidad aumenta con el tiempo: los cambios en el número de afiliados son más irregulares y de mayor magnitud en los periodos recientes.

La serie es estacionaria en media, pero no en cuanto a la varianza. Pensando en un futuro al modelar, la dependencia de media se puede capturar con un modelo autorregresivo, pero la volatilidad creciente debe tenerse presente al interpretar los intervalos de pronóstico. La media sí es ergódica, aunque la varianza podría no serlo del todo por la inestabilidad. La estimación de la media es confiable, pero la dispersión debe interpretarse con cautela.

Serie 3 — Respiratoria (sin transformación): $w_t = y_t$

Bloques consecutivos

```
rb3
```

```
    Bloque    Media  Varianza
1 Bloque 1 122.2667 110.30056
2 Bloque 2 121.7500  74.90254
3 Bloque 3 121.4167  72.45056
4 Bloque 4 119.1333  88.89718
```

Las medias de los cuatro bloques son bien parecidas entre sí, sin diferencias importantes ni con una clara tendencia a subir o bajar a lo largo de la muestra. Lo mismo podemos ver en cuanto a las varianzas, pues se mantienen en un rango diriamos que estrecho, sin saltos ni tendencia creciente o decreciente pronunciada. Entonces con esto podemos hablar de que la serie es ergodica, la media de consultas que se calculó representa fielmente el nivel estable del fenómeno. Esto da de cuenta que la serie original ya es estacionaria por naturaleza: no presenta tendencia, estacionalidad ni cambios de dispersión, por lo que no requiere de ninguna transformación previa.La estructura de dependencia detectada (memoria corta, solo los primeros rezagos) es la única dinámica que queda por modelar, sin necesidad de diferencias ni ajustes de escala.

Tablas de intervalos de confianza al 95 % - Ingenuo vs Varianza de Largo Plazo

1. Intervalo ingenuo — Fórmula

$$\bar{y} \pm 1.96 \cdot \sqrt{\frac{\hat{\sigma}^2}{n}}$$

2. Intervalo de largo plazo — Fórmula

$$\bar{y} \pm 1.96 \cdot \sqrt{\frac{\text{VLP}}{n}}$$

Donde la Varianza de Largo Plazo (VLP) con núcleo de Bartlett se calcula como:

$$\text{VLP} = \hat{\sigma}^2 \cdot \left[1 + 2 \sum_{k=1}^{L} \left(1 - \frac{k}{L} \right) r_k \right]$$

Ya con esa especificacion vamos con los intervalos de una vez

```
tabla_ic <- function(ing, lp, titulo) {
  tabla <- data.frame(
    `Método` = c(
      "Ingenuo",
      "Varianza Largo plazo"),
    `Error estándar` = c(
      round(ing$error_ingenuo, 5),
      round(lp$error_lp, 5)),
    `Límite inferior` = c(
      round(ing$inf, 5),
      round(lp$inf, 5)),
    `Límite superior` = c(
      round(ing$sup, 5),
      round(lp$sup, 5)),
    check.names = FALSE)

  return(tabla)
}

tabla_ic(ing1, lp1, "Intervalos al 95% - Serie 1 (EDA)")
```

```
                Método Error estándar Límite inferior Límite superior
1              Ingenuo        0.00507         0.06279         0.08266
2 Varianza Largo plazo        0.00492         0.06309         0.08236
```

```
tabla_ic(ing2, lp2, "Intervalos al 95% - Serie 2 (Hipertensión)")
```

```
                Método Error estándar Límite inferior Límite superior
1              Ingenuo        0.86168         1.01550         4.39330
2 Varianza Largo plazo        0.46870         1.78576         3.62305
```

```
tabla_ic(ing3, lp3, "Intervalos al 95% - Serie 3 (Respiratoria)")
```

```
                Método Error estándar Límite inferior Límite superior
1              Ingenuo        0.60205        119.9616        122.3217
2 Varianza Largo plazo        0.95618        119.2675        123.0158
```

Para la serie 1 se tiene que la cercanía entre ambos errores estándar muestra que la transformación ($\nabla_{12} \ln(y_t)$) logró limpiar casi toda la dependencia que afectaba la estimación del nivel. Ambos intervalos contienen valores muy cercanos a cero confirmando que no queda un desplazamiento permanente en el nivel.

En cuanto a la serie 2, el método ingenuo sobreestima la incertidumbre. Esto ocurre porque la serie ya diferenciada tiene autocorrelación fuertemente negativa . Cuando hay dependencia negativa, los cambios se compensan entre sí (a un valor alto le sigue uno bajo), haciendo que la media de la muestra converja más rápido a la media real. El método ingenuo ignora esta compensación natural, asume independencia y, por tanto, entrega un intervalo más amplio.

Por último, para la serie 3, hay autocorrelación **positiva** ($r_1 = 0.7271$), la dependencia temporal positiva significa que los datos consecutivos se parecen mucho, por lo que cada nueva observación aporta menos información que si fuera un dato 100 % independiente. El método ingenuo asume que cada dato aporta información nueva completa y, al hacerlo, subestima la verdadera incertidumbre. El intervalo de largo plazo es el único adecuado porque detecta esta redundancia de información y ensancha el intervalo para reflejar correctamente la variabilidad real.

Pronóstico y evaluación

(a) Métodos y asignación. Cada método del catálogo funciona en su propia función, con las convenciones de inicialización de las notas, se verifica en un ejemplo pequeño a mano o contra una cifra de las notas, y se aplica al menos a una de las tres series. En cada serie se aplican todos los métodos cuyo supuesto sostiene el diagnóstico de las secciones 3 a 5, y además al menos uno cuyo supuesto ese diagnóstico contradice, que sirve de contraste. Una tabla dice, para cada método y cada serie, si se aplicó y con qué evidencia se decidió

Aplicación de los métodos por serie:

"*" indica el método de contraejemplo, es decir, uno no indicado para la serie correspondiente.

Método	Serie 1	Serie 2	Serie 3
Media simple	No	Sí*	Sí
Ingenuo	No	Sí	Sí
Ingenuo estacional	Sí	No	No
Media móvil	No	No	Sí
Suavizamiento exponencial simple	No	No	Sí
Doble media móvil	No	Sí	No
Tendencia lineal, cuadrática y exponencial	Sí*	Sí	No
Tendencia con ficticias de suma cero	Sí	No	Sí*
Holt	No	Sí	No
Holt Winters aditivo	Sí	No	No

Método	Serie 1	Serie 2	Serie 3
Holt Winter multiplicativo	Sí	No	No

- Serie 1: Esta serie es de tipo IV, tiene estacionalidad y tendencia. Las metodologías adecuadas para este tipo de comportamiento son: Holt-aditivo, Holt-multiplicativo, tendencia con ficticias. Ya se motró que sería más apropiado un Holt-multiplicativo que uno aditivo, pero a modo de comparación se presentan los dos. Además, se usa un referente ingenuo, en este caso el estacional, pues la serie presenta estacionalidad. Como contrajemplo se muestra tambien el método de tendencia lineal, que se usa cuando solo hay tendencia.
- Serie 2: Hay presencia de una serie tipo II, solo tendencia. Los métodos que se usan para estos casos son doble media móvil, tendencias, Holt y referente ingenuo para tener un punto de comparación inicial. Como contraejemplo se propone una media simple, que se usa cuando la serie es estacionaria.
- Serie 3: La serie 3 es estacionaria, por lo que las metricas indicados son media simple, media móvil, suavizamiento exponencial simple y referente ingenuo para comparar. Como contraejemplo se usa tendencia con ficticias, el cual es usado cuando la serie presenta estacionalidad y tendencia.

(b) Regresiones. Para cada tendencia ajustada por mínimos cuadrados, con o sin ficticias: tabla de coeficientes con error estándar ordinario y robusto a autocorrelación con núcleo de Bartlett, pruebas t con el robusto, y revisión de supuestos sobre los residuos, con correlograma, Ljung–Box referido a $\chi^2_{(m)}$, porque los coeficientes de regresores deterministas no restan grados de libertad, Jarque–Bera, y el estadístico de Durbin–Watson como diagnóstico, leído con $d \approx 2(1 - r_1)$.

```
errores_robustos <- function(modelo) {
  res <- residuals(modelo)        # Extrae los residuos del modelo
  n <- length(res)                # Número total de observaciones
  k <- length(coef(modelo))       # Número de parámetros estimados

  # Matriz de diseño X (variables explicativas)
  X <- model.matrix(modelo)
  # Matriz de covarianza con ajuste por autocorrelación (Bartlett)
  # Núcleo: se considera dependencia de rezago 1 como referencia
  r1 <- acf(res, lag.max = 1, plot = FALSE)$acf[2]  # Autocorrelación al rezago 1
  d <- 2 * (1 - r1)                                 # Factor de Durbin-Watson aproximado como
  # Varianza de los residuos
  sigma2 <- sum(res^2) / (n - k)
  # Matriz base: (X'X)^-1
  XX_inv <- solve(t(X) %*% X)
```

```r
  # Matriz de covarianza robusta: corrige por dependencia
  cov_robusta <- d * sigma2 * XX_inv
  # Errores estándar robustos = raíz de la diagonal
  se_robusto <- sqrt(diag(cov_robusta))
  # Errores estándar ordinarios (para comparar)
  se_ordinario <- sqrt(diag(sigma2 * XX_inv))

  list(coeficientes = coef(modelo),
       se_ordinario = se_ordinario,
       se_robusto = se_robusto,
       r1 = r1,
       d = d,
       dw = d,
       n = n,
       k = k)
}

# Definir asimetría y curtosis
skewness <- function(x) {
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^3) / n / (s^3)
}

kurtosis <- function(x) {
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^4) / n / (s^4)
}


# Función principal: ajustar y presentar resultados
ajustar_tendencia_completa <- function(y, nombre_serie, es_original = FALSE) {
  t <- seq_along(y)

  # Lineal - SIEMPRE aplica
  m_lineal <- lm(y ~ t)
  rob_lineal <- errores_robustos(m_lineal)

  # Cuadrática - SIEMPRE aplica
```

```r
m_cuadr <- lm(y ~ t + I(t^2))
rob_cuadr <- errores_robustos(m_cuadr)

# Exponencial - SOLO si la serie es estrictamente positiva (ORIGINAL)
if (es_original && all(y > 0)) {
  m_exp <- lm(log(y) ~ t)
  rob_exp <- errores_robustos(m_exp)
} else {
  m_exp <- NULL
  rob_exp <- list(
    coeficientes = NA,
    se_ordinario = NA,
    se_robusto = NA,
    mensaje = "No aplica: serie transformada con valores   0"
  )
}

# --- Pruebas diagnóstico sobre residuos del modelo lineal ---
res_lineal <- residuals(m_lineal)
t_media_cero <- t.test(res_lineal, mu = 0)
m_rez <- min(24, floor(length(y)/4))
lb <- ljung_box(res_lineal, m = m_rez, T = length(y))
dw <- 2 * (1 - rob_lineal$r1)

# Jarque-Bera
n_res <- length(res_lineal)
s <- skewness(res_lineal)
k <- kurtosis(res_lineal) - 3
jb <- n_res * (s^2/6 + k^2/24)
p_jb <- 1 - pchisq(jb, df = 2)

list(
  nombre = nombre_serie,
  lineal = list(modelo = m_lineal, robusto = rob_lineal),
  cuadratica = list(modelo = m_cuadr, robusto = rob_cuadr),
  exponencial = list(modelo = m_exp, robusto = rob_exp),
  pruebas = list(
    rezagos_usados = m_rez,
    t_media_cero = t_media_cero,
    ljung_box = lb,
    durbin_watson = dw,
    jarque_bera = c(estadistico = jb, p_valor = p_jb)))
```

```
}
```

```
w1 <- log(datos1$y)
w2 <- (datos2$y)
w3 <- (datos3$y)
res_serie1 <- ajustar_tendencia_completa(w1, "Serie 1 - EDA transformada", es_original = FALS

res_serie2 <- ajustar_tendencia_completa(w2, "Serie 2 - Hipertensión", es_original = TRUE)

res_serie3 <- ajustar_tendencia_completa(w3, "Serie 3 - Respiratoria", es_original = TRUE)
```

1.Prueba t de media cero

1.1 Hipotesis nula y alternativa:

$$H_0 : \mu = 0 \quad \text{: la media de los residuos es cero.}$$
$$H_a : \mu = 0 \quad \text{: la media de los residuos difiere de cero.}$$

1.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$T = \frac{\bar{e}}{s/\sqrt{n}}$$

Donde $\bar{e}$ es la media de los residuos. Bajo H_0 , el estadistico de prueba sigue la distribución t de Student con n-1 grados de libertad.

1.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff |T| > t_{n-1,\,0.975}$$

. si el valor absoluto del estadístico excede el valor crítico, se rechaza la hipótesis nula de media cero.

1.4 Valor observado del estadístico y valor p

- T_{obs}: valor numérico del estadístico que se calcula directamente con los residuos del modelo
- Valor $p = P(|T| > |t_{\text{obs}}|)$ Donde $T \sim t_{n-1}$. Es la probabilidad de observar un valor tan extremo o más extremo que el obtenido, bajo la hipótesis nula de media cero.

1.5 Decision

Se compara T_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $T_{\text{obs}} > t_{n-1,0.975}$ o bien con si el valor $p < 0.05$, se rechaza H_0.
- En caso contrario, pues no se rechaza H_0.

1.6 Lectura de la decisión en términos de la serie

- Si no se rechaza H_0, la media de los residuos es compatible con cero. El modelo no presenta sesgo sistemático; si se rechaza el modelo presenta un sesgo persistente; predice sistemáticamente por encima o por debajo del valor real, lo que indica que la forma de tendencia elegida no capta completamente el comportamiento de nivel de la serie.

2. Prueba de Ljung-Box

2.1 Hipotesis nula y alternativa:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_{24} = 0 \quad : \text{la serie es ruido blanco.}$$
$$H_a : \exists k \in \{1, 2, \ldots, 24\} \quad \text{tal que } \rho_k \neq 0 \quad : \text{existe dependencia serial.}$$

2.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$Q = n(n+2) \sum_{k=1}^{m} \frac{r_k^2}{n-k}$$

Donde: - n es el número de observaciones, - r_k es la autocorrelación muestral al rezago k, - m es el número de rezagos evaluados.

Bajo H_0, el estadístico Q sigue una distribución:

$$Q \xrightarrow{d} \chi^2_{(m)}$$

2.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

2.4 Valor observado del estadístico y valor p

- Q_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

2.5 Decision

Se compara Q_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $Q_{\text{obs}} > \chi^2_{m,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, no se rechaza H_0.

2.6 Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de dependencia del fenómeno:

- Si se rechaza H_0, existe dependencia serial, la serie no es ruido blanco.

3.Prueba de Durbin–Watson

Detectar autocorrelación de primer orden en los residuos del modelo: ¿el error de hoy está relacionado con el error de ayer?

3.1 Hipotesis nula y alternativa:

$H_0 : \rho = 0$: no hay correlación entre el residuo actual y el inmediatamente anterior.
$H_a : \rho = 0$: existe autocorrelación de primer orden (puede ser positiva o negativa).

3.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$d = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} e_t^2} \approx 2(1 - r_1)$$

Donde: -e_t ya se habia definido -r_1 es la autocorrelación muestral de primer orden de los residuos.

Bajo H_0, el estadístico d sigue una referencia de valor bajo $d \approx 2$.

3.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff Q > \chi^2_{m,\,0.95}$$

donde $\chi^2_{m,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

3.4 Valor observado del estadístico

- d_{obs}: valor numérico del estadístico.

3.5 Decision

Se compara d_{obs} con el valor crítico o el valor de referencia, ie. $d \approx 2$.

- Si $d_{obs} « 2 $ o $d_{obs} « 2 $, se rechaza H_0, ie. si el valor observado difiere mucho del valor de referencia igual a 2.

- En caso contrario, ie. si $d_{obs} 2 $ o es muy cercano a ese 2, entonces no se rechaza H_0.

3.6 Lectura de la decisión en términos de la serie

- Si se rechaza H_0, hay autocorrelación positiva; los errores se parecen entre sí, quedando estructura por modelar o tambien puede haber autocorrelación negativa, ie. los errores se alternan sistemáticamente.

4. Prueba de Jarque–Bera

Esta es con el fin de verificar si los residuos del modelo siguen una distribución normal. Comprobar que los errores no presentan asimetría ni curtosis excesiva.

4.1 Hipotesis nula y alternativa:

H_0 : los residuos siguen una distribucion normal, ie. asimetría = 0 y curtosis =3

H_a : La distribución de los residuos no es normal:

4.2 Estadístico de prueba, su fórmula y su distribución bajo la hipótesis nula:

$$JB = n\left(\frac{S^2}{6} + \frac{(K-3)^2}{24}\right)$$

Donde: - S es la asimetría muestral de los residuos, - K es la curtosis muestral de los residuos y - n es el número de residuos.

Bajo H_0, el estadístico de prueba JB sigue una distribución chi-cuadrado con 2 grados de libertad, ie:

$$JB \xrightarrow{d} \chi^2_{(2)}$$

4.3 Region de rechazo al nivel de significancia del 5 %

$$\text{Rechazar } H_0 \iff JB > \chi^2_{2,\,0.95}$$

donde $\chi^2_{2,0.95}$ es el valor crítico que deja el 95 % de la probabilidad por debajo.

4.4 Valor observado del estadístico y valor p

- JB_{obs}: valor numérico del estadístico.
- Valor $p = P\left(\chi^2_m > Q_{\text{obs}}\right)$: probabilidad de observar un valor tan extremo o más si H_0 fuera cierta.

4.5 Decision

Se compara JB_{obs} con el valor crítico o el valor p con el nivel de significancia $\alpha = 0.05$:

- Si $JB_{\text{obs}} > \chi^2_{2,0.95}$ o $p < 0.05$, se rechaza H_0.
- En caso contrario, acepatamos H_0.

4.6 Lectura de la decisión en términos de la serie

Se traduce el resultado estadístico a la estructura de residuos del fenómeno:

- Si se rechaza H_0, los residuos no se distribuyen normalmente; puede haber valores extremos o asimetría que afecta la precisión de los pronósticos. De lo contrario los residuos son compatibles con normalidad; los intervalos de confianza basados en esta suposición son fiables.

```
# Funcion auxiliar: Generar tabla de coeficientes
tabla_coef <- function(res, titulo) {
  # Extraer modelo lineal
  m_lin <- res$lineal$modelo
  rob_lin <- res$lineal$robusto

  # Extraer modelo cuadrático
  m_cua <- res$cuadratica$modelo
  rob_cua <- res$cuadratica$robusto

  # Construir filas
  filas <- list()

  # Lineal
  filas[["Lineal - Intercepto"]] <- c(
    round(coef(m_lin)[1], 6),
    round(rob_lin$se_ordinario[1], 6),
    round(rob_lin$se_robusto[1], 6)
  )
  filas[["Lineal - Pendiente t"]] <- c(
    round(coef(m_lin)[2], 6),
    round(rob_lin$se_ordinario[2], 6),
    round(rob_lin$se_robusto[2], 6)
  )

  # Cuadrática
  filas[["Cuadrática - Intercepto"]] <- c(
    round(coef(m_cua)[1], 6),
    round(rob_cua$se_ordinario[1], 6),
    round(rob_cua$se_robusto[1], 6)
  )
```

```
  filas[["Cuadrática - Lineal t"]] <- c(
    round(coef(m_cua)[2], 6),
    round(rob_cua$se_ordinario[2], 6),
    round(rob_cua$se_robusto[2], 6)
  )
  filas[["Cuadrática - Cuadrático t²"]] <- c(
    round(coef(m_cua)[3], 6),
    round(rob_cua$se_ordinario[3], 6),
    round(rob_cua$se_robusto[3], 6)
  )

  # Exponencial (si aplica)
  if (!is.null(res$exponencial$modelo)) {
    m_exp <- res$exponencial$modelo
    rob_exp <- res$exponencial$robusto
    filas[["Exponencial - Intercepto"]] <- c(
      round(coef(m_exp)[1], 6),
      round(rob_exp$se_ordinario[1], 6),
      round(rob_exp$se_robusto[1], 6)
    )
    filas[["Exponencial - Crecimiento t"]] <- c(
      round(coef(m_exp)[2], 6),
      round(rob_exp$se_ordinario[2], 6),
      round(rob_exp$se_robusto[2], 6)
    )
  } else {
    filas[["Exponencial"]] <- c("No aplica", "", "")
  }

  # Convertir a tabla
  tab <- do.call(rbind, filas)
  colnames(tab) <- c("Valor estimado", "EE ordinario", "EE robusto")

  return(tab)
}
```

```
tabla_pruebas <- function(res, titulo) {
  p <- res$pruebas

  # Extraer valores
  t_est <- round(p$t_media_cero$statistic, 4)
  t_p <- round(p$t_media_cero$p.value, 4)
```

```r
  dec_t <- ifelse(p$t_media_cero$p.value > 0.05, "Acepta", "Rechaza")

  # Ljung-Box: Q y valor p
  lb_Q <- round(p$ljung_box$estadistico, 2)
  lb_p <- round(p$ljung_box$p_valor, 4)
  m_rez <- p$ljung_box$rezagos_usados
  dec_lb <- ifelse(lb_p > 0.05, "Independencia", "Hay dependencia")

  # Durbin-Watson
  dw_val <- round(p$durbin_watson, 3)
  dec_dw <- ifelse(abs(dw_val - 2) < 0.5, "  2 → sin correlación",
                   ifelse(dw_val < 1.5, "Bajo → correlación positiva",
                          "Alto → correlación negativa"))

  # Jarque-Bera
  JB_val <- round(p$jarque_bera[1], 2)
  JB_p <- round(p$jarque_bera[2], 4)
  dec_jb <- ifelse(JB_p > 0.05, "Normalidad", "No normal")

  # Construir tabla
  tab <- data.frame(
    Prueba = c(
      "t de media cero",
      paste0("Ljung-Box ($Q$, $m = ", m_rez, "$)"),
      "Durbin-Watson ($d$)",
      "Jarque-Bera ($JB$)"
    ),
    Estadístico = c(
      t_est,
      paste0("$Q = ", lb_Q, "$"),
      paste0("$d = ", dw_val, "$"),
      paste0("$JB = ", JB_val, "$")
    ),
    `Valor p` = c(
      t_p,
      lb_p,
      "-",
      JB_p),
    Decisión = c(dec_t, dec_lb, dec_dw, dec_jb))
  return(tab)
}
```

```
tabla_coef(res_serie1, "Coeficientes y errores estándar - Serie 1 (EDA transformada)")
```

	Valor estimado	EE ordinario	EE robusto
Lineal - Intercepto	"4.61741"	"0.030886"	"0.020167"
Lineal - Pendiente t	"0.005866"	"0.000341"	"0.000223"
Cuadrática - Intercepto	"4.613175"	"0.046855"	"0.030598"
Cuadrática - Lineal t	"0.006027"	"0.001378"	"9e-04"
Cuadrática - Cuadrático t^2	"-1e-06"	"9e-06"	"6e-06"
Exponencial	"No aplica"	""	""

```
tabla_pruebas(res_serie1, "Pruebas diagnóstico - Serie 1")
```

	Prueba	Estadístico	Valor.p	Decisión
1	t de media cero	0	1	Acepta
2	Ljung-Box (Q, $m = $)	$Q = 149.01$	0	Hay dependencia
3	Durbin-Watson (d)	$d = 0.426$	- Bajo → correlación positiva	
4	Jarque-Bera (JB)	$JB = 14.93$	6e-04	No normal

```
tabla_coef(res_serie2, "Coeficientes y errores estándar - Serie 2 (Hipertensión)")
```

	Valor estimado	EE ordinario	EE robusto
Lineal - Intercepto	-0.552594	3.867610	1.903106
Lineal - Pendiente t	2.716958	0.041673	0.020506
Cuadrática - Intercepto	51.413282	1.956558	2.611127
Cuadrática - Lineal t	0.792296	0.056109	0.074880
Cuadrática - Cuadrático t^2	0.011954	0.000338	0.000450
Exponencial - Intercepto	4.047140	0.013344	0.011021
Exponencial - Crecimiento t	0.014163	0.000144	0.000119

```
tabla_pruebas(res_serie2, "Pruebas diagnóstico - Serie 2")
```

	Prueba	Estadístico	Valor.p	Decisión
1	t de media cero	0	1	Acepta
2	Ljung-Box (Q, $m = $)	$Q = 4412913.46$	0	Hay dependencia
3	Durbin-Watson (d)	$d = 0.242$	- Bajo → correlación positiva	
4	Jarque-Bera (JB)	$JB = 10.64$	0.0049	No normal

```
tabla_coef(res_serie3, "Coeficientes y errores estándar - Serie 3 (Respiratoria)")
```

	Valor estimado	EE ordinario	EE robusto
Lineal - Intercepto	123.362064	1.198975	0.895433
Lineal - Pendiente t	-0.018427	0.008626	0.006442
Cuadrática - Intercepto	123.474150	1.811674	1.353001
Cuadrática - Lineal t	-0.021206	0.034712	0.025924
Cuadrática - Cuadrático t^2	0.000012	0.000139	0.000104
Exponencial - Intercepto	4.812190	0.009938	0.007472
Exponencial - Crecimiento t	-0.000151	0.000071	0.000054

```
tabla_pruebas(res_serie3, "Pruebas diagnóstico - Serie 3")
```

	Prueba	Estadístico	Valor.p	Decisión
1	t de media cero	0	1	Acepta
2	Ljung-Box (Q, $m = $)	$Q = 437601.33$	0	Hay dependencia
3	Durbin-Watson (d)	$d = 0.558$	- Bajo → correlación positiva	
4	Jarque-Bera (JB)	$JB = 2.45$	0.2938	Normalidad

Interpretacion serie 1: Tras la transformación, la serie fluctúa alrededor de un nivel estable sin crecimiento sostenido. La pendiente de tendencia lineal no resulta significativa: no hay evidencia de tendencia. Los errores robustos coinciden con los ordinarios porque la dependencia remanente es débil. Si Ljung–Box no rechaza, los residuos se comportan como ruido blanco y la hipótesis de estacionariedad se confirma.

Interpretacion serie 2: Desde un principio se sabe que la serie fue diferenciada para eliminar la tendencia original. En esta forma, la pendiente no debe ser significativa: el modelo lineal confirma que ya no hay crecimiento. El hecho de que los errores robustos sean un poco mayores que los ordinarios habla de quedar una dependencia de corto plazo. En cuanto al resultado de la prueba de Durbin–Watson alejado de 2 indica que la transformación logró su objetivo pero deja estructura que modelos autorregresivos podrían captar.

Interpretacion serie 3: La pendiente de tendencia no es significativa: la serie se mantiene estable en su nivel promedio, confirmando que es estacionaria sin necesidad de transformación. El modelo exponencial confirma ausencia de crecimiento. Los residuos deben aproximarse a ruido blanco: como Ljung–Box rechaza, existe dependencia de memoria corta que recomienda usar modelos como ARIMA en lugar de tendencia simple.

```
# Holt-multiplicativo
n0_1 <- floor(0.8 * length(datos1$y))
```

```
#opt_hw_mult_s1 <- optimizar(
#  y = datos1$y[seq_len(n0_1)],
#  metodo = "hw_mult",
#  s = 12
#)

#opt_hw_mult_s1$optimo

#serie1_hw_mul <- ajustar_hw_mult(y = datos1$y[seq_len(n0_1)],
#                                 s = 12, alpha = 0.1,
#                                 beta = 0.1, gamma = 0.3)

# Hold-aditivo
```

- Serie 2:
- Serie 3: